



دانشکده مهندسی کامپیوتر

بررسی روش های بازیابی تصویر با استفاده از مدل های زبانی - تصویری

پایان نامه یا رساله برای دریافت درجه کارشناسی ارشد
در رشته مهندسی کامپیوتر گرایش نرم افزار

زهرا شاکری

استاد راهنما:

دکتر بهروز مینائی بیدگلی

اردیبهشت ماه 1405

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تأییدیه‌ی هیأت داوران جلسه‌ی دفاع از پایان‌نامه /رساله

نام دانشکده: مهندسی کامپیوتر

نام دانشجو: زهرا شاکری

عنوان پایان‌نامه یا رساله:

تاریخ دفاع:

رشته: مهندسی کامپیوتر

گرایش: نرم افزار

ردیف	سمت	نام و نام خانوادگی	مرتبه دانشگاهی	دانشگاه یا مؤسسه	امضا
1	استاد راهنما				
2	استاد راهنما				
3	استاد مشاور				
4	استاد مشاور				
5	استاد مدعو خارجی				
6	استاد مدعو خارجی				
7	استاد مدعو داخلی				
8	استاد مدعو داخلی				

تأییدیه‌ی صحت و اصالت نتایج

باسمه تعالی

اینجانب زهرا شاکری به شماره دانشجویی 401723875 دانشجوی رشته نرم افزار مقطع تحصیلی کارشناس ارشد تأیید می‌نمایم که کلیه‌ی نتایج این پایان‌نامه/رساله حاصل کار اینجانب و بدون هرگونه دخل و تصرف است و موارد نسخه‌برداری شده از آثار دیگران را با ذکر کامل مشخصات منبع ذکر کرده‌ام. در صورت اثبات خلاف مندرجات فوق، به تشخیص دانشگاه مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی ...) با اینجانب رفتار خواهد شد و حق هرگونه اعتراض درخصوص احقاق حقوق مکتسب و تشخیص و تعیین تخلف و مجازات را از خویش سلب می‌نمایم. در ضمن، مسؤولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذی‌صلاح (اعم از اداری و قضایی) به عهده‌ی اینجانب خواهد بود و دانشگاه هیچ‌گونه مسؤولیتی در این خصوص نخواهد داشت.

نام و نام خانوادگی: زهرا شاکری

امضا و تاریخ:

مجوز بهره‌برداری از پایان‌نامه

بهره‌برداری از این پایان‌نامه در چهارچوب مقررات کتابخانه و با توجه به محدودیتی که توسط استاد راهنما به شرح زیر تعیین می‌شود، بلامانع است:

- ☐ بهره‌برداری از این پایان‌نامه/ رساله برای همگان بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه/ رساله با اخذ مجوز از استاد راهنما، بلامانع است.
- ☐ بهره‌برداری از این پایان‌نامه/ رساله تا تاریخ ممنوع است.

نام استاد یا اساتید راهنما:

تاریخ:

امضا:

تقديم به: (اختياري)

.....

تشکر و قدردانی: (اختیاری)

چکیده

در سال‌های اخیر، با رشد نمایی داده‌های تصویری و متنی در فضای وب و شبکه‌های اجتماعی، نیاز به سیستم‌های هوشمند برای بازیابی مؤثر تصویر و متن بیش‌ازپیش احساس می‌شود. در کاربردهایی مانند موتورهای جستجو، تجارت الکترونیک، سیستم‌های تعاملی و حتی حوزه‌هایی نظیر سلامت دیجیتال و امنیت، کاربران اغلب نیازمند جست‌وجو و بازیابی محتوایی هستند که ترکیبی از ورودی متنی و تصویری باشد. این مسئله فراتر از بازیابی مبتنی بر ویژگی‌های دیداری صرف است، چرا که در بازیابی ترکیبی^۱، کاربر می‌تواند یک تصویر را به همراه توضیح متنی ارائه دهد و انتظار داشته باشد سیستم، نتایجی متناسب با هر دو جنبه ارائه دهد. [1]

انسان‌ها جهان پیرامون خود را از طریق کانال‌های متعدد ادراک می‌کنند؛ مانند تصاویر و صداهایی که از طریق بینایی^۲ و شنوایی دریافت می‌شوند. اگرچه هر کانال به‌تنهایی ممکن است ناقص یا همراه با نویز باشد، انسان‌ها به طور طبیعی قادرند اطلاعات گردآوری‌شده از کانال‌های مختلف را ترکیب کنند تا مفاهیم کلیدی موردنیاز برای درک بهتر جهان را استخراج نمایند. الهام از این توانایی انسانی، پژوهشگران را به توسعه الگوریتم‌هایی سوق داده است که بتوانند یادگیری مؤثر از داده‌های چندوجهی^۳ را شبیه‌سازی کنند. به‌عنوان مثال، رایانه‌ها می‌توانند مرتبط‌ترین تصاویر را برای یک پرس‌وجوی متنی جستجو کنند یا محتوای یک تصویر را با استفاده از زبان طبیعی توصیف نمایند. [2]

تحولات اخیر در یادگیری عمیق موجب معرفی مدل‌های زبان-تصویر^۴ شده‌اند که توانسته‌اند شکاف میان داده‌های متنی و تصویری را تا حد زیادی کاهش دهند. از جمله این مدل‌ها می‌توان به CLIP اشاره کرد که توسط OpenAI معرفی شد و با آموزش بر روی صدها میلیون زوج تصویر-متن توانست نگاهی مشترک بین فضای متنی و تصویری برقرار سازد و عملکرد چشمگیری در وظایفی چون بازیابی متقابل متن-تصویر و دسته‌بندی Zero-shot نشان دهد. [3] در ادامه، مدل‌هایی نظیر ALIGN [4] و BLIP [3] با بهره‌گیری از معماری‌های پیشرفته‌تر و داده‌های آموزشی گسترده‌تر، توانایی‌های مشابهی را ارائه داده و در برخی سناریوها عملکرد بهتری از خود نشان دادند. همچنین، مدل‌های عمومی‌تری مانند FLAVA [5] با تأکید بر یادگیری چندوجهی و چندوظیفه‌ای طراحی شده‌اند که بتوانند در طیفی از وظایف دیداری-زبانی عملکرد مناسبی داشته باشند. در گام‌های جدیدتر، خانواده مدل‌های Qwen-VL و به‌ویژه Qwen2.5-VL معرفی شدند که با تکیه بر داده‌های چندزبانه، معماری‌های مقیاس‌پذیر و قابلیت‌های ترکیبی قوی‌تر، توانسته‌اند نمایش‌های مشترک دقیق‌تر و تعمیم‌پذیرتری ایجاد کنند [6].

با وجود این پیشرفت‌ها، همچنان چالش‌های جدی در این حوزه وجود دارد. یکی از چالش‌های مهم، بازیابی Zero-shot است که در آن سیستم باید بتواند مفاهیم یا ترکیب‌هایی را که در داده‌های آموزشی دیده نشده‌اند

¹Composed Image Retrieval

²Vision

³Multimodal Data

⁴Vision-Language Models

به‌درستی تفسیر و بازیابی کند [7]. افزون بر این، مطالعات اخیر نشان داده‌اند که بسیاری از مدل‌های موجود در درک ترکیب معنایی^۱ دچار کاستی هستند، این مدل‌ها هنوز ضعف‌هایی در تفکیک ویژگی‌ها و بازنمایی دقیق آن‌ها دارند [8-10].

یکی از مهم‌ترین چالش‌ها مربوط به زبان‌های کم‌منبع به‌ویژه زبان فارسی است. بیشتر مدل‌های زبانی-تصویری بر اساس داده‌های انگلیسی آموزش‌دیده‌اند و کارایی آن‌ها در زبان فارسی به دلیل کمبود داده‌های موازی متنی-تصویری با افت چشمگیری مواجه می‌شود. با این حال، مسئله کمبود داده، مشکلات نگارشی و تنوع لهجه‌ها و سبک‌های نوشتاری همچنان مانع اصلی در بهبود عملکرد این مدل‌ها در زبان فارسی به شمار می‌رود.

پژوهش حاضر با تمرکز بر این موضوع، تلاش دارد امکان‌سنجی و بهبود کارایی بازیابی تصویر مبتنی بر مدل‌های زبان - تصویر را در زمینه زبان فارسی بررسی نماید. استفاده از مدل‌هایی نظیر CLIP فارسی و نیز بهره‌گیری از توانایی‌های مدل‌های پیشرفته‌تر مانند Qwen2.5-VL [11] می‌تواند زمینه‌ساز ارائه‌ی رویکردی کارآمدتر برای بازیابی تصویر در بسترهای فارسی‌زبان باشد. این مسیر تحقیق، نه‌تنها از نظر علمی، بلکه از منظر کاربردی نیز اهمیت ویژه‌ای دارد؛ چرا که توسعه ابزارهای هوشمند متناسب با زبان فارسی می‌تواند نقش مؤثری در بهبود سامانه‌های جست‌وجو، آرشیوهای دیجیتال و کاربردهای هوش مصنوعی در صنایع مختلف ایفا کند.

واژه‌های کلیدی: بازیابی تصویر ترکیبی، مدل چندوجهی، یادگیری عمیق، CLIP، تطبیق متن و تصویر

¹ Compositionality

فهرست مطالب

فصل 1: مقدمه	1
1-1- مقدمه	2
بیان مسئله	6
1-2- اهمیت و ضرورت تحقیق	7
1-3- هدف پژوهش	8
1-4- تاریخچه	10
1-5- شیوه های نوین	11
سوالات پژوهشی	13
فصل 2: مروری بر منابع	15
2-1- مقدمه	16
2-2- بازیابی تصویر مبتنی بر محتوا	23
2-2-1- استخراج ویژگی	24
2-2-1-1- ویژگی های سطح پایین	25
2-2-2- ویژگی های جهانی	26
2-2-2-1- ویژگی های رنگ	26
2-2-2-2- ویژگی های بافت	27
2-2-2-3- ویژگی های شکل	27
2-2-2-4- اطلاعات مکانی	27
2-2-2-5- ترکیب ویژگی ها	28
2-2-3- اندازه گیری شباهت	28
2-2-4- نمایه سازی و جستجو	29
2-2-5- مزایا	29
2-2-6- چالش های روش های سنتی بازیابی تصویر مبتنی بر محتوا	29
2-3- بازیابی تصویر و تحول آن به سمت روش های معنایی و چندوجهی	31
2-4- بازیابی تصویر ترکیبی	41
2-5- ترنسفورمرها در بازیابی تصویر	42
2-6- معماری های چندوجهی مدرن	42
2-7- مدل های Zero-shot و Few-shot در بازیابی ترکیبی	44
2-8- مدل های زبانی-تصویری	45
2-8-1- مدل CLIP	45
2-8-2- مدل ALIGN	47
2-8-3- مدل BLIP	50
2-8-3-1- مدل QWEN	53
2-8-4- روش Pic2Word	55

63.....	5-8-2- ایده SEARLE
64.....	9-2- فیوژن چندوجهی در بازیابی تصویر مبتنی بر محتوا
65.....	1-9-2- انواع فیوژن چندوجهی
71.....	10-2- دیتاست ها
71.....	 ساختار داده در CIR
74.....	11-2- روش های مبتنی بر مدل های چندوجهی و زبان محور در قطعه بندی تصویر
81.....	1-11-2- محدودیت های روش های کلاسیک قطعه بندی تصویر
83	2-11-2- قطعه بندی پرامپت پذیر و مدل های پایه قطعه بندی : (SAM) Segment Anything
83.....	1-2-11-2- تعریف وظیفه قطعه بندی پرامپت پذیر
84.....	2-11-2-2- SAM به عنوان مدل پایه برای قطعه بندی (Foundation Model)
85.....	3-2-11-2- دیتاست SA-1B و اهمیت مقیاس داده
85.....	4-2-11-2- قطعه بندی مبتنی بر متن و تصویر با CLIPSeg
89.....	12-2- مروری بر ادبیات موضوع
90.....	13-2- نتیجه گیری
95	فصل 3: روش تحقیق
96.....	1-3- مقدمه
Error! Bookmark not defined.	2-3- محتوا
112.....	1-2-3- علت انتخاب روش
112.....	2-2-3- تشریح کال روش تحقیق
117	فصل 4: نتایج و تفسیر آنها
118.....	1-4- مقدمه
118.....	2-4- محتوا
124.....	تولید داده ها
126	فصل 5: جمع بندی و پیشنهادها
127.....	1-5- مقدمه
127.....	2-5- محتوا
127.....	جمع بندی
127.....	نوآوری
127.....	پیشنهادها
129	مراجع
131	پیوست ها

فهرست اشکال

26	 شکل (1-2) دسته بندی ویژگی های سطح پایین در باریابی تصویر
89	 نمونه شکل
116	 زیرنویس شکل
125	 زیرنویس شکل
128	 زیرنویس شکل

فهرست جداول

جدول (1-2) نتیجه بررسی پرسش نامه ها در ارتباط با عوامل موثر	89
جدول (1-3) بالانویس جدول	116
جدول (1-4) بالانویس جدول	125
جدول (1-5) بالانویس جدول	128

فهرست علائم اختصاری

شتاب گرانش	a (m/s^2)
نیرو	F (N)

فصل 1:

مقدمه

1-1- مقدمه

رشد نمایی محتوای چندوجهی در اینترنت، به طور بنیادین نحوه ایجاد، اشتراک گذاری و مصرف اطلاعات را دگرگون کرده است. اکوسیستم های دیجیتال مدرن¹ به طور فزاینده ای با مدالیته های متنوع داده² از جمله تصاویر طبیعی³، اسناد متنی، اینفوگرافیک ها⁴، اسکرین شات ها⁵ و ویدئوها⁶ پر شده اند. این گسترش نیازمند سامانه های بازیابی پیشرفته⁷ است که قادر باشند مفاهیم معنایی⁸ را در میان مدالیته های مختلف درک و تطبیق دهند و فراتر از الگوهای سنتی جست و جوی صرفاً متنی⁹ حرکت کنند. جست و جوی چندوجهی¹⁰ که هدف آن بازیابی محتوای مرتبط¹¹ بدون توجه به نوع مدالیته¹² پرس و جو یا سند است، به عنوان یک قابلیت حیاتی برای کاربردهایی از کشف محصولات تجارت الکترونیک گرفته تا کاوش در متون علمی و پیمایش شبکه های اجتماعی مطرح شده است [12]. سیستم های بازیابی تصویر¹³ که هدف آن ها یافتن تصاویر مشابه با ورودی کاربر از میان پایگاه های داده بزرگ است، نقش مهمی در کاربردهایی نظیر تشخیص پزشکی، تجارت الکترونیک، نظارت تصویری، و جستجوی وب ایفا می کنند [13]. در چارچوب معماری های معاصر بازیابی چندوجهی¹⁴، مدل های تعبیه سازی¹⁵ و بازرتبه بندی¹⁶ دو ماژول

¹ Modern Digital Ecosystems

² Diverse Data Modalities

³ Natural Images

⁴ Infographics

⁵ Screenshots

⁶ Videos

⁷ Advanced Retrieval Systems

⁸ Semantic Concepts

⁹ Traditional Text-only Search Paradigms

¹⁰ Multimodal Search

¹¹ Relevant Content Retrieval

¹² Modality

¹³ Image Retrieval Systems

¹⁴ Contemporary Multimodal Retrieval Architectures

¹⁵ Embedding Models

¹⁶ Reranking Models

حیاتی¹ را تشکیل می دهند. حوزه یادگیری نمایش چندوجهی² طی دهه گذشته پیشرفت های قابل توجهی³ را تجربه کرده است [14].

در میان این آثار پیشگام، مدل CLIP [1] به طور ویژه تأثیرگذار بوده است؛ زیرا نشان داد که یادگیری کنتراستو در مقیاس بزرگ بر روی جفت های تصویر-متن می تواند نمایش های هم تراز و قدرتمند تولید کند. موفقیت این مدل، اهمیت یادگیری فضاهای تعبیه سازی مشترک⁴ را تثبیت کرده است؛ فضاهایی که در آن ها محتوای دارای شباهت معنایی⁵ صرف نظر از نوع مدالیت در نقاط نزدیک به یکدیگر در فضای نمایش قرار می گیرند.

با شتاب گرفتن روند توسعه مدل های پایه (Foundation Models)، مدل های از پیش آموزش دیده بینایی-زبانی چندوجهی (Multimodal Pre-trained Vision-Language Models – VLMs) مانند Qwen-VL (Wang و همکاران، 2024؛ Bai و همکاران، 2025) و GPT-4o (Hurst و همکاران، 2024) به موفقیت های بی سابقه ای (Unprecedented Success) در درک چندوجهی (Multimodal Comprehension) دست یافته اند. با تکیه بر این دستاوردها (Breakthroughs)، جامعه پژوهشی بازیابی چندوجهی (Multimodal Retrieval Community) به طور فزاینده ای به سمت آموزش مدل های تعبیه سازی چندوجهی یکپارچه (Unified Multimodal Embedding Models) مبتنی بر VLM ها حرکت کرده است. از تلاش های شاخص (Notable Efforts) در این حوزه می توان به E5-V (Jiang و همکاران، 2024)، GME (Zhang و همکاران، 2025)، BGE-VL (Zhou و همکاران، 2025) و VLM2Vec (Meng و همکاران، 2025؛ Jiang و همکاران، 2025) اشاره کرد.

آموزش نمایش های چندوجهی یکپارچه (Unified Multimodal Representations) مبتنی بر VLM ها چندین مزیت قابل توجه (Compelling Advantages) به همراه دارد. نخست، VLM ها به دلیل پیش آموزش روی مجموعه داده های تصویر-متن در مقیاس بزرگ دارای هم تراز ذاتی بین وجهی (-Inherent Cross-modal Alignment) هستند. دوم، این مدل ها از مکانیزم های توجه پیشرفته (Sophisticated Attention Mechanisms) برای ثبت تعاملات ریزدانه⁶ میان عناصر بصری و متنی بهره می برند. سوم، آن ها مسیر طبیعی (Natural Pathway) برای پردازش اسناد چندوجهی پیچیده (Complex Multimodal)

¹ Most Critical Modules

² Multimodal Representation Learning

³ Significant Progress

⁴ Shared Embedding Spaces

⁵ Semantically Similar Content

⁶ Fine-grained Interactions

Documents) مانند اینفوگرافیک ها (Infographics) و اسلایدهای ارائه (Presentation Slides) فراهم می کنند که در آن ها اطلاعات بصری و متنی به شدت درهم تنیده اند (Deeply Intertwined). علاوه بر این (Furthermore)، رویکردهای مبتنی بر VLM می توانند دانش گسترده چندزبانه (Extensive Multilingual Knowledge) و چنددامنه ای (Multi-domain Knowledge) نهفته در مدل های پایه را به ارث ببرند (Inherit) که این امر امکان تعمیم پذیری قوی تر (More Robust Generalization) را در سناریوهای متنوع بازیابی (Diverse Retrieval Scenarios) فراهم می سازد.

در میان رویکردهای موجود، بازیابی تصویر ترکیبی¹ به عنوان یک مسئله ی نوظهور، توجه بسیاری از پژوهشگران را به خود جلب کرده است. در این نوع بازیابی، ورودی شامل یک تصویر و یک متن است که هدف آن توصیف تغییرات یا خصوصیات جدید برای اصلاح یا مشخص سازی هدف بازیابی می باشد. این مسئله از نیاز کاربران برای جستجوی دقیق تر بر پایه ی تغییرات مفهومی ناشی می شود [15].

بر خلاف روش های سنتی مانند CBIR² که صرفاً بر ویژگی های بصری تصویر تکیه دارند [16]، یا-Text-to-Image Retrieval که فقط از اطلاعات متنی استفاده می کند [17]، در بازیابی تصویر ترکیبی، هر دو مدالیته باید به صورت مشترک پردازش و ادغام شوند. این امر نیازمند مدل هایی است که بتوانند به درستی تصویر و متن را درک کرده و در یک فضای معنایی مشترک تحلیل کنند.

با ظهور مدل های قدرتمند چندوجهی مانند [1] CLIP، [3] BLIP و اخیراً [11] Qwen2.5-VL، امکان نگاشت همزمان تصویر و متن به یک فضای برداری مشترک فراهم شده است. این مدل ها، از طریق آموزش روی حجم وسیعی از داده های تصویری-متنی، توانایی درک مفاهیم پیچیده بصری-زبانی را به دست آورده اند.

در این پژوهش، با تمرکز بر مدل SEARLE [10] که یکی از مدل های مطرح در بازیابی تصویر ترکیبی است، عملکرد آن در بازیابی تصویر هدف بر اساس ترکیب ورودی تصویر و متن تحلیل می شود. همچنین برای تقویت نتایج، از مدل Qwen2.5-VL به عنوان یک مدل پایه ی قدرتمند زبان و تصویر استفاده خواهد شد.

¹ Composed Image Retrieval - CIR² Content-Based Image Retrieval

در ادامه ی این فصل، ابتدا مسئله تحقیق مطرح شده، سپس اهداف و پرسش های پژوهش بیان می شود. در نهایت، روش انجام تحقیق و ساختار کلی پایان نامه معرفی خواهد شد.

بیان مسئله

در عصر حاضر، با گسترش روزافزون داده های چندرسانه ای به ویژه تصاویر و متن ها در فضای دیجیتال، نیاز به توسعه سیستم های هوشمند برای بازیابی مؤثر اطلاعات تصویری افزایش یافته است. بازیابی تصویر مبتنی بر محتوا¹ مدت ها به عنوان رویکردی رایج مطرح بوده است، اما با ورود نیازهای پیچیده تر کاربران، مانند جستجوی تصویر با ترکیب تصویر دیگر و توصیف متنی، رویکردهای سنتی با محدودیت هایی مواجه شده اند. در سال های اخیر، مدل های یادگیری عمیق چندوجهی همچون CLIP [1] ، BLIP [3] ، و مدل های جدیدتری نظیر Qwen-VL [11] توانسته اند با تلفیق مؤثر اطلاعات تصویری و متنی، دستاوردهای قابل توجهی در زمینه بازیابی ترکیبی داشته باشند. این مدل ها توانایی درک همزمان تصویر و زبان را دارند و می توانند روابط پیچیده میان ویژگی های بصری و توصیفات زبانی را مدل سازی کنند. با این حال، چالش هایی همچنان باقی است؛ از جمله فهم دقیق ترکیب تصویر و متن، مدیریت فضای جستجوی بزرگ، طراحی معماری های سبک برای inference سریع، و ارزیابی دقیق کیفیت بازیابی.

پیشرفت این حوزه نیازمند تحلیل و بررسی عمیق بر روی روش های موجود، شناسایی شکاف های پژوهشی و ارائه پیشنهادهایی برای بهبود عملکرد سیستم های بازیابی تصویر ترکیبی است. این پژوهش تلاش دارد با بررسی مدل های چندوجهی موجود و ارزیابی تجربی برخی از آن ها، تصویری جامع از وضعیت فعلی ارائه داده و مسیرهای تحقیقاتی آینده را روشن سازد.

2-1- اهمیت و ضرورت تحقیق

با افزایش حجم تصاویر دیجیتال در حوزه هایی همچون پزشکی، تجارت الکترونیک، رسانه های اجتماعی، و امنیت، نیاز به سیستم هایی که بتوانند به صورت هوشمند و دقیق، تصاویر مرتبط را بر اساس ترکیبی از ورودی های متنی و تصویری بازیابی کنند، بیش از پیش احساس می شود. کاربران امروزی اغلب با مفاهیمی پیچیده و ترکیبی به جستجوی اطلاعات می پردازند؛ به عنوان مثال، ممکن است کاربر بخواهد تصویری شبیه به یک تصویر داده شده ولی با ویژگی هایی خاص (مثل «شبیه به این تصویر ولی در شب» یا «همین تصویر ولی بدون آدم») را جستجو کند. این نوع جستجو که به آن بازیابی تصویر ترکیبی گفته می شود، به طور مستقیم با نیازهای کاربران واقعی هماهنگ تر است.

تحقیقات سنتی عمدتاً روی بازیابی تصویر بر اساس متن² یا تصویر³ تمرکز داشته اند و کمتر به مسئله ترکیب اطلاعات چندوجهی پرداخته اند. ورود مدل های چندوجهی مانند CLIP[1] ، Qwen-BLIP[3] ، VL[11] افق های جدیدی برای حل این مسئله گشوده اند. با این حال، همچنان سوالاتی در زمینه بهینه سازی معماری ها، درک معنایی بهتر از ترکیب تصویر و متن، و بهبود معیارهای ارزیابی باقی مانده اند که ضرورت تحقیق در این زمینه را دوچندان می کند.

این تحقیق با تمرکز بر بررسی و ارزیابی مدل های چندوجهی در زمینه بازیابی تصویر ترکیبی، تلاش دارد ضمن پر کردن بخشی از خلأ موجود در ادبیات، مسیر را برای پژوهش های آینده نیز هموار سازد.

¹ Composited Image Retrieval

² Text-to-Image Retrieval

³ Image-to-Image Retrieval

3-1- هدف پژوهش

با رشد روزافزون حجم داده های چندرسانه ای، به ویژه تصاویر، و گسترش کاربرد سامانه های هوشمند جست و جو و بازیابی محتوا، نیاز کاربران به روش های دقیق تر و انعطاف پذیرتر برای بازیابی تصاویر افزایش یافته است. در بسیاری از کاربردها، یافتن تصویری صرفاً بر اساس شباهت بصری با یک تصویر موجود کافی نیست؛ بلکه کاربر ممکن است بخواهد تصویر مرجع را همراه با یک تغییر یا ویژگی مشخص که به صورت متنی بیان می شود، مورد جست و جو قرار دهد. برای مثال، کاربر ممکن است بخواهد «تصویری مشابه این تصویر، اما در فضای شب» یا «همین نوع لباس، اما با رنگ قرمز» را بازیابی کند. چنین سناریویی به عنوان بازیابی تصویری ترکیبی¹ شناخته می شود و مستلزم استفاده همزمان از اطلاعات تصویری و متنی در فرآیند تشکیل پرس و جو است.

هدف اصلی این پژوهش، ارزیابی، مقایسه و تحلیل نظام مند روش های مبتنی بر مدل های دیداری-زبانی برای مسئله بازیابی تصویری ترکیبی است. در این مسئله، یک تصویر مرجع به همراه یک توصیف متنی نسبی به سامانه داده می شود و هدف، بازیابی تصویر یا تصاویری از گالری است که ضمن حفظ ویژگی های مرتبط با تصویر مرجع، تغییر یا مشخصه بیان شده در متن را نیز منعکس کنند. از این رو، مسئله اصلی پژوهش بررسی میزان توانایی مدل های دیداری-زبانی در ایجاد نمایش مناسبی از این پرس و جوی ترکیبی و استفاده از آن برای رتبه بندی تصاویر گالری است.

برای دستیابی به این هدف، آزمایش های پژوهش بر روی مجموعه داده استاندارد CIRR انجام می شود و مدل های CLIP، OpenCLIP، SigLIP، BLIP و SEARLE به عنوان روش های مورد مطالعه و مقایسه بررسی خواهند شد. انتخاب این مدل ها امکان مقایسه چند رویکرد متفاوت برای ایجاد نمایش های دیداری-زبانی، ترکیب اطلاعات تصویر و متن و تشکیل پرس و جوی ترکیبی را فراهم می کند. در این چارچوب، تلاش می شود همه مدل ها تحت شرایط یکسان از نظر داده، تصاویر گالری، Ground Truth، پروتکل ارزیابی و معیارهای اندازه گیری مورد مقایسه قرار گیرند تا تفاوت مشاهده شده در عملکرد، تا حد امکان به ویژگی های روش های مورد ارزیابی نسبت داده شود.

یکی از اهداف مهم پژوهش، بررسی تأثیر نحوه ترکیب مؤلفه تصویری و متنی بر عملکرد بازیابی است. به همین منظور، برای روش هایی که از ترکیب یا ادغام نمره ها و نمایش های تصویری و متن استفاده می کنند،

¹ Composed Image Retrieval - CIR

آزمایش های کنترل شده برای بررسی اثر وزن دهی این مؤلفه ها انجام خواهد شد. این آزمایش ها با هدف تعیین میزان وابستگی عملکرد بازیابی به سهم اطلاعات بصری و زبانی و شناسایی تنظیمات مناسب تر انجام می شوند. نتایج این بخش به عنوان تحلیل تکمیلی و آزمایش ablation در کنار نتایج اصلی گزارش خواهند شد.

همچنین، در مواردی که از **caption** های تولید شده استفاده می شود، اثر این اطلاعات به صورت جداگانه و کنترل شده بررسی خواهد شد. در این بخش، **caption** اصلی موجود در **annotation** به عنوان اطلاعات مرجع حفظ می شود و **caption** تولید شده تنها در سناریوهای تعریف شده برای آزمایش مورد استفاده قرار می گیرد. به این ترتیب، امکان بررسی تجربی این موضوع فراهم می شود که آیا افزودن اطلاعات متنی تولید شده می تواند نمایش پرس و جوی ترکیبی و در نتیجه عملکرد بازیابی را بهبود دهد یا خیر.

از نظر ارزیابی، معیارهای رسمی مرتبط با مجموعه CIRR، به ویژه **Recall@K** و **Recall_Subset@K**، به عنوان معیارهای اصلی عملکرد در نظر گرفته می شوند. در کنار این معیارها، شاخص های تکمیلی مانند **MRR**، **AP** و **Precision** در رتبه های مختلف نیز، در صورت نیاز، برای تحلیل دقیق تر رفتار مدل ها گزارش خواهند شد. استفاده همزمان از معیارهای اصلی و تکمیلی امکان بررسی عملکرد مدل ها را هم از منظر توانایی بازیابی تصاویر مرتبط در رتبه های مختلف و هم از منظر کیفیت رتبه بندی فراهم می کند.

یکی دیگر از اهداف پژوهش، بررسی قابلیت باز تولید و هزینه محاسباتی روش های مورد مطالعه است. برای این منظور، فرآیند آماده سازی داده ها، استخراج embedding ها، تشکیل گالری، اجرای inference، رتبه بندی و ذخیره نتایج به گونه ای طراحی می شود که شرایط اجرای آزمایش ها قابل ثبت و تکرار باشد. همچنین، embedding های تصاویر گالری در قالب cache نگهداری می شوند تا از محاسبه مجدد ویژگی ها در آزمایش های تکراری جلوگیری شده و امکان مقایسه منصفانه تر زمان و هزینه اجرای روش ها فراهم شود. در این پژوهش، تمرکز اصلی بر روش های **zero-shot** و بدون آموزش مجدد روی مجموعه داده هدف است؛ بنابراین، هدف پژوهش توسعه و آموزش یک مدل جدید از ابتدا نیست، بلکه ارزیابی توانایی مدل ها و روش های از پیش آموزش دیده در انجام بازیابی تصویر ترکیبی در یک چارچوب آزمایشی یکسان است. این رویکرد امکان بررسی میزان انتقال قابلیت های آموخته شده مدل های دیداری-زبانی به مسئله CIR و مقایسه مستقیم روش های مختلف را فراهم می کند.

در نهایت، پژوهش حاضر در صدد ارائه یک ارزیابی تجربی منسجم، نقاط قوت و ضعف روش های مورد بررسی را شناسایی کرده و مشخص کند که هر روش در چه شرایطی می تواند عملکرد مناسب تری در بازیابی تصویر ترکیبی ارائه دهد. علاوه بر مقایسه مقدار معیارهای ارزیابی، تحلیل خطا، بررسی رفتار مدل ها در

رتبه های مختلف، تحلیل اثر ترکیب اطلاعات تصویری و متنی و ارزیابی هزینه محاسباتی نیز انجام خواهد شد. یافته های این پژوهش می تواند به درک بهتر قابلیت ها و محدودیت های مدل های دیداری-زبانی در مسئله بازیابی تصویر ترکیبی و انتخاب روش مناسب برای کاربردهای آینده کمک کند.

لازم به ذکر است که موضوعاتی مانند توسعه مدل های زبانی-دیداری جدید، آموزش اختصاصی مدل روی داده های CIR، روش های Textual Inversion، مدل های Qwen-VL و بررسی بنچمارک های خارج از چارچوب آزمایش اصلی، در این پژوهش به عنوان محور اصلی ارزیابی در نظر گرفته نمی شوند و در صورت نیاز، می توانند در بخش «پیشنهاد های پژوهشی آینده» مطرح شوند.

4-1- تاریخچه

پژوهش در حوزه بازیابی تصویر¹ از دهه ۱۹۹۰ میلادی آغاز شد و در ابتدا بر مبنای ویژگی های سطح پایین تصویر مانند رنگ، بافت و شکل بنا گردید. این رویکرد که به نام بازیابی تصویر مبتنی بر محتوا² شناخته می شود، تلاش داشت تا با استخراج توصیفگرهای بصری، شباهت میان تصاویر را محاسبه کند [18]. هرچند این روش ها در مقیاس کوچک نتایج قابل قبولی ارائه می کردند، اما به دلیل وجود شکاف معنایی³ یعنی فاصله میان ویژگی های سطح پایین و درک معنایی انسان – قادر به پاسخگویی به نیازهای پیچیده کاربران نبودند.

با ظهور یادگیری عمیق و به ویژه شبکه های عصبی کانولوشنی (CNN)، تحول بزرگی در حوزه بینایی ماشین و بازیابی تصویر به وجود آمد. پژوهش های مطرحی همچون [19] نشان دادند که شبکه های عمیق قادر به استخراج ویژگی های معنایی قدرتمند از تصاویر هستند. این پیشرفت، بنیان گذار نسل جدیدی از سیستم های بازیابی تصویر شد که دقت و کارایی بسیار بالاتری نسبت به روش های سنتی داشتند.

از سوی دیگر، نیاز به تعامل طبیعی تر با سیستم های جستجو منجر به توسعه روش های بازیابی چندوجهی⁴ گردید، که در آن مدالیت های مختلف مانند متن و تصویر به طور همزمان مورد استفاده قرار می گیرند. یکی از دستاوردهای مهم در این حوزه، معرفی مدل های یادگیری مشترک نمایش⁵ است که هدف آن ها نگاشت

¹ Image Retrieval

² Content-Based Image Retrieval - CBIR

³ Semantic Gap

⁴ Multimodal Retrieval

⁵ Joint Representation Learning

داده های متنی و تصویری به فضای مشترک تعبیه می باشد.

در سال های اخیر، مدل های قدرتمندی نظیر [1] CLIP و [4] ALIGN معرفی شدند که با استفاده از داده های عظیم متنی-تصویری توانستند نمایش های چندوجهی بسیار غنی ایجاد کنند. این مدل ها امکان مقایسه مستقیم متن و تصویر را فراهم آورده و نقطه عطفی در پیشرفت سیستم های جستجو و بازیابی تصویر محسوب می شوند.

به موازات این روند، پژوهش های جدیدتر بر روی بازیابی تصویر ترکیبی¹ متمرکز شده اند، جایی که کاربر یک تصویر پایه و یک عبارت متنی تکمیلی را برای مشخص کردن نیاز خود ارائه می دهد. مطالعاتی مانند [10] نشان داده اند که این رویکرد می تواند قابلیت سیستم های جستجو را به میزان چشمگیری افزایش دهد، به ویژه در کاربردهایی همچون تجارت الکترونیک، پزشکی و پایگاه های داده چندرسانه ای بزرگ.

به این ترتیب، مسیر تکامل از CBIR سنتی به یادگیری عمیق در بازیابی تصویر و به مدل های چندوجهی و ترکیبی نشان دهنده گذار تدریجی از تحلیل های سطح پایین به سمت درک معنایی و تعامل هوشمند با کاربر است. این روند پژوهشی همچنان در حال پیشرفت بوده و یکی از محورهای اصلی تحقیقات روز در حوزه بینایی ماشین و پردازش زبان طبیعی محسوب می شود.

5-1- شیوه های نوین

با پیشرفت چشمگیر یادگیری عمیق و مدل های چندوجهی در سال های اخیر، روش های نوینی برای بازیابی تصویر ترکیبی مطرح شده اند که به طور مؤثری بر محدودیت های روش های سنتی غلبه کرده اند. این رویکردها عموماً بر پایه مدل های چندوجهی بنا شده اند که توانایی یادگیری نمایش مشترک از داده های تصویری و متنی را دارند.

یکی از دسته های اصلی این روش ها، مدل هایی هستند که مبتنی بر نمایش عمل می کنند. در این روش ها، تصویر و متن به فضای برداری یکسانی نگاشت می شوند و سپس با ترکیب بردار تصویر پایه و بردار متن اصلاحی، نمایش نهایی ساخته می شود. (Vo et al., 2019) این شیوه مزیت سادگی و قابلیت تعمیم پذیری بالا دارد، اما نقطه ضعف اصلی آن در عدم توانایی مدل برای یادگیری تعاملات پیچیده بین مدالیته ها است.

دسته‌ی دیگری از روش‌ها بر پایه یادگیری توجهی¹ توسعه یافته‌اند. در این روش‌ها، مکانیزم توجه² برای شناسایی بخش‌های مرتبط تصویر با متن به کار گرفته می‌شود. (Chen et al., 2020) نقطه قوت این مدل‌ها توانایی درک جزئیات دقیق‌تر و ارتباط معنایی عمیق‌تر بین تصویر و متن است. با این حال، محاسبات سنگین و نیاز به داده‌های آموزشی حجیم از جمله محدودیت‌های آن‌ها محسوب می‌شود.

همچنین، مدل‌های یادگیری مبتنی بر مقیاس بزرگ³ مانند CLIP [1] و ALIGN (Jia et [20]) انقلابی در این حوزه ایجاد کردند. این مدل‌ها با آموزش روی میلیاردها نمونه متن-تصویر قادر به یادگیری نمایش‌های تعمیم‌پذیر هستند. نقطه قوت این دسته، قابلیت تعمیم روی دامنه‌های مختلف بدون نیاز به بازآموزی گسترده است. نقطه ضعف آن‌ها، نیاز به منابع محاسباتی عظیم در مرحله آموزش و همچنین وجود نویز در داده‌های وب است که ممکن است بر دقت مدل در وظایف خاص تأثیر بگذارد.

در پژوهش‌های اخیر، روش‌های بهبود یافته‌ای مانند SEARLE پیشنهاد شده‌اند که از تنظیم نمایش‌های تعبیه‌شده⁴ برای افزایش دقت بازیابی تصویر ترکیبی استفاده می‌کنند. این رویکردها توانسته‌اند عملکرد مدل‌های پایه را به‌طور چشمگیری ارتقاء دهند. نقطه قوت آن‌ها دقت بالا در وظایف خاص و نقطه ضعفشان نیاز به طراحی دقیق در مرحله تنظیم ویژگی‌هاست.

به‌طور کلی، شیوه‌های نوین بازیابی تصویر ترکیبی مزیت‌هایی همچون افزایش دقت، قابلیت تعمیم‌پذیری، و توانایی درک عمیق‌تر روابط متنی-تصویری را ارائه می‌دهند. اما همچنان با چالش‌هایی نظیر نیاز به داده‌های بزرگ، پیچیدگی محاسباتی، و دشواری در ارزیابی کیفی نتایج مواجه هستند. این امر ضرورت تحقیق و توسعه بیشتر در این حوزه را برجسته می‌سازد.

¹ Attention-based Models

² Attention Mechanism

³ Large-scale Pretrained Multimodal Models

⁴ Embedding Adjustment

سوالات پژوهشی

مدل های یادگیری عمیق چگونه می توانند ترکیب اطلاعات تصویری و متنی را در فرآیند بازیابی تصویر بهینه سازی کنند؟

کدام یک از روش های مبتنی بر مدل های پیش آموزش دیده دیداری-زبانی، تحت یک پروتکل آزمایشی یکسان، برای بازیابی تصویر ترکیبی در مجموعه CIRR عملکرد و هزینه محاسباتی مناسب تری ارائه می کند؟

عملکرد CLIP، OpenCLIP، SigLIP، BLIP و SEARLE در یک گالری، annotation، Ground Truth و پروتکل ارزیابی یکسان چگونه با یکدیگر تفاوت دارد؟

آیا استفاده از caption تولید شده به عنوان ورودی کمکی می تواند عملکرد بازیابی را نسبت به استفاده از caption اصلی بهبود دهد؟ این پرسش فقط در قالب ablation و با کنترل leakage بررسی شود.

رابطه میان دقت بازیابی، زمان inference، حافظه و هزینه استخراج embedding برای مدل های مقایسه شده چیست؟

چه رویکردهایی برای سنجش شباهت میان یک پرس و جوی ترکیبی (تصویر + متن) و مجموعه ای از تصاویر وجود دارد و کدام یک عملکرد بهتری دارد؟

استفاده از مدل های چندوجهی مانند CLIP در چه مواردی منجر به بهبود دقت بازیابی تصویر می شود؟ چه معیارهایی برای ارزیابی عملکرد سیستم های بازیابی تصویر ترکیبی مناسب تر هستند و چگونه می توان دقت و کارایی این سیستم ها را سنجید؟

چه چالش هایی در پیاده سازی سیستم های بازیابی تصویر مبتنی بر ترکیب متن و تصویر وجود دارد و چه راهکارهایی برای رفع آن ها می توان ارائه داد؟

مدل های موجود در چه جنبه هایی (مانند درک معنایی متن یا شباهت بصری تصویر) ضعف دارند و چگونه می توان این نواقص را با استفاده از مدل های جدیدتر یا روش های بهبود یافته پوشش داد؟

فصل 2:

مروری بر منابع

1-2- مقدمه

فصل حاضر به بررسی نظام مند مطالعات و دستاوردهای علمی پیشین در حوزه بازیابی تصویر و به ویژه بازیابی تصویر ترکیبی اختصاص دارد. هدف اصلی این فصل، تحلیل و طبقه بندی یافته های پژوهشگران در سطح بین المللی، تبیین روند تکامل رویکردهای مطرح در این حوزه و همچنین شناسایی چالش ها و خلأهای تحقیقاتی موجود است. مرور ادبیات از بخش های اساسی هر پژوهش علمی محسوب می شود، زیرا با ارائه تصویری روشن از وضعیت دانش موجود، زمینه لازم برای تعریف مسئله پژوهش و جهت دهی به تحقیقات بعدی را فراهم می کند.

در دهه های اخیر، با گسترش سریع داده های چندرسانه ای در فضای دیجیتال، مسئله بازیابی اطلاعات تصویری به یکی از موضوعات مهم در حوزه بینایی ماشین و بازیابی اطلاعات تبدیل شده است. در این میان، رویکردهای اولیه بازیابی تصویر عمدتاً در قالب بازیابی تصویر مبتنی بر محتوا¹ توسعه یافته اند. در این روش ها، تصاویر بر اساس ویژگی های بصری سطح پایین² نظیر رنگ، بافت و شکل توصیف شده و سپس میزان شباهت میان تصاویر بر اساس این ویژگی ها محاسبه می شود. با وجود موفقیت نسبی این رویکردها در برخی کاربردها، محدودیت اصلی آن ها در ناتوانی در درک مفاهیم معنایی تصاویر و وجود شکاف میان ویژگی های بصری و ادراک انسانی، که به عنوان شکاف معنایی³ شناخته می شود، مطرح شده است [18, 21]. با پیشرفت روش های یادگیری عمیق⁴ و به ویژه توسعه شبکه های عصبی کانولوشنی⁵، رویکردهای جدیدی برای استخراج ویژگی های سطح بالاتر و معنایی تر از تصاویر معرفی شد که توانستند عملکرد سیستم های بازیابی تصویر را به طور قابل توجهی بهبود بخشند. در ادامه این روند، ظهور مدل های بینایی-زبان⁶ موجب شکل گیری نسل جدیدی از روش های بازیابی چندوجهی شد که در آن ها اطلاعات بصری و متنی در یک فضای تعبیه سازی مشترک⁷ نمایش داده می شوند.

¹ Content-Based Image Retrieval – CBIR

² Low-Level Visual Features

³ Semantic Gap

⁴ Deep Learning

⁵ Convolutional Neural Networks – CNNs

⁶ Vision-Language Models – VLMs

⁷ Shared Embedding Space

در میان این مدل ها، مدل CLIP¹ [1]، به عنوان یکی از مهم ترین نقاط عطف در توسعه مدل های چندوجهی شناخته می شود. این مدل با استفاده از یادگیری کنتراست² و آموزش بر روی مجموعه بزرگی از جفت های تصویر-متن، قادر به یادگیری نمایش های مشترک برای داده های تصویری و متنی است و امکان مقایسه مستقیم میان این دو مدالیت را فراهم می سازد [1].

در چارچوب این پیشرفت ها، مسئله ای با عنوان بازیابی تصویر ترکیبی مطرح شده است که در سال های اخیر توجه قابل توجهی را به خود جلب کرده است. در این مسئله، پرس و جوی کاربر شامل یک تصویر مرجع³ و یک توصیف متنی نسبی⁴ است که تغییرات مورد نظر نسبت به تصویر مرجع را بیان می کند. هدف سیستم، بازیابی تصویری از میان مجموعه داده است که با ترکیب اطلاعات بصری تصویر مرجع و اطلاعات معنایی متن ارائه شده بیشترین تطابق را داشته باشد [8].

با وجود پیشرفت های قابل توجه در این حوزه، چالش هایی نظیر نیاز به داده های آموزشی برچسب خورده، دشواری ادغام مؤثر اطلاعات چندوجهی و محدودیت در تعمیم پذیری مدل ها همچنان مطرح هستند. در پاسخ به این چالش ها، پژوهش های اخیر رویکردهای نوینی را پیشنهاد کرده اند که از مدل های چندوجهی پیش آموزش دیده و حتی مدل های زبانی بزرگ⁵ برای بهبود عملکرد سیستم های CIR استفاده می کنند. از جمله این روش ها می توان به مدل هایی مانند SEARLE، Pic2Word و CoLLM اشاره کرد که هر یک با بهره گیری از تکنیک هایی نظیر نگاشت تصویر به نمایش های متنی، معکوس سازی متنی⁶ و استفاده از مدل های زبانی برای تولید داده های آموزشی، تلاش کرده اند محدودیت های روش های پیشین را برطرف کنند [10, 22].

بر این اساس، در این فصل ابتدا مفاهیم پایه و سیر تکاملی روش های بازیابی تصویر، به ویژه رویکردهای مبتنی بر محتوا، مورد بررسی قرار می گیرد. سپس تحول این حوزه با ظهور یادگیری عمیق و مدل های چندوجهی بینایی زبان تشریح می شود. در ادامه، مهم ترین پژوهش های انجام شده در زمینه بازیابی تصویر ترکیبی و روش های مبتنی بر مدل های چندوجهی تحلیل و مقایسه خواهند شد. در نهایت، با جمع بندی مطالعات پیشین، نقاط قوت و ضعف رویکردهای موجود و خلأهای تحقیقاتی شناسایی شده و زمینه لازم

¹ Contrastive Language-Image Pre-training

² Contrastive Learning

³ Reference Image

⁴ Relative Text Description


⁵ Large Language Models – LLMs

⁶ Textual Inversion

برای ارائه پژوهش حاضر فراهم می شود.

2-2- بازیابی تصویر¹

بازیابی تصاویر بدنبال یافتن تصاویری است که شامل یک شی یا صحنه مشابه با تصویر مورد جستجو، همانند آنچه در شکل ۲۰ نمایش داده شده است، باشند. موفقیت AlexNet(21) اینرا به ذهن متبادر کرد که ویژگی های نمایان شده در لایه های بالایی یک شبکه عصبی کانولوشن که برای دسته بندی تصاویر آموزش دیده است، را میتوان به عنوان توصیفگر خوبی برای دسته بندی تصاویر مورد استفاده قرار داد. مطالعات بسیار زیادی با همین انگیزه، از شبکه های عصبی کانولوشن برای فعالیت های بازیابی تصاویر استفاده کردند. [review] این مطالعات به نتایج قابل رقابت در قیاس با روش های سنتی همانند VLAD و Fisher Vector دست پیدا کردند. در پاراگراف بعدی ما ایده اصلی موجود در این روشهای مبتنی بر شبکه عصبی کانولوشن را معرفی میکنیم .



Gong et al.(154) با الهام از Spatial Pyramid Matching ایده نوعی reverse SPM را ارائه کرد که patch ها را در مقیاس های چندگانه با شروع از کل تصویر و سپس با ادغام (pool) هر مقیاس بدون توجه به اطلاعات مکانی آن، استخراج میکرد. سپس پاسخهای patch محلی را با استفاده از VLAD encoding در مقیاس بهتری تجمیع میکرد. طبیعت بدون ترتیب VLAD به ایجاد نمود بدون تغییر بهتری کمک

¹ Image retrieval

میکرد. سپس مقادیر عمیق سراسری اصلی با ویژگی های VLAD برای رسیدن به مقیاس های بهتر متصل شده تا تشکیل یک نمایش جدید از تصویر را بدهد.

[165] Razavian et al.(155) از ویژگی های استخراج شده از شبکه OverFeat بعنوان یک نمود تصویری کلی برای استفاده در فعالیت های مختلف مربوط به حوزه بینایی کامپیوتر استفاده کرد. او ابتدا مجموعه آموزشی را با استفاده از نمونه های چرخانده شده و crop شده تغییر داد. سپس برای هر تصویر چندین Subpatch با اندازه های مختلف از مکان های مختلف استخراج کرد. هر sub-patch برای نمود CNN خود محاسبه میشود. فاصله بین تصویر اصلی و تصویر جستجو شده برابر میانگین فاصله هر subpatch از تصویر اصلی قرار داده میشود. با توجه به موفقیت های اخیر که روش های یادگیری عمیق بدست آورده اند، تحقیق انجام شده در (۵۱) بدنبال ارزیابی این است که آیا یادگیری عمیق میتواند فاصله معنایی در بازیابی تصاویر مبتنی بر محتوا (content-based image retrieval (CBIR)) را پر کند یا خیر. نتایج نوید بخش آنها نشان میدهد که مدل های شبکه عصبی کانولوشن از پیش آموزش دیده بر روی دیتاست های عظیم را میتوان بصورت مستقیم برای استخراج ویژگی در فعالیت های CBIR جدید مورد استفاده قرار داد.

اگر از این روش به منظور feature representation در زمینه جدیدی استفاده شود، مشخص شده است که similarity learning باعث بهبود کارایی بازیابی میشود. در ادامه با حفظ مدل های عمیق با یک هدف similarity learning و یا دسته بندی در زمینه جدید میتوان بطور قابل ملاحظه ای دقت را نیز بهبود داد. روش متفاوت دیگری در (۱۵۶) ارائه شده است که در آن، ابتدا patch های تصویری شی مانند با استفاده از یک شی یاب کلی (general object detector) استخراج شده و سپس یک ویژگی CNN از هر object patch با مدل از پیش آموزش دیده AlexNet استخراج میشود. با آزمایشات فراوانی که محققان در این تحقیق خود انجام دادند نهایتاً به این نتیجه رسیدند که روش آنها قادر به کسب بهبود قابل توجهی در دقت با همان میزان هزینه فضایی (space consumption) و هزینه زمانی میباشد.

در آخر بدون استفاده از sliding windows و یا multiple-scale patches Babenko et al.(157) بر روی توصیفگرهای جامعی که تمام تصویر را با استفاده از یک مدل CNN به یک بردار نگاشت میکرد تمرکز کرد. مشخص شد که بهترین کارایی نه در لایه بالایی شبکه بلکه در لایه ای که دو سطح پایین تر از خروجی بود مشاهده شده است. نتیجه مهمی که در اینجا وجود دارد این است که تاثیر سوء PCA بر روی کارایی CNN

کمتر از VLAD و یا Fisher Vector ها است. بنابر این کم حجم سازی (PCA compressing) PCA برای ویژگی های CNN بهتر عمل میکند. در جدول ۶ نتایج بازیابی تصاویر در چند دیتاست عمومی نشان داده شده است.

روشها	Holidays	Paris6K	Oxford5K	UKB
Babenko et al	۷۴,۷	-	۵۵,۷	۳,۴۳
Sun et al	۷۹,۰	-	-	۳,۶۱
Gong et al	۸۰,۲	-	-	-
Razavian et al	۸۴,۳	۷۹,۵۰	۶۸,۰	-(۹۱,۱)
Wan et al	-	۹۴,۷	۷۸,۳	-

• نتایج

مشکل جالب دیگری که در ویژگی های CNN وجود دارد این است که کدام لایه بیشترین اثر را در کارایی نهایی دارد؟ بعضی از روشها ویژگی ها را در لایه تماما متصل دوم استخراج میکنند (۱۵۴, ۱۵۶)

در حالی که بعضی دیگر از روش ها , از لایه تماما متصل اول در مدل CNN خود برای image representation بهره میبرند. (۱۵۵, ۱۵۷) علاوه بر اینها, این انتخابها ممکن است برای دیتاست های مختلف هم تغییر کند(۵۱)بنابر این ما فکر میکنیم تحقیقات بیشتر در زمینه ویژگی های هر لایه هنوز یک مسئله حل نشده (open problem)باقی مانده است .

Semantic Segmentation

طی نیم سال اخیر تعداد زیادی از تحقیقات حول فعالیت قطعه بندی معنایی (semantic segmentation) متمرکز شده اند و نتایج آنها نوید دهنده پیشرفتهای قابل ملاحظه ای هستند.[review] دلیل اصلی موفقیت آنها, استفاده از مدل های CNN ناشی میشود که قادر به مقابله با تخمین های سطح پیکسلی با استفاده از شبکه های از پیش آموزش دیده بر روی دیتاست های با مقیاس بزرگ هستند.Semantic segmentation با

دسته بندی در سطح تصویر (image-level classification) و تشخیص سطح شی (object-level detection) متفاوت بوده و نیازمند mask های خروجی است که دارای توزیع مکانی دو بعدی باشند.

برای semantic segmentation, پیشرفتهای اخیر در روش های مبتنی بر CNN را میتوان بصورت زیر خلاصه کرد:

Detection-based segmentation

FCN-CRFs based segmentation

Weakly supervised annotations

Detection-based segmentation

این روش تصاویر را بر اساس پنجره های کاندید خروجی حاصله از فاز تشخیص شی قطعه بندی میکند.
[review]

RCNN (31) و SDS(60) ابتدا پیشنهادهایی برای هر ناحیه (region proposals) را برای تشخیص شی تولید کرده و سپس از روش های اضافی برای قطعه بندی ناحیه و انتساب پیکسلها به برجسب کلاس از فاز تشخیص استفاده میکردند. (158) Hariharan et al. روشی را بر مبنای SDS(60) ارائه کرد که در آن hypercolumn در هر پیکسل را بعنوان برداری از فعالسازی ها در نظر گرفت و به این وسیله به بهبود عظیمی دست پیدا کرد. یک مشکل قطعه بندی بر اساس تشخیص, هزینه اضافی زیاد بابت تشخیص اشیاء است. (159) Dai et al. بدون استخراج نواحی از تصاویر خام, یک روش convolutional feature masking (CFM) را به منظور استخراج پیشنهادها بصورت مستقیم از feature map طراحی کرد. از آنجایی که feature map های کانولوشنی تنها یکبار نیازمند محاسبه شدن هستند, روش بهینه و کارامدی است هرچند که خطاهای ایجاد شده توسط پیشنهادها و [افاز] تشخیص شی معمولاً در مرحله قطعه بندی پخش میشوند.

FCN-CRFs based segmentation

در این روش که استراتژی محبوبی شده و پایه ای برای انجام semantic segmentation شده است با جایگزینی لایه های تماماً متصل با لایه های کانولوشنی بیشتر, به قطعه بندی معنایی پرداخته میشود. (۴۸), (۱۶۰). Long et al. (48). معماری نوینی را تعریف کرد که در آن اطلاعات معنایی از یک لایه جامع عمیق به همراه اطلاعات ظاهری از یک لایه کم عمق مناسب برای تولید قطعه بندی های دقیق و با جزئیات

استفاده کرد. (DeepLab ۱۶۰ مدل FCN مشابه ای را ارائه کرد که علاوه بر موارد فوق، از نیروی conditional random fields (CRFs) نیز در FCN برای بازیابی دقیق مرزها استفاده کرد. Lin et al. (161) به جای استفاده از CRF ها بجای یک مرحله post-processing بطور مشترک FCN و CRF را بوسیله آموزش قطعه به قطعه، آموزش داد. به همین شکل (۱۶۲) نیز CRF ها را به صورت یک recurrent neural network (RNN) تبدیل کرد که میشد آنرا به عنوان بخشی از یک مدل FCN اضافه کرد.

Weakly supervised annotations

علاوه بر پیشرفت هایی صورت گرفته در مدل های قطعه بندی، بعضی کارها بر روی قطعه بندی با سرپرست ضعیف (weakly supervised segmentation) تمرکز کرده اند. Papandreou et al. (163) قطعه بندی چالش برانگیزتری را با داده آموزشی بطور ضعیف حاشیه نویسی شده (weakly annotated training data) مثل محفظه های شناسایی (bounding boxes) و یا برچسب های سطح تصویر (image-level labels) مورد مطالعه قرار داد. به همین شکل روش BoxSup (164) از حاشیه نویسی های محفظه شناسایی (bounding box annotations) جهت تخمین ماسک های قطعه بندی (segmentation masks) که برای بروز آوری شبکه بصورت تکراری مورد استفاده قرار می گرفتند، بهره برد. این کارها نشان داند که کارایی عالی در زمان ترکیب تعداد کمی از تصاویر حاشیه نویسی شده در سطح پیکسل با تعداد زیادی از تصاویر حاشیه نویسی شده با محفظه شناسایی بدست می آید.

خصوصیات اصلی روش های بالا و مقایسه بین نتایج آنها در 2012 PASCAL VOC در جدول ۷ نمایش داده شده است.

پیشینه و مروری بر روش های مختلف یادگیری عمیق (با محوریت Computer Vision)

3-2- بازیابی تصویر مبتنی بر محتوا¹

بازیابی تصویر مبتنی بر محتوا که به اختصار CBIR نامیده می شود، به مجموعه ای از روش ها و الگوریتم هایی اطلاق می شود که هدف آن ها، جست و جوی تصاویر مشابه بر اساس محتوای بصری² است، نه اطلاعات متنی یا برچسب های انسانی (Tags، Metadata).

در این رویکرد، سیستم با تحلیل ویژگی های ذاتی تصویر مانند رنگ (Color Features)، بافت (Texture Features) و شکل (Shape Features)، نمایش عددی تصویر را استخراج کرده و با مقایسه این نمایش ها، میزان شباهت میان تصاویر را تعیین می کند.

در مقابل روش های مبتنی بر متن (Text-Based Image Retrieval)، که به توصیفات انسانی، برچسب ها و کلمات کلیدی وابسته اند، سیستم های CBIR مستقل از مداخله انسان عمل می کنند و بدون نیاز به برچسب گذاری دستی، توانایی بازیابی تصاویر مشابه را دارند. همین استقلال باعث شده است CBIR در حوزه های زیر جایگاه مهمی پیدا کند:

- پزشکی (Medical Imaging)
- پایش ویدئویی (Video Surveillance)
- تحلیل محتوای وب (Web-Scale Image Search)
- امنیت و تشخیص هویت
- چنדרسانه ای و مدیریت دارایی های دیجیتال

این رویکرد نخستین بار در اوایل دهه 1990 مورد توجه قرار گرفت و در دهه های بعدی توسعه پیدا کرد [21].

پژوهش های نخستین در حوزه ی بازیابی تصویر عمدتاً بر بازیابی مبتنی بر محتوا متمرکز بودند؛ جایی که

¹ Content-Based Image Retrieval — CBIR

² Visual Content

شباهت میان تصاویر با تکیه بر ویژگی های سطح پایین¹ نظیر توزیع رنگ، بافت، لبه ها و ویژگی های هندسی تعیین می شود. سیستم های اولیه نظیر QBIC و Photobook نشان دهنده ی کاربرد عملی این رویکرد محسوب می شوند و می شوند و مسیر را برای کارهای بعدی هموار کرده اند [21].

یک سامانه ی بازیابی متنی مبتنی بر محتوا معمولاً از سه مؤلفه اصلی تشکیل می شود:

1-3-2- استخراج ویژگی

یکی از مهمترین مراحل در بازیابی تصویر مبتنی بر محتوا، مرحله استخراج ویژگی است که در آن تصویر به مفاهیم بصری و ویژگی های عددی تبدیل می شود. ویژگی های استخراج شده می توانند شامل ویژگی های سطح پایین مانند رنگ، شکل، بافت، و اطلاعات فضایی یا توصیف کننده های محلی باشند. این مرحله تعیین کننده برای دقت و کارایی کل سیستم محسوب می شود.

عادی سازی یا طبقه بندی اختیاری: پس از استخراج ویژگی ها، مرحله ای اختیاری به نام عادی سازی یا طبقه بندی می تواند انجام شود تا ویژگی ها را برای فرآیندهای بعدی بهینه سازی کند.

هدف استخراج ویژگی تبدیل ادراک انسان به یک توصیف عددی است که می تواند توسط ماشین ها دستکاری شود. دقت تصاویر بازیابی شده تا حد زیادی تحت تأثیر ویژگی هایی است که استخراج می شود. با این حال، این انتخاب بر اساس نیازهای کاربر است. تغذیه ویژگی های استخراج شده به الگوریتم های یادگیری ماشین (با نظارت یا بدون نظارت) می تواند عملکرد بازیابی تصویر مبتنی بر محتوا را بهبود بخشد.

روند تحقیقات اخیر بازیابی تصویر بر استفاده از یادگیری عمیق برای بهبود دقت به بهای افزایش زمان اجرا متمرکز است. مشکل دیگری که بر عملکرد بازیابی تصویر مبتنی بر محتوا تأثیر منفی می گذارد (یعنی استفاده از حافظه، مقیاس پذیری، سرعت، دقت) ویژگی های ابعادی بالایی است که معمولاً هنگام تلاش برای ترجمه محتوای تصویر بصری به یک فرم ویژگی عددی ایجاد می شوند. این نمایش های ویژگی با ابعاد بالا، که به عنوان «نفرین ابعاد» شناخته می شوند، معمولاً ماهیتی پراکنده دارند. "کاهش ابعاد" راه حلی برای این مشکل است. در ادبیات، تعدادی از مطالعات جامع بسیاری از روش های پیشنهادی برای کاهش ابعاد را مورد بحث قرار دادند. معیار تشابه یکی دیگر از فرآیندهای حیاتی است که بر عملکرد بازیابی تصویر مبتنی بر محتوا تأثیر دارد.

¹ low-level features


از آنجایی که این اندازه گیری با چیدمان بردار ویژگی تعیین می شود، انتخاب یک اندازه گیری نامناسب منجر به بازگشت تصاویر مشابه کمتر می شود و دقت سیستم بازیابی تصویر مبتنی بر محتوا را کاهش می دهد. به عبارت دیگر با استفاده از معیار تشابه مناسب می توان به دقت بالایی دست یافت. از آنجایی که تعدادی از مجموعه داده ها در چارچوب های بازیابی تصویر مبتنی بر محتوا استفاده می شوند، معیارهای خاصی مانند دقت، یادآوری و زمان اجرا معمولاً برای تعیین اثربخشی بازیابی تصویر مبتنی بر محتوا استفاده می شوند که تحت تأثیر انتخاب مجموعه داده تصویر قرار می گیرند.

به طور کلی، بسته به روش های استخراج ویژگی، ویژگی ها به ویژگی های جهانی و ویژگی های محلی طبقه بندی می شوند. ویژگی های جهانی (به عنوان مثال رنگ، بافت، شکل و اطلاعات فضایی) نمایشی برای کل تصویر می دهند. آنها این مزیت را دارند که در استخراج ویژگی و محاسبات شباهت سریعتر هستند. از سوی دیگر، آنها نمی توانند بین پس زمینه و شی در تصویر (قسمت های مختلف تصویر) تفاوت قائل شوند. این باعث می شود که آنها برای بازیابی در صحنه های پیچیده یا تشخیص اشیا نامناسب باشند، اما برای طبقه بندی و تشخیص اشیا مناسب هستند. در مقایسه با ویژگی جهانی، ویژگی های محلی برای بازیابی تصویر، تطبیق وظایف و شناسایی مناسب هستند. "تشخیص شیء وظیفه شناسایی شی و برچسب گذاری شی در یک تصویر است در حالی که تشخیص شی مربوط به وجود یک شی است که متعلق به یک کلاس از پیش تعریف شده در تصویر و مکان آن است. بنابراین، طبقه بندی یک وظیفه فرعی برای تشخیص اشیا است. ویژگی های محلی به عنوان نقاط کلیدی یا برخی از قسمت های تصاویر به عنوان مثال، گوشه ها، حباب ها و لبه ها تعریف می شوند. آنها نسبت به مقیاس، چرخش، ترجمه، تغییر پس زمینه، درهم و برهمی و انسداد جزئی قوی هستند.

1-1-3-2- ویژگی های سطح پایین

همانطور که قبلاً ذکر شد، استخراج و انتخاب ویژگی که نشان دهنده محتوای معنایی تصاویر است، نقش اصلی را در بازیابی تصویر مبتنی بر محتوا بازی می کند. این ویژگی ها را می توان به ویژگی های کلی (یعنی رنگ، بافت، شکل و اطلاعات فضایی) که کل تصویر را توصیف می کنند، و ویژگی های محلی، که معمولاً از طریق تقسیم تصویر به بخش ها یا از طریق محاسبه برخی از نکات کلیدی به دست می آیند، تقسیم می شوند. مانند گوشه ها، حباب ها و لبه ها. ویژگی های محلی در برابر تغییرات مقیاس، ترجمه و چرخش ثابت

هستند. هر دو نوع در این بخش همراه با مروری بر مطالعات اخیر برای نشان دادن اهمیت ویژگی های انتخاب شده و تأثیر آنها بر عملکرد سیستم توضیح داده می شود.



شکل (2-1) دسته بندی ویژگی های سطح پایین در بازیابی تصویر

2-3-2- ویژگی های جهانی

ویژگی های جهانی مانند رنگ، بافت، شکل و اطلاعات فضایی، از مهم ترین شاخص های مورد استفاده در بازیابی تصویر مبتنی بر محتوا هستند. این بخش به بررسی اجمالی هر یک از این ویژگی ها و روش های استخراج آنها می پردازد.

2-3-2-1- ویژگی های رنگ

ویژگی رنگ به دلیل قابلیت تشخیص بصری توسط انسان، یکی از مهم ترین ویژگی هایی است که در بازیابی تصویر به کار گرفته می شود. این ویژگی ها در فضا های رنگی مختلفی مانند RGB، YCbCr، و LAB محاسبه می شوند. از جمله توصیفگرهای رنگ می توان به لحظه های رنگی، همبستگی رنگی، هیستوگرام رنگی و ماتریس هم رخداد رنگ اشاره کرد. هر چند ویژگی های رنگ به دلیل ثبات در برابر ترجمه، چرخش و

تغییر مقیاس قوی هستند، اما ضعف هایی در انتقال اطلاعات مکانی دارند که این محدودیت را با استفاده از ویژگی های مکمل باید برطرف کرد.

2-2-3-2- ویژگی های بافت

بافت ها الگوهای تکراری و ساختاری هستند که نمی توانند به تنهایی بر اساس شدت یا رنگ تعریف شوند. این ویژگی به دلیل اهمیت آن در تصاویر واقعی، نقش محوری در تشخیص الگو و بازیابی تصویر ایفا می کند. با این حال، پیچیدگی محاسباتی و حساسیت به نویز از چالش های اصلی روش های مبتنی بر بافت هستند. روش های متعددی برای تحلیل بافت استفاده شده اند، مانند فیلترهای گابور، ماتریس هم وقوع سطح خاکستری (GLCM) و تبدیل موجک.

2-2-3-2- ویژگی های شکل

ویژگی های شکل از جمله ویژگی های سطح پایین هستند که به شناسایی اشیاء کمک می کنند. استخراج این ویژگی ها یا براساس منطقه¹ یا براساس مرز² انجام می شود. در روش های منطقه محور، استخراج از کل منطقه صورت می گیرد، در حالی که در روش های مبتنی بر مرز، تنها مرز اشیاء در نظر گرفته می شود. توصیفگرهایی مانند توصیفگر فوریه و لحظات هندسی از رایج ترین روش های استخراج شکل هستند. این ویژگی ها معمولاً برای بهبود دقت با سایر ویژگی ها ترکیب می شوند.

2-3-2-4- اطلاعات مکانی

بسیاری از روش های استخراج ویژگی های سطح پایین مانند رنگ و بافت، فاقد اطلاعات مکانی هستند. اطلاعات مکانی به موقعیت نسبی اشیاء در تصویر اشاره دارد. برای رفع این مشکل، روش هایی مانند تطبیق

¹ region-based

² contour-based

هرم فضایی توسعه یافته اند که به ثبت بهتر ویژگی های مکانی کمک می کنند. به عنوان مثال، در رویکرد تطبیق هرم فضایی، تصویر به سطوح مختلف تجزیه می شود و ویژگی های مکانی در هر سطح ثبت می شوند.

در نسل های اولیه بازیابی تصویر مبتنی بر محتوا از ویژگی های مهندسی شده¹ مانند هیستوگرام رنگ²، توصیف گرهای بافتی³ و ویژگی های شکل⁴ مورد استفاده قرار می گرفتند. با ظهور شبکه های عصبی کانولوشنی⁵، استخراج ویژگی عمیق⁶ به رویکرد غالب تبدیل شد [18, 21].

5-2-3-2- ترکیب ویژگی ها

در ابتدا، روش های بازیابی تصویر مبتنی بر محتوا از یک ویژگی برای بازیابی تصاویر استفاده می کردند که دقت پایینی داشتند. برای بهبود عملکرد و دقت، ترکیب چندین ویژگی مانند رنگ، بافت و شکل مطرح شد. به عنوان مثال، شریواستاو و تایاجی (2015) یک سیستم سه مرحله ای برای بازیابی تصاویر پیشنهاد کردند که ابتدا ویژگی های رنگی، سپس بافت و در نهایت ویژگی های شکل را برای بازیابی تصاویر استفاده می کند. این رویکرد با تغییر پارامترهایی مانند تعداد تصاویر بازیابی شده در هر مرحله، دقت نتایج را بهبود می بخشد.

3-2-3- اندازه گیری شباهت⁷

پس از نمایش تصاویر در فضای ویژگی، شباهت میان تصویر پرسوجو و تصاویر موجود در پایگاه داده با معیارهایی مانند فاصله اقلیدسی⁸، کسینوسی⁹ و ... محاسبه می شود.

¹ Handcrafted Features

² Color Histogram

³ Texture Descriptors

⁴ Shape Features

⁵ Convolutional Neural Networks – CNNs

⁶ Deep Feature Extraction

⁷ Similarity Measurement

⁸ Euclidean Distance

⁹ Cosine Similarity

در روش های یادگیری عمیق، گاهی این فضا با هدف بیشینه سازی جدایی پذیری از طریق اهداف تضعیفی¹ و سه تایی² آموزش داده می شوند.

4-3-2- نمایه سازی و جستجو³

برای سازگاری با داده های وب مقیاس⁴، تکنیک هایی نظیر درخت های تقریباً نزدیک ترین همسایه⁵ و روش های فشرده سازی بردار⁶ به کار گرفته شده اند. در مرورهای ده ساله ی بازیابی تصویر مبتنی بر محتوا، تغییرات این مؤلفه ها و حرکت به سمت پایگاه های بسیار بزرگ و وب مقیاس⁷ را تحلیل میکند [21].

5-3-2- مزایا

- مستقل از برچسب دهی دستی؛ کار با تصاویر بدون تکیه بر متاداده های متنی امکان پذیر بود.
- مناسب برای بازیابی سریع و اولیه در مجموعه های کوچک تا متوسط.

6-3-2- چالش های روش های سنتی بازیابی تصویر مبتنی بر محتوا

اگرچه روش های کلاسیک در زمان خود تحول بزرگی ایجاد کردند، اما محدودیت های بنیادینی وجود داشت که باعث کاهش اثربخشی آنها در محیط های واقعی و داده های پیچیده شد.

۱. شکاف معنایی⁸

¹ Euclidean Distance

² Triplet Loss

³ Indexing and Retrieval

⁴ Web-Scale

⁵ Approximate Nearest Neighbor – ANN

⁶ Vector Compression

⁷ Web-Scale

⁸ semantic gap

ماشین تنها ویژگی های آماری تصویر را می بیند، در حالی که انسان مفاهیم، اشیا و روابط معنایی را درک می کند.

به عنوان مثال، دو تصویر ممکن است از نظر رنگ و بافت مشابه باشند ولی از نظر معنایی هیچ ارتباطی نداشته باشند.

(Liu et al., 2007)، ص. 3)

۲. حساسیت به تغییرات محیطی

روش های سنتی نسبت به موارد زیر بسیار حساس بودند:

- تغییر زاویه دید
 - روشنایی
 - مقیاس
 - وجود نویز یا پس زمینه پیچیده
- کوچک ترین تغییر در شرایط تصویربرداری می توانست نتایج را کاملاً تغییر دهد.

۳. ناتوانی در ترکیب قیدها (Composite Constraints)

در پرس و جوهای ترکیبی مانند:

«همین کیف، اما رنگ روشن تر و طرح ساده تر»

یا

«همین کت، ولی یقه متفاوت»

روش های سنتی قادر به اعمال همزمان چند تغییر معنایی نبودند.

این محدودیت ها زمینه ساز ظهور شبکه های عصبی عمیق و مدل های چندوجهی شدند، که توانستند اتصال بهتری میان تصویر و مفهوم برقرار کنند.

- ویژگی های سطح پایین قادر به انتقال مفاهیم معنایی سطح بالا¹ را نیستند (Liu et al., 2007)، ص. 3؛ لذا نتایج ممکن است از انتظارات انسانی فاصله داشته باشند.
 - وابستگی زیاد به انتخاب ویژگی ها و معیارهای مقایسه ای دستی.
- این محدودیت ها انگیزه ای اصلی برای توسعه ای روش های مبتنی بر یادگیری معنایی و چندوجهی بوده اند. [21].

¹ semantic concepts

4-2- بازیابی تصویر و تحول آن به سمت روش های معنایی و چندوجهی

بازیابی تصویر¹ یکی از حوزه های مهم در هوش مصنوعی و بینایی کامپیوتری است که هدف آن یافتن تصاویر مرتبط با یک پرس و جو² از میان مجموعه ای بزرگ از تصاویر می باشد. پرس و جو می تواند به صورت متنی، تصویر یا ترکیبی ارائه شود. در شکل کلاسیک، بازیابی تصویر بر اساس ویژگی های سطح پایین مانند رنگ، بافت و شکل صورت می گرفت که به آن بازیابی تصویر مبتنی بر محتوا³ گفته می شود [13].

اما بازیابی تصویر مبتنی بر محتوا توانایی محدودی در درک معنایی تصاویر داشت و نمی توانستند با نیازهای پیچیده کاربران تطابق پیدا کنند، به همین دلیل مفهوم بازیابی تصویر معنایی⁴ مطرح شد؛ در این روش با بهره گیری از مدل های یادگیری ماشین و یادگیری عمیق⁵، تلاش می شود تا مفاهیم معنایی از تصاویر استخراج شوند. [Liu et al., 2007]

ظهور شبکه های عصبی پیچشی (CNNs) و سپس مدل های ترنسفورمری، امکان استخراج ویژگی های سطح بالا را فراهم کرد و موجب افزایش چشمگیر دقت بازیابی تصویر گردید [19] (Krizhevsky et al., 2012); (He et al., 2016).

یادگیری عمیق در بینایی کامپیوتر و بازیابی تصویر

با معرفی شبکه های عصبی کانولوشنی (CNN)، بازیابی تصویر دچار تحول اساسی شد. در این روش ها، به جای ویژگی های دستی، از ویژگی های خودآموخته (Learned Features) در لایه های عمیق شبکه استفاده می شود.

1-2-2. شبکه های عصبی کانولوشنی (Convolutional Neural Networks – CNNs)

CNN ها شبکه هایی هستند که برای پردازش داده های تصویری طراحی شده اند و از عملکرد کانولوشن برای استخراج ویژگی های مکانی استفاده می کنند. مقاله مشهور AlexNet (Krizhevsky et al., 2012) نقطه

¹ Image Retrieval

² Query

³ Content-Based Image Retrieval – CBIR

⁴ Semantic Image Retrieval

⁵ Deep Learning

آغاز انقلاب یادگیری عمیق در بینایی کامپیوتر بود و نشان داد شبکه های عمیق می توانند عملکردی بسیار بهتر از روش های سنتی در استخراج ویژگی داشته باشند.

معماری های مطرح:

• **AlexNet** – معرفی شبکه عمیق با ReLU و Dropout

[Krizhevsky et al., 2012]

• **VGGNet** – معماری ساده اما عمیق با فیلترهای 3×3

[Zisserman, 2014 & Simonyan]

• **ResNet** – معرفی اتصالات باقی مانده (Residual Connections)

برای رفع مشکل ناپدید شدن گرادیان

[He et al., 2016]

این سه مدل پایه بسیاری از سیستم های بازیابی تصویر مدرن هستند.

۱- Convolutional Neural Networks (CNNs)


شبکه های عصبی کانولوشن (CNN) یکی از مهمترین روش های یادگیری عمیق هستند که در آنها چندین لایه با روشی قدرتمند آموزش می بینند (۲۰) این روش بسیار کارآمد بوده و یکی از رایجترین روشها در کاربردهای مختلف بینایی کامپیوتر است. تصویر کلی یک معماری شبکه عصبی کانولوشن در شکل ۲ نمایش داده شده است. بطور کلی، یک شبکه CNN از سه لایه اصلی تشکیل میشود که عبارتند از: لایه کانولوشن، لایه Pooling و لایه تماماً متصل. لایه های مختلف وظایف مختلفی را انجام میدهد. در شکل ۲ یک معماری کلی از شبکه عصبی کانولوشن برای دسته بندی تصاویر (۲۱) بصورت لایه به لایه نمایش داده شده است.

در هر شبکه عصبی کانولوشن دو مرحله برای آموزش وجود دارد. مرحله feed forward و مرحله backpropagation یا پس انتشار. در مرحله اول تصویر ورودی به شبکه تغذیه میشود و این عمل چیزی جز ضرب نقطه ای بین ورودی و پارامترهای هر نورون و نهایتاً اعمال عملیات کانولوشن در هر لایه نیست. سپس خروجی شبکه محاسبه میشود. در این جا به منظور تنظیم پارامترهای شبکه و یا به عبارت دیگر همان آموزش شبکه، از نتیجه خروجی جهت محاسبه میزان خطای شبکه استفاده میشود. برای اینکار خروجی

شبکه را با استفاده از یک تابع خطا (loss function) با پاسخ صحیح مقایسه کرده و اینطور میزان خطا محاسبه میشود. در مرحله بعدی بر اساس میزان خطای محاسبه شده مرحله backpropagation آغاز میشود. در این مرحله گرادیانت هر پارامتر با توجه به قاعده chain rule محاسبه میشود و تمامی پارامترها با توجه به تاثیری که بر خطای ایجاد شده در شبکه دارند تغییر پیدا میکنند. بعد از بروز آوری شدن پارامترها مرحله بعدی feed-forward شروع میشود. بعد از تکرار تعداد مناسبی از این مراحل آموزش شبکه پایان میابد.

انواع لایه های شبکه CNN

در حالت کلی، یک شبکه عصبی کانولوشن یک شبکه عصبی سلسله مراتبی است که لایه های کانولوشنی آن بصورت یک در میان با لایه های pooling بوده و بعد از آنها تعدادی لایه تماما متصل وجود دارد .



یک طرح کلی از معماری یک شبکه عصبی کانولوشن

لایه کانولوشن :


در این لایه ها ، شبکه CNN از kernel های مختلف برای convolve کردن تصویر ورودی و همینطور feature map های میانی استفاده میکند و اینگونه feature map های مختلفی همانند آنچه در شکل ۳ مشاهده میکنید ایجاد میکند. انجام عملیات convolution سه فایده دارد (۲۲) :

1. مکانیزم اشتراک وزن در هر feature map باعث کاهش شدید تعداد پارامترها میشود

2. اتصال محلی، ارتباط بین پیکسل های همسایه را یادمیگیرد

3. باعث تغییر ناپذیری و ثبات نسبت به تغییر مکان شیء میشود


بواسطه فواید معرفی شده توسط عملیات convolution , بعضی از مقالات تحقیقاتی مشهور از آن جهت جایگزینی لایه های تماما متصل استفاده کردند تا با این کار سرعت فرآیند یادگیری را افزایش دهند (۲۳, ۲۴). یکی از روشهای جالب مدیریت لایه های کانولوشنی، روش (۱۹) Network in Network (NIN) است که در آن ایده اصلی جایگزینی لایه کانولوشنی با یک شبکه عصبی پرسپترون کوچک است که شامل چندین لایه تماما متصل با توابع فعال سازی غیرخطی است. به این ترتیب فیلترهای خطی با شبکه های عصبی غیرخطی جایگزین میشوند. این روش باعث بدست آوردن نتایج خوبی در دسته بندی تصاویر میشود.



لایه های pooling

یک لایه pooling معمولا بعد از یک لایه کانولوشنی قرار میگیرد و از آن برای کاهش اندازه feature map ها

و پارامترهای شبکه میتوان استفاده کرد. همانند لایه های کانولوشنی، لایه های pooling بخاطر در نظر گرفتن پیکسل های همسایه در محاسبات خود، نسبت به تغییر مکان (translation) بی تغییر (با ثبات) هستند. پیاده سازی لایه Pooling با استفاده از تابع max (max pooling) و تابع Average (Average pooling) رایجترین پیاده سازی ها هستند. در شکل ۴ میتوانید نمونه ای از فرایند Max pooling را مشاهده کنید. با استفاده از فیلتر max pooling با اندازه 2×2 و stride ۲ یک feature map با اندازه 8×8 یک خروجی با اندازه 4×4 را ایجاد میکند.



عملیات max pooling

(25) Boureau et al. تحلیل نظری دقیقی از کارایی max pooling و average pooling ارائه داد. Scherer (26) et al. هم مقایسه ای بین این دو عملیات انجام داد و فهمید max pooling میتواند باعث همگرایی سریعتر، تعمیم بهتر (بهبود تعمیم دهی) و انتخاب ویژگی های نا متغیر بسیار عالی [۹] شود. طی سالهای اخیر پیاده سازی های سریع مختلفی از انواع مختلفی از CNN بر روی GPU انجام شده است که اکثر آنها از عملیات Max pooling استفاده میکنند (۲۱، ۲۷).

لایه های POOLING از میان سه لایه شبکه های کانولوشن , تنها لایه ای هستند که بیشترین میزان مطالعه روی آنها انجام شده است. سه روش معروف در رابطه با این لایه وجود دارد که هر کدام اهداف متفاوتی را دنبال میکنند.

Stochastic pooling

یک کاستی max pooling این است که نسبت به overfitting مجموعه آموزشی [۱۰] حساس بوده, و تعمیم را سخت میکند. (۲۲) با هدف حل این مشکل, Zeiler et al.(28) روش stochastic pooling را پیشنهاد داد که در آن عملیات قطعی pooling با یک رویه اتفاقی [۱۱] جایگزین میشود. این رویه اتفاقی, انتخاب تصادفی مقادیر در داخل هر ناحیه Pooling بر اساس یک توزیع چندجمله ای است. این عملیات شبیه max pooling استاندارد با تعداد زیادی کپی از تصویر ورودی که هر کدام تغییر شکل [۱۲] محلی کوچکی دارند است. طبیعت تصادفی (stochastic) بودن برای جلوگیری از مشکل Overfitting مفید بوده و به همین دلیل از آن در این روش استفاده شده است. [۱۳]

Spatial pyramid pooling (SPP)

معمولا روش های مبتنی بر شبکه های عصبی کانولوشن نیازمند یک تصویر ورودی با اندازه ثابت هستند. این محدودیت ممکن است باعث کاهش دقت تشخیص برای تصاویری با اندازه دلخواه شود. به منظور حذف این محدودیت , He et al(29) از یک معماری شبکه عصبی کانولوشن معمولی استفاده کرد با این تفاوت که لایه pooling آخر را با یک لایه spatial pyramid pooling جایگزین نمود. این لایه قادر به استخراج نماد ها (تصاویر) با اندازه ثابت از تصاویر (یا نواحی) دلخواه است. این روش باعث ایجاد یک راه حل قابل انعطاف برای مدیریت مقیاس ها, اندازه ها و aspect ratio های مختلف میشود که میتوان از آن در هر ساختار و معماری CNN استفاده کرده و کارایی آنرا افزایش داد.

Def-pooling


مدیریت و رسیدگی به تغییر شکل [۱۴] یک چالش اساسی در بینایی کامپیوتر است. خصوصا در زمینه های مربوط به تشخیص اشیاء Max pooling (object recognition) و Average pooling برای مدیریت تغییر شکل (deformation) مفید اند اما قادر به یادگیری محدودیت تغییر شکل (deformation) و مدل هندسی اجزای شی نیستند. به منظور مقابله بهتر با تغییر شکل (30) Ouyang et al. , (deformation) یک لایه pooling جدید با تغییر شکل محدود (deformation constrained pooling layer) معرفی کرد. که به

def-pooling layer معروف است. تا به این وسیله مدل عمیق (deep model) بدست آمده با یادگیری تغییر شکل الگوهای دیداری (deformation of visual patterns) غنی شود. از این لایه میتوان بجای لایه max pooling در هر سطحی از انتزاع استفاده کرد.

میتوان از ترکیب چندین نوع مختلف لایه pooling که هر کدام با هدف و شیوه متفاوتی توسعه پیدا کرده اند، کارایی یک شبکه عصبی کانولوشن را افزایش داد.

لایه تماما متصل

بعد از آخرین لایه Pooling, همانطور که در شکل ۲ مشاهده میشود, لایه های تماما متصل وجود دارند که feature map های ۲ بعدی را به feature vector یک بعدی جهت ادامه فرآیند feature representation تبدیل میکند.



عملیات لایه های تماما متصل که بعد از آخرین لایه Pooling قرار گرفته اند

لایه های تماما متصل همانند همتایان خود در شبکه های عصبی مصنوعی سنتی عمل میکنند و تقریباً ۹۰٪ پارامترهای یک شبکه CNN را شامل میشوند. لایه تماما متصل بما اجازه میدهد تا نتیجه شبکه را در قالب یک بردار با اندازه مشخص ارائه کنیم. ما میتوانیم از این بردار برای دسته بندی تصاویر (۲۱) استفاده کنیم و یا اینکه از آن جهت ادامه پردازش های بعدی بهره ببریم (۳۱).

تغییر ساختار لایه های تماماً متصل رایج نیست، اما یک نمونه در روش (32) Transferred learning انجام شد که در آن پارامترهای فراگرفته شده توسط ImageNet (21) حفظ شده اما لایه تماماً متصل آخر با دو لایه تماماً متصل جایگزین شد تا شبکه با اینکار بتواند با فعالیتهای تشخیص بینایی جدید انطباق پیدا کند.

مشکل بزرگ این نوع لایه ها این است که دارای تعداد بسیار زیادی پارامتر اند. که نتیجه این امر هزینه پردازشی بسیار بالایی است که در زمان آموزش بایستی صرف شود. بنابر این یک روش که معمولاً بکاربرده میشود و نتایج رضایت بخشی نیز دارد این است که یا کلاً این لایه ها حذف شوند و یا تعداد اتصالات در این لایه ها توسط روشهایی کاهش یابد. بعنوان مثال (23) GoogLeNet یک شبکه عمیق و گسترده را طراحی کرد که در آن هزینه محاسباتی ثابت نگه داشته شده است. این کار با تعویض معماری تماماً متصل با معماری بطور پراکنده متصل صورت گرفت.

استراتژی آموزش (Training strategy)


در قیاس با shallow learning، فایده یادگیری عمیق این است که میتوان معماری های عمیق (deep architecture) را جهت یادگیری اطلاعات انتزاعی تر ایجاد کرد. اما تعداد بسیار زیاد پارامترهای معرفی شده، ممکن است سبب مشکل overfitting شود. اخیراً روش های regularization زیادی در مقابله با Overfitting ارائه شده است مثل روش stochastic pooling که در قبل به آن اشاره کردیم. در این بخش ما چند تکنیک و روش regularization را که سبب بهبود کارایی شبکه میشود را معرفی میکنیم. دقت کنید که الزاماً تمامی تکنیک های معرفی شده در این بخش، خاص شبکه های عصبی کانولوشن نیستند. یعنی این تکنیک ها قابل اعمال در شبکه های عصبی مصنوعی سنتی هم هستند (مثل شیوه dropout)

Dropout و DropConnect

تکنیک Dropout توسط (33) Hinton et al. ارائه شد و توسط (34) Baldi et al. هم بصورت کامل توضیح داده شد. روش dropout به منظور جلوگیری از overfitting معرفی شد. و نحوه کار آن به این صورت است که در هر مرحله از آموزش، هر نورون یا با احتمال $p-1$ (از شبکه) بیرون انداخته شده (dropped out) و یا با احتمال p نگه داشته میشود، بطوریکه نهایتاً یک شبکه کاهش داده شده باقی بماند. یالهای ورودی و خروجی به یک نود بیرون انداخته شده (dropped-out node) نیز حذف میشوند. اینگونه تنها شبکه کاهش یافته بر روی داده ها در آن مرحله آموزش خواهد دید. (بعد از این کار) نودهای حذف شده سپس به همراه

وزنهای سابق آنها(قبل از حذف شدن) دوباره به درون شبکه وارد میشوند. این تکنیک بعداً در (۳۵-۴۰) بهبود پیدا کرد. (38) Warde-Farley et al. در تحقیقات خود بهینگی dropout ها را مورد تحلیل قرار داد و نهایتاً عنوان کرد که dropout یک شیوه یادگیری گروهی بسیار موثر است.

یک نمونه معروف مشتق شده از Dropout به (۴۱) DropConnect معروف است که بصورت تصادفی وزنهای بجای مقادیر فعالسازی حذف میکند. آزمایشات نشان دادند که این روش میتواند پایاپای و حتی بهتر از روش Dropout در انواع گوناگونی از Benchmark های استاندارد عمل کند. هرچند با سرعت کمتر. شکل ۶ مقایسه ای از یک معماری بدون حذف Dropout , DropConnect و No Drop را نشان میدهد



مقایسه ای بین شبکه های Dropout , No-Drop و DropConnect.

Data augmentation

معمولاً زمانی که از یک CNN برای تشخیص شیء (object recognition) استفاده میشود، از data augmentation برای تولید داده های اضافی بدون تحمیل هزینه برچسب گذاری بیشتر استفاده میکنند. شبکه AlexNet(21) از دو شکل مشخص [data augmentation](#) استفاده کرد. اولین شکل data augmentation شامل ایجاد image translation و انعکاس های افقی (horizontal reflections) بود، و دومین شکل شامل تغییر شدت نور در [کانالهای RGB تصاویر](#) بود. (42) Howard et al. با انتخاب AlexNet(21) به عنوان مدل پایه خود و بعد با اضافه کردن تبدیلات (transformations) اضافی که توسعه image crops با پیکسلهای اضافی و افزودن تغییرات رنگی بیشتر (color manipulations) بود، باعث بهبود translation invariance و Color Invariance شد. این شیوه data augmentation بصورت گسترده توسط تعدادی از تحقیقات اخیر مورد استفاده قرار گرفته است.. (۲۳، ۲۹) (43) Dosovitskiy et al. یک شیوه

یادگیری ویژگی بدون سرپرست (unsupervised feature learning) مبتنی بر data augmentation ارائه داد که در آن شیوه کار به اینصورت است. این روش ابتدا بصورت تصادفی تعدادی image patch را انتخاب کرده و آنها را بعنوان یک کلاس جانشین در نظر میگیرد، سپس این کلاسها را با اعمال تبدیلات مربوط به translation, scale, رنگ و contrast گسترش (بسط) داده و نهایتاً یک شبکه CNN را جهت تشخیص و تمایز بین این کلاسهای جانشین (surrogate classes) آموزش میدهد. ویژگی های فراگرفته شده توسط این شبکه نتایج خوبی را در زمینه های مختلف دسته بندی نشان میدهد. (44) Wu et al. علاوه بر روش های کلاسیک همانند scaling, rotating و cropping از color casting, تکنیک های [lens distortion](#) و vignetting نیز بهره برد که همین امر باعث ایجاد نمونه های آموزشی بیشتر با پوشش گسترده تری شد.

2-2-2. استخراج ویژگی عمیق برای CBIR

در روش های مبتنی بر CNN:

1. تصویر به یک شبکه^۱ پیش تمرین شده داده می شود.
 2. خروجی یکی از لایه های میانی (معمولاً آخرین لایه^۲ قبل از طبقه بندی) به عنوان بردار ویژگی (Image Embedding) استخراج می شود.
 3. شباهت میان تصاویر با معیارهایی مانند Cosine Similarity یا Euclidean Distance محاسبه می شود.
- این روش باعث ایجاد نمایش های غنی و مقاوم در برابر تغییرات می شود.

2-2-3. محدودیت های روش های مبتنی بر CNN

با وجود قدرت بالا، CNN ها هنوز:

- قادر به ترکیب قیدهای مفهومی پیچیده (مثلاً «همین صحنه اما در شب») نیستند.
- فاقد درک عمیق زبان طبیعی هستند.
- در پردازش روابط تصویر-متن محدودند.

این نقاط ضعف باعث شد پژوهش ها به سمت مدل های ترنسفورمر (Transformer) و سپس مدل های چندوجهی (Multimodal) حرکت کنند.

3-2. مدل های ترنسفورمر (Transformer) در بینایی کامپیوتر

معماری Transformer نخستین بار در پردازش زبان معرفی شد، اما با موفقیت Vision Transformer (ViT)، وارد حوزه بینایی کامپیوتر نیز شد.

5-2- بازیابی تصویر ترکیبی¹

یکی از مفاهیم کلیدی در این حوزه، بازیابی تصویر ترکیبی است؛ روشی که در آن پرس و جو نه صرفاً یک متن یا تصویر، بلکه ترکیبی از هر دو است. در این چارچوب، کاربر یک تصویر مرجع² را ارائه کرده و از طریق یک توصیف متنی نسبی³ تغییرات مدنظر خود را مشخص می کند؛ برای مثال، تغییراتی در ظاهر، رنگ، زاویه یا ویژگی های مفهومی تصویر را بیان می نماید [10]. هدف در CIR، بازیابی تصویری است که نسبت به تصویر مرجع، دقیقاً همان تغییرات بیان شده در متن را دارا باشد.

کار CIR تلاش می کند با استفاده از یک پرس و جوی مرکب از تصویر و متن، تصویر هدف را بازیابی کند. این روش در مقایسه با بازیابی صرفاً مبتنی بر تصویر، دقت بالاتری دارد؛ زیرا متن امکان بیان قصد کاربر را فراهم می کند [8].

اهمیت این مسئله در کاربردهایی همچون تجارت الکترونیک، سیستم های جستجوی محتوای چندرسانه ای و حوزه ی پزشکی کاملاً مشهود است، زیرا کاربران اغلب نیازمند بیان تغییرات هدفمند و جزئی بر مبنای یک نمونه تصویری هستند. با این حال، بیشتر روش های کلاسیک CIR برای آموزش نیازمند سه تایی های برچسب خورده⁴ شامل تصویر پرس و جو، متن تغییر و تصویر هدف هستند؛ داده هایی که تولیدشان بسیار پرهزینه و زمان بر است و همین امر به عنوان یکی از موانع اصلی توسعه ی گسترده ی روش های CIR مطرح شده است [8, 22].

¹ Composed Image Retrieval – CIR

² Reference Image

³ Relative Caption / Modification Text

⁴ Labeled Triplets

6-2- ترنسفورمرها در بازیابی تصویر

معرفی ترنسفورمرها . ViT [6] در بازیابی تصویر نشان داد که معماری های مبتنی بر ترنسفورمر قادرند بدون پیچیدگی های کانولوشن، با تقسیم تصویر به پچ ها¹ و به کارگیری مکانیزم توجه²، وابستگی های بلندمدت را مدل سازی کنند. این تغییر ساختاری منجر به بهبود قابل ملاحظه در فهم الگوهای پیچیده تصویری و ارتقای بهره وری در بازیابی تصویر شد.

7-2- معماری های چندوجهی مدرن³

در سال های اخیر، توسعه ی معماری هایی که توانایی پردازش و تحلیل هم زمان اطلاعات تصویری و زبانی طبیعی را دارند، توجه گسترده ای در حوزه ی یادگیری چندوجهی⁴ به خود جلب کرده است. این معماری ها با هدف ایجاد یک فضای نمایش مشترک⁵ میان داده های چندرسانه ای طراحی می شوند؛ فضایی که در آن ویژگی های استخراج شده از مدال های مختلف، نظیر تصویر و متن، به صورت بردارهای قابل مقایسه نمایش داده می شوند. چنین چارچوبی امکان مقایسه و بازیابی میان وجهی⁶ را فراهم کرده و در عین حال زمینه ی تعامل عمیق و معنایی میان مدال ها را مهیا می سازد، به گونه ای که مدل قادر است روابط مفهومی پیچیده میان اطلاعات بصری و زبانی را بهتر درک و مدل سازی کند [1].

پایه نظری مهم دیگر، مدل های چندوجهی⁷ هستند که توانایی پردازش و ادغام داده ها از حوزه های مختلف (مانند متن و تصویر) را دارا می باشند. این مدل ها با استفاده از فضای نهفته مشترک⁸، امکان مقایسه و بازیابی میان وجهی⁹ را فراهم می کنند [1]. مدل های شاخصی همچون CLIP¹⁰ نشان دادند که آموزش همزمان تصویر و متن می تواند به ایجاد نمایش های معنایی قدرتمند منجر شود.

¹ Patches

² self-attention

³ Modern Multimodal Architectures

⁴ (Multimodal Learning

⁵ joint embedding space

⁶ Cross-modal Retrieval

⁷ Multimodal Models

⁸ Joint Embedding Space

⁹ Cross-modal Retrieval

¹⁰ Contrastive Language-Image Pre-training

در نهایت، مبانی نظری این حوزه بر سه اصل کلیدی استوار است:

- نمایش مؤثر داده ها¹ که هدف آن استخراج ویژگی های معنایی غنی از تصاویر و متون است.
- یادگیری فضای نهفته مشترک² که داده های چندوجهی را در یک فضای برداری قابل مقایسه نگاشت می کند.
- معیارهای شباهت و ارزیابی³ که میزان نزدیکی پرسوجو و نتایج بازیابی شده را تعیین می کنند [23].

این مفاهیم و اصول نظری زیربنای توسعه روش های نوین بازیابی تصویر ترکیبی محسوب می شوند و بستری برای مرور تحقیقات پیشین و شناسایی خلأهای پژوهشی فراهم می کنند. معماری های چندوجهی مدرن شامل اجزای اصلی زیر می شوند:

1. **کدگذارهای مجزا⁴**: برای هر مدال، مانند یک شبکه عصبی کانولوشنی یا ویژن ترانسفورمر (ViT) برای تصاویر و یک مدل ترانسفورمر مبتنی بر زبان (مانند BERT) برای متن.
2. **ماژول های همترازی⁵**: این بخش ها وظیفه همسان سازی ویژگی های استخراج شده از مدال های مختلف را به عهده دارند تا بتوانند در فضای برداری یکسان قرار گیرند.
3. **مکانیسم های توجه⁶**: که در معماری های مدرن برای مدل سازی ارتباطات پیچیده بین بخش های مختلف تصویر و بخش های متن استفاده می شوند.
4. **آموزش چندوظیفه ای⁷**: معماری های ترکیبی معمولاً به گونه ای آموزش داده می شوند که بتوانند چند وظیفه از قبیل بازیابی تصویر، تولید توضیح متنی، طبقه بندی و سوال و پاسخ تصویری را به صورت همزمان انجام دهند.

نمونه های مطرح این معماری ها شامل CLIP، BLIP، FLAVA و Qwen-VL هستند که همگی عملکرد قابل توجهی در درک و بازیابی چندوجهی ارائه داده اند [Multimodal Fusion and Vision-Language Models.pdf]. Vision-Language Models for Vision Tasks.pdf

¹ Feature Representation

² Joint Embedding Learning

³ Similarity Measures & Evaluation Metrics

⁴ Encoders

⁵ Alignment Modules

⁶ Attention Mechanisms

⁷ Multitask Learning

مطالعات مرور اخیر نشان می دهد که CBIR از استفاده ی صرف ویژگی های دیداری سطح پایین، به استفاده از نمایش های عمیق یادگرفته شده (Learned Deep Representations) و سپس به ترکیب اطلاعات متنی و تصویری حرکت کرده است. در این مسیر، ظهور مدل های بینایی-زبان مانند CLIP و BLIP نقطه ی عطفی محسوب می شود؛ زیرا این مدل ها امکان تعریف پرس و جوهای متنی غنی، بازیابی صفر-نمونه و بازیابی تصویر ترکیبی را فراهم کرده اند. این روند در بخش های مرتبط با «Deep Learning-based CBIR» و «Multimodal Image Retrieval» در مرورهای CBIR به طور مستند بیان شده است (Content-based image retrieval: A review of recent trends,).

8-2- مدل های Zero-shot و Few-shot در بازیابی ترکیبی

یکی از چالش های مهم در حوزه بازیابی ترکیبی تصویر و متن، کمبود داده های برچسب گذاری شده گسترده و متنوع است. مدل های Zero-shot و Few-shot به عنوان راه حل های نوین این مشکل مطرح شده اند که توانایی تعمیم به وظایف جدید یا داده های ناشناخته را بدون نیاز به آموزش مجدد گسترده دارند. در Zero-shot، مدل قادر است بدون دریافت نمونه آموزشی مستقیم برای یک کلاس یا وظیفه خاص، عملکرد قابل قبولی داشته باشند. به بیان دیگر، مدل ها بر اساس دانش کسب شده از داده های قبلی و توانایی درک معنایی، می توانند بر روی داده های کاملاً جدید (که در آموزش مشاهده نکرده اند) پیش بینی انجام دهند. مدل CLIP نمونه بارز مدل های zero-shot است که به واسطه آموزش کانتراستیفیکیشن بر روی مجموعه داده های عظیم (بر ۴۰۰ میلیون جفت تصویر-متن)، توانایی استخراج ویژگی های متن و تصویر در فضای مشترک را پیدا کرده و بدون آموزش اضافی برای وظایف بازیابی، عملکرد مطلوبی ارائه می دهد [1]. در مدل های Few-shot، نیاز به تعداد کمی نمونه آموزشی برای تطبیق یا یادگیری یک وظیفه جدید دارند. با استفاده از تکنیک هایی مانند fine-tuning محدود یا meta-learning، مدل می تواند با چند نمونه محدود، درک بهتری از ویژگی های مرتبط با وظیفه جدید پیدا کند. این مدل ها برای کاربردهایی که داده های برچسب دار کمیاب یا گران قیمت هستند بسیار مفیدند.

در بازیابی ترکیبی تصویر و متن، مدل های zero-shot و few-shot نقش مهمی در کاهش نیاز به داده های حجیم و هزینه های برچسب گذاری ایفا می کنند و باعث افزایش کارایی و کاربردپذیری سیستم های بازیابی در شرایط واقعی می شوند. همچنین، مدل های جدیدی مانند Textual Inversion و Zero-shot Composed Image Retrieval نیز از این ایده ها برای رفع مشکل کمبود داده های سه تایی بهره برده اند تا

بازیابی ترکیبی را به سطحی بالاتر ارتقاء دهند [10].

9-2- مدل های زبانی-تصویری¹

مطالعات نشان می دهد که بازیابی تصویر مبتنی بر محتوا از ویژگی های دیداری سطح پایین به استفاده از نمایش های معنایی مشترک تصویر-زبان تغییر کرده است. نقطه عطف این تغییر ظهور مدل های نظیر CLIP و BLIP بود که با یادگیری مشترک بر داده های بزرگ وب، قابلیت های Zero-Shot و Composed Retrieval را فراهم کردند [18].

1-9-2- مدل CLIP²

مدل CLIP از سوی شرکت OpenAI معرفی شد و نقطه عطفی در زمینه یادگیری نمایشی مشترک³ برای تصاویر و متن محسوب می شود. این مدل با استفاده از داده های بزرگ مقیاس شامل میلیون ها جفت های تصویر و متن، بر پایه هدف تضعیفی⁴ آموزش می بیند تا بتواند ویژگی های دو مدال⁵ را در فضای برداری یکسان⁶ نگاشت کند [1].

در ساختار CLIP، دو شبکه عصبی جداگانه تحت عنوان رمزگذار تصویر⁷ و رمزگذار متن⁸ وجود دارند که هر یک وظیفه تبدیل ورودی مربوط به خود به بردار ویژگی نهفته را بر عهده دارند. هدف نهایی آن است که جفت های مرتبط تصویری-متنی بیشترین شباهت و جفت های نامرتبط کمترین شباهت را داشته باشند، به گونه ای که مدل بیاموزد روابط معنایی میان متن و تصویر را بدون نظارت مستقیم نمایش دهد. برای این منظور از معیار شباهت کسینوسی⁹ میان بردارهای دو رمزگذار استفاده می شود و مدل در هر بچ¹⁰ موظف

¹ Vision-Language Models – VLMs

² Contrastive Language-Image Pre-training

³ representation learning

⁴ Contrastive Objective

⁵ Modalities

⁶ Shared Embedding Space

⁷ Image Encoder

⁸ Text Encoder

⁹ Cosine Similarity

¹⁰ Batch

است متن صحیح را برای هر تصویر و بالعکس شناسایی کند [1].

در این چارچوب، یکی از نوآوری های بنیادین CLIP جایگزینی برچسب های محدود دستی با نظارت زبان طبیعی¹ است، به این معنا که هر تصویر با یک متن توصیفی مرتبط است و سیستم با یادگیری از این جفت ها، نمایش هایی از تصویر ایجاد می کند که قابل انتقال و قابل تعمیم به وظایف جدید هستند. بر اساس مقاله ی اصلی، نویسندگان مجموعه داده ای عظیم شامل حدود ۴۰۰ میلیون جفت تصویر-متن را گردآوری کردند و نشان دادند که آموزش مدل با این داده ها موجب یادگیری نمایش های بصری بسیار انتقال پذیر² می شود [1].

از دیدگاه معماری، رمزگذار تصویر در CLIP می تواند از خانواده ResNet یا Vision Transformer (ViT) باشد و رمزگذار متن نیز اغلب گونه ای از ترنسفورمر زبانی³ است. ترکیب این دو رمزگذار در کنار هدف تضعیفی یادگیری را به صورت هم زمان بین دو مدال هماهنگ می سازد و سبب می شود تصاویر و متون در یک فضا قابل مقایسه شوند. این طراحی دو مزیت اصلی را ایجاد می کند:

1. **کارایی بالا در یادگیری نمایش های قابل انتقال:** CLIP قادر است بدون تنظیم مجدد⁴، در حالت

صفر نمونه⁵ روی طیف وسیعی از وظایف مانند OCR، مکان یابی جغرافیایی⁶، تشخیص عمل⁷ و ... عملکرد مطلوبی داشته باشد [4].

2. **بازدهی محاسباتی و مقیاس پذیری بالا:** تغییر هدف از پیش بینی کلاس به هدف تضعیفی، نسبت

عملکرد به هزینه محاسباتی را تا چهار برابر افزایش داده است؛ بدین ترتیب، CLIP در عین کارایی، عملکردی هم تراز یا حتی بهتر از بهترین مدل های مبتنی بر ImageNet در زمان انتشار خود دارد [4].

این ویژگی ها موجب شده اند که CLIP پایه و مبنای بسیاری از مدل های بعدی در حوزه بازیابی تصویر و متن و به ویژه بازیابی تصویر ترکیبی⁸ باشد. یکی از قابلیت های برجسته CLIP در مرحله آزمون آن است که

¹ Natural Language Supervision

² Transferable Visual Representations

³ Text Transformer

⁴ Fine-Tuning

⁵ Zero-Shot

⁶ Geo-Localization

⁷ Action Recognition

⁸ Composed Image Retrieval - CIR

رمزگذار متن می تواند با جاسازی¹ نام کلاس ها یا توضیحات متنی، یک طبقه بند صفر-نمونه² را به صورت مستقیم سنتز کند [1]. همین قابلیت سبب می شود مدل برای وظایف بازیابی چندوجهی بسیار مناسب باشد، زیرا فضای نهفته مشترک بین تصویر و زبان امکان تعریف پرس وجوهایمانند «این تصویر + این تغییر متنی» را فراهم می آورد.

به همین دلیل، بسیاری از روش های بازیابی تصویر ترکیبی صفر نمونه³ مستقیماً بر پایه معماری یا ایده فضای مشترک CLIP طراحی شده اند. برای مثال، روش SEARLE از فضای توکن های CLIP برای تعریف یک شبه کلمه⁴ استفاده می کند تا بتواند تغییرات مفهومی را در فضای نهفته مدل کند [10].

در مجموع، مدل CLIP را می توان نقطه آغاز نسل جدیدی از مدل های زبانی-تصویری⁵ دانست که بستر اصلی پیشرفت در بازیابی میان وجهی، یادگیری بدون نظارت صریح، و وظایف صفر نمونه محسوب می شوند. این مدل نه تنها از نظر فنی کامیاب بوده بلکه پایه ای نظری برای ارتباط معنا در بین مدال ها ایجاد کرده است و از همین رو، یکی از ارکان کلیدی تحول از CBIR کلاسیک به CIR مبتنی بر نمایش های چندوجهی به شمار می آید.

2-9-2- مدل ALIGN⁶

مدل ALIGN یکی از مدل های پیش آموزش دیداری-زبانی⁷ در مقیاس بسیار بزرگ است که توسط گوگل معرفی شده و از نظر ایده ی کلی به مدل CLIP شباهت دارد؛ یعنی از یک معماری دو رمزگذار⁸ برای نگاشت همزمان تصویر و متن به یک فضای نمایش مشترک⁹ و یک هدف هم تراز¹⁰ بر روی جفت های تصویر-متن بهره می برد [24].

ALIGN از نظر مقیاس داده، یک مرتبه ی بزرگی بالاتر از CLIP (با ۴۰۰ میلیون جفت) و FILIP (با ۳۰۰

¹ Embedding

² Zero-Shot Classifier

³ Zero-Shot CIR – ZS-CIR

⁴ Pseudo Word

⁵ Vision-Language Models – VLMs

⁶ Align before fuse

⁷ vision-language pre-training

⁸ dual-encoder

⁹ shared embedding space

¹⁰ alignment objective

میلیون جفت) عمل می کند و به طور خاص بر مقیاس پذیری¹ و استفاده ی کارآمد از داده های وب مقیاس و نسبتاً نویزی تمرکز دارد.

در سطح معماری، ALIGN مشابه CLIP از دو شاخه ی مستقل برای پردازش تصویر و متن بهره می برد: یک رمزگذار دیداری² مبتنی بر شبکه ی کانولوشن عمیق یا ترنسفورمر تصویر و یک رمزگذار متنی³ مبتنی بر ترنسفورمر زبانی. خروجی هر دو رمزگذار، پس از عبور از سرهای تصویر-متن (projection heads)، به یک فضای برداری مشترک نگاشته می شود که در آن، تصویر و متن های مرتبط به یکدیگر نزدیک، و نمونه های نامرتب دور قرار می گیرند.[4]

نوآوری کلیدی ALIGN، همان طور که از عنوان مقاله نیز برمی آید، بر اصل «هم تراز کن، سپس ادغام کن»⁴ استوار است. ایده این است که قبل از هر نوع ادغام عمیق⁵ بین ویژگی های دیداری و متنی – مثلاً برای وظایفی مانند پاسخ به پرسش تصویری⁶ یا استدلال چندوجهی – ابتدا باید یک نمایش هم تراز شده ی قوی و عمومی از تصویر و متن در سطح جهانی یاد گرفته شود. برای این منظور، ALIGN تمرکز اصلی را روی یادگیری نمایش های هم تراز شده ی دووجهی⁷ با استفاده از جفت های تصویر-متن وب مقیاس قرار می دهد و فرآیند ادغام عمیق را به مرحله های بعدی و مدل های پایین دستی موکول می کند. این دیدگاه با دسته بندی ارائه شده در مرور مدل های دیداری-زبانی نیز سازگار است، جایی که ALIGN در کنار CLIP ذیل مدل های مبتنی بر اهداف هم تراز در فضای تعبیه مشترک قرار می گیرد[24].

در ALIGN، مشابه CLIP، هدف اصلی یادگیری یک تابع امتیازدهی سازگاری⁸ بین تصویر و متن است که بر روی فضای تعبیه⁹ تعریف شده و با یک هدف کانتراستیو آموزش¹⁰ داده می شود؛ یعنی در هر مینی-بچ، امتیاز تصویر با متن صحیح خودش نسبت به همه ی متون دیگر در آن مینی-بچ بیشینه، و امتیاز متن با تصویر صحیح خودش نسبت به سایر تصاویر کمینه می شود. این فرمول بندی باعث می شود که مدل بتواند

¹ scalability

² vision encoder

³ text encoder

⁴ align before fuse

⁵ deep fusion

⁶ VQA

⁷ cross-modal aligned representations

⁸ compatibility function

⁹ embedding space

¹⁰ contrastive learning

بدون نیاز به برچسب های ریزدانه¹، تنها با اتکا به جفت های طبیعی تصویر-متن، بازنمایی های معنایی قدرتمندی یاد بگیرد.[4]

ویژگی مهم دیگر ALIGN استفاده از تقطیر مومنتومی² است. در این چارچوب، یک مدل معلم³ که به صورت مومنتومی از روی وزن های مدل دانش آموز⁴ به روزرسانی می شود، برای تولید سیگنال آموزشی پایدارتر و کمتر نویزی استفاده می گردد. به بیان ساده، به جای آن که مدل صرفاً از برچسب های سخت⁵ ناشی از تطبیق تصویر-متن استفاده کند، از نرم برچسب ها⁶ و نمایش های معلم بهره می برد تا اثر نویز موجود در جفت های وب مقیاس کاهش یابد. این سازوکار به ALIGN اجازه می دهد که با وجود کیفیت ناهمگون و گاه نامطمئن توصیف های متنی وب، همچنان نمایش های پایدار و قابل انتقال⁷ برای هر دو modality یاد بگیرد.

در عمل، تقطیر مومنتومی با نگه داشتن یک کپی مومنتومی از پارامترهای مدل دانش آموز و به روزرسانی تدریجی آن پیاده سازی می شود؛ بدین ترتیب، مدل معلم به عنوان یک «میانگین زمانی» از مدل در طول آموزش عمل می کند و پیش بینی های آن نسبت به نوسانات کوتاه مدت گرادیان ها مقاوم تر است. این رویکرد، هم راستا با دسته ای اهداف هم ترازی اشاره شده در مرور مدل های دیداری-زبانی است که در آن ها، هم تراز سازی تصویر-متن روی فضای تعبیه مشترک صورت می گیرد[24].

داده های مورد استفاده، مانند بسیاری از مدل های وب مقیاس، به طور کامل پاک سازی نشده و حاوی نویز معنایی و زبانی هستند؛ برای مثال، ممکن است متن همراه تصویر، توصیف دقیقی از محتوای آن نباشد یا حاوی اطلاعات جانبی باشد. ترکیب هدف کانتراستیو هم تراز با تقطیر مومنتومی در ALIGN کمک می کند که اثر این نویز کاهش یابد و مدل بتواند از حجم عظیم داده، الگوهای معنایی پایدار استخراج کند. نتایج گزارش شده در مقاله اصلی نشان می دهد که افزایش مقیاس داده، همراه با این طرح آموزشی، منجر به بهبود محسوس عملکرد در وظایف بازیابی تصویر-متن⁸ و سایر وظایف پایین دستی می شود؛ این موضوع با ادبیات کلی مرورهای VLM نیز همخوان است که در آن ها رشد مقیاس داده و مدل، یکی از عوامل اصلی

¹ fine-grained labels

² momentum distillation

³ teacher

⁴ student

⁵ hard labels

⁶ soft targets

⁷ transferable representations

⁸ image-text retrieval

جهش عملکرد در وظایف چندوجهی معرفی می شود [24].

با توجه به ماهیت دو رمزگذاری و هدف هم ترازی در ALIGN، خروجی این مدل یک فضای نمایش مشترک است که در آن می توان بازیابی تصویر مبتنی بر متن¹ و بازیابی متن مبتنی بر تصویر² را به صورت zero-shot و بدون آموزش مجدد روی دیتاست هدف انجام داد؛ همان الگوی کلی که برای CLIP نیز در ادبیات CIR و ZS-CIR به عنوان یک مبنا³ استفاده می شود [1] برای CLIP؛ و در مرورهای CIR، استفاده از مدل های پیش آموزش دووجهی برای بازیابی ترکیبی تصویر مورد تأکید قرار گرفته است [25].

در زمینه ی بازیابی تصویر ترکیبی⁴، که در آن یک تصویر ورودی به همراه یک اصلاح متنی⁵ یا یک جمله ی ترکیبی⁶ به مدل داده می شود، وجود یک فضای تعبیه ی قدرتمند، هم تراز و مقیاس پذیر مانند فضای ALIGN، این امکان را فراهم می کند که روش های پایین دستی مختلف بر روی این نمایش ها بنا شوند و بتوانند بدون نیاز به برچسب گذاری گسترده ی سه تایی (image + modification + target) از مزیت اطلاعات وب مقیاس بهره ببرند

([Effective Conditioned and Composed Image Retrieval Combining CLIP-Based Features, CVPR 2022, p.1–3] برای نقش مدل های CLIP-محور در CIR).

3-9-2- مدل BLIP⁷

مدل BLIP یک چارچوب پیش آموزش دیداری-زبانی⁸ است که با هدف یکپارچه سازی وظایف فهم⁹ و تولید¹⁰ در مدل های دیداری-زبانی طراحی شده است در این چارچوب، معماری جدیدی با عنوان آمیخته چندوجهی رمزگذار-رمزگشا¹¹ معرفی می شود. این معماری به گونه ای طراحی شده است که می تواند در

¹ text-to-image retrieval

² image-to-text retrieval

³ backbone

⁴ composed image retrieval – CIR

⁵ textual modification

⁶ composed query

⁷ Bootstrapping Language-Image Pre-Training

⁸ vision-language pre-training

⁹ understanding

¹⁰ generation

¹¹ Multimodal Mixture of Encoder-Decoder – MED

نقش های متفاوتی عمل کند؛ از جمله رمزگذار تک وجهی¹، رمزگذار متن وابسته به تصویر² و رمزگشای متن وابسته به تصویر³. به همین دلیل، MED یک ساختار انعطاف پذیر برای پیش آموزش چندوظیفه ای⁴ و انتقال پذیری⁵ فراهم می کند [3].

پیش آموزش دیداری-زبانی⁶ طی سال های اخیر موجب بهبود قابل توجه عملکرد در بسیاری از وظایف بینایی-زبانی شده است. با این حال، اغلب مدل های موجود تنها در یکی از دو دسته ی وظایف مبتنی بر درک⁷ یا مبتنی بر تولید⁸ عملکرد مطلوبی دارند و در پوشش هم زمان هر دو نوع وظیفه با محدودیت مواجه هستند. علاوه بر این، بخش قابل توجهی از پیشرفت های گزارش شده در این حوزه از طریق افزایش مقیاس داده های آموزشی حاصل شده است؛ داده هایی که عمدتاً شامل جفت های تصویر-متن نویزی استخراج شده از وب⁹ هستند. این داده ها معمولاً دارای نویز، ناهماهنگی معنایی و نبود برچسب های دقیق هستند و در نتیجه به عنوان منبعی زیربهبینه برای نظارت آموزش¹⁰ در نظر گرفته می شوند [3].

از منظر معماری نیز بسیاری روش های موجود در مدل های چندوجهی بر یکی از دو رویکرد اصلی تکیه دارند: مدل های مبتنی بر رمزگذار¹¹ یا مدل های رمزگذار-رمزگشا¹².

در مدل های مبتنی بر رمزگذار، هدف اصلی یادگیری بازنمایی های مشترک از تصویر و متن برای وظایفی مانند بازیابی تصویر-متن¹³ یا تطبیق تصویر و متن¹⁴ است؛ اما، این مدل ها معمولاً برای تولید متن، مانند توصیف تصویر¹⁵، مناسب نیستند. در مقابل، معماری های رمزگذار-رمزگشا که برای تولید توالی های متنی طراحی شده اند، در وظایف مبتنی بر بازیابی تصویر-متن عملکرد قابل توجهی نداشته اند. بنابراین هر یک از این دو نوع معماری تنها بخشی از نیازهای سیستم های چندوجهی را پوشش می دهند و در پوشش کامل

¹ Unimodal Encoder

² Image-Grounded Text Encoder

³ Image-Grounded Text Decoder

⁴ Multi-Task Pre-training

⁵ Transfer Learning

⁶ Vision-Language Pre-training -VLP

⁷ understanding-based

⁸ generation-based

⁹ Noisy Web Image-Text Pairs

¹⁰ Suboptimal Supervision

¹¹ Encoder-Based Models

¹² Encoder-Decoder Models

¹³ Image-Text Retrieval

¹⁴ Image-Text Matching

¹⁵ Image Captioning

طیف وظایف تولید را در یک چارچوب واحد ترکیب کند [3].

برای پیش آموزش این معماری، BLIP از سه هدف آموزشی استفاده می کند که به صورت آموزش مشترک¹ بهینه سازی می شوند. نخست، یادگیری کانتراستیو تصویر-متن² است که در آن مدل می آموزد بازنمایی های تصاویر و متون مرتبط در فضای تعبیه³ به یکدیگر نزدیک و از نمونه های نامرتبط دور باشند؛ این هدف نقشی اساسی در وظایف بازیابی تصویر-متن دارد. هدف دوم تطبیق تصویر-متن⁴ است که به صورت یک مسئله طبقه بندی دودویی⁵ تعریف می شود و مدل باید تشخیص دهد آیا یک جفت تصویر-متن با یکدیگر سازگار هستند یا خیر. هدف سوم مدل سازی زبانی شرطی بر تصویر⁶ است که در آن مدل در نقش یک رمزگشای متنی وابسته به تصویر عمل کرده و با توجه به محتوای تصویر، توالی کلمات را تولید می کند؛ این سازوکار اساس وظیفه تولید توضیح تصویر⁷ را تشکیل می دهد. ترکیب این سه هدف آموزشی باعث می شود BLIP بتواند به طور همزمان قابلیت های لازم برای فهم چندوجهی و تولید متن را در یک مدل واحد ارائه دهد [3]. علاوه بر نوآوری معماری، BLIP در حوزه داده نیز رویکردی جدید ارائه می دهد. این مدل از مکانیزمی با عنوان Captioning and Filtering (CapFilt) برای بهره گیری مؤثر از داده های نویزی وب مقیاس⁸ استفاده می کند. در این روش، یک مدل MED از پیش آموزش دیده به دو ماژول مجزا Captioner و Filter ریزتنظیم می شود. ماژول Captioner برای تصاویر وب کپشن های مصنوعی⁹ تولید می کند، در حالی که ماژول Filter وظیفه حذف کپشن های نویزی را از هر دو منبع، یعنی متن های اصلی وب و کپشن های مصنوعی تولید شده، بر عهده دارد. این فرآیند به نوعی بوت استرپینگ داده¹⁰ محسوب می شود که در آن مدل اولیه برای بازسازی و پالایش داده های آموزشی مورد استفاده قرار می گیرد. نتایج مقاله نشان می دهد که همکاری این دو ماژول به بهبود قابل توجه عملکرد منجر شده و تنوع بیشتر در کپشن های تولیدی نیز می تواند کیفیت یادگیری مدل را افزایش دهد [3].

ترکیب معماری MED و مکانیزم CapFilt باعث شده است که BLIP در طیف گسترده ای از وظایف

¹ Joint Training

² Image-Text Contrastive Learning

³ Embedding Space

⁴ Image-Text Matching

⁵ Binary Classification

⁶ Image-Conditioned Language Modeling

⁷ Image Captioning

⁸ Noisy Web-Scale Data

⁹ Synthetic Captions

¹⁰ Dataset Bootstrapping

دیداری-زبانی به نتایج پیشرفته (State-of-the-Art) دست یابد. به طور مشخص، این مدل در وظیفه بازیابی تصویر-متن بهبود حدود ۲/۷٪ در معیار Average Recall@1، در وظیفه توصیف تصویر بهبود ۲/۸٪ در معیار CIDEr و در وظیفه پاسخ به پرسش تصویری¹ افزایش ۱/۶٪ در امتیاز VQA را گزارش می کند. علاوه بر این، BLIP توانایی انتقال صفر-نمونه² به وظایف زبان-ویدیو³ را نیز نشان می دهد که بیانگر قابلیت تعمیم مناسب بازنمایی های چندوجهی یادگرفته شده در این مدل است [3].

1-3-9-2-مدل QWEN

مدل QWEN به عنوان نسل پیشرفته مدل های بینایی-زبان⁴ طراحی شده و تمرکز آن بر درک جامع چندرسانه ای⁵ در حوزه هایی مانند تصویر، سند، ویدئو و رابط های تعاملی است [11]. ویژگی های اصلی آن عبارتند از:

- تشخیص بینایی تقویت شده⁶ برای اشیاء و مفاهیم صحنه.
 - موضوع یابی دقیق⁷ با استفاده از نقاط و جعبه های مرزی⁸.
 - تحلیل ساختاری اسناد⁹ شامل استخراج داده از فرم ها، فاکتورها و نمودارها.
 - درک ویدئوهای طولانی¹⁰ از طریق کدگذاری زمان مطلق¹¹.
- نوآوری کلیدی آن، بهره گیری از رمزگذار تصویر با وضوح پویا است که با مکانیزم توجه پنجره ای قادر به پردازش تصاویر مختلف در وضوح های نیتو است.
- به استناد سند بالا، مدل در اندازه های B3، B7 و B72 عرضه شده و نسخه B72 در بنچمارک های بینایی با مدل های پیشرفته مانند GPT 4o و Claude 3.5 رقابت می کند [11].

¹ Visual Question Answering – VQA

² Zero-Shot Transfer

³ Video-Language Tasks

⁴ Vision-Language Models

⁵ Multimodal Comprehension

⁶ Enhanced Visual Recognition

⁷ Precise Object Localization

⁸ Bounding Boxes/Points

⁹ Document Parsing

¹⁰ Long Video Comprehension

¹¹ Absolute Time Encoding

دو مدل مکمل طراحی شده اند:

الف) Qwen3-VL Embedding

- هدف آن، نگاشت انواع مدالیت ها (تصویر، متن، سند، ویدئو) به فضای بازنمایی مشترک¹ است.
- از پیش آموزش کانتراستو در مقیاس بزرگ² مشابه CLIP بهره می برد تا بردارهای مرتبط نزدیک و نامرتب دور شوند.
- با تقطیر از مدل رتبه بندی³ کیفیت بردارها را بهبود می دهد.
- پشتیبانی از Matryoshka Representation Learning برای تنظیم ابعاد تعبیه بدون نیاز به بازآموزی کامل.

ب) Qwen3-VL Reranker

- یک رمزگذار متقاطع⁴ برای تخمین ریزدانه ارتباط⁵ میان پرس و جو و سند⁶.
- از مکانیزم توجه متقابل⁷ استفاده می کند تا روابط معنایی دقیق میان متن و تصویر را مدل سازی کند.
- خروجی آن برای رتبه بندی مجدد نتایج بازیابی شده توسط مدل Embedding به کار می رود.

ارتباط میان Qwen2.5-VL و Qwen3-VL Embedding/Reranker

- Qwen2.5-VL نقش مدل پایه چندرسانه ای را ایفا می کند که درک و استدلال تصویری، سندی و ویدئویی دارد.
- Qwen3-VL ابزار تخصصی بازیابی و امتیازدهی است که با استفاده از نمایش های یکپارچه⁸ و رمزگذاری متقاطع، دقت را افزایش می دهد.

در سناریوهایی مانند بازیابی تصویر ترکیبی⁹ هر دو مدل به صورت سلسله ای عمل می کنند:

1. Embedding برای جستجوی اولیه (Candidate Retrieval)

¹ Unified Representation Space

² Large-Scale Contrastive Pre-Training

³ Reranking Model Distillation

⁴ Cross-Encoder

⁵ Fine-grained Relevance Estimation

⁶ Query–Document Pair

⁷ Cross-Attention

⁸ Unified Representations

⁹ Composed Image Retrieval

2. Reranker برای ارزیابی دقیق ارتباط متن-تصویر

3. Qwen2.5-VL برای تحلیل نهایی محتوا یا پاسخ به پرسش های پیچیده.

4-9-2- روش Pic2Word

بازیابی تصویر ترکیبی¹ مسئله ای است که در آن کوئری² از ترکیب یک تصویر مرجع³ و یک متن توصیفی/اصلاحی⁴ تشکیل می شود و هدف، بازیابی تصاویری است که به طور هم زمان با تصویر مرجع و متن اصلاحی سازگار باشند [8].

در مقایسه با سیستم های بازیابی صرفاً مبتنی بر تصویر⁵، حضور متن در CIR امکان انتقال صریح قصد کاربر⁶ را فراهم میکند؛ به عنوان مثل نوع تغییری که باید روی تصویر اعمال شود. این ویژگی منجر به افزایش دقت بازیابی میشود [8].

با ظهور مدل های زبان-بینایی⁷ مانند CLIP، توجه قابل ملاحظه ای به مسئله CIR جلب شده و این حوزه در کاربردهای عملی، از جمله جست و جوی اینترنتی و خرده فروشی الکترونیکی⁸ اهمیت ویژه ای پیدا کرده است [8].

روش های کلاسیک CIR اغلب به صورت یک مسئله یادگیری نظارت شده⁹ فرموله می شوند. برای آموزش نیازمند سه تایی های برچسب دار¹⁰ شامل:

- تصویر مرجع¹¹،
- متن اصلاحی/توضیحی¹²،

¹ Composed Image Retrieval - CIR

² Query

³ Query Image

⁴ Text Specification/Modifier

⁵ Image-based Retrieval Systems

⁶ User Intent

⁷ Vision-Language Models - VLMs

⁸ E-commerce

⁹ Supervised Learning

¹⁰ Labeled Triplets

¹¹ Query Image

¹² Text Specification

- تصویر هدف¹

هستند [8]. با این حال، برچسب گذاری چنین سه تایی هایی بسیار پرهزینه است و مقیاس پذیری عملی این حوزه را محدود میکند [8].

به منظور رفع این محدودیت، مقاله Pic2Word مسئله جدیدی به نام بازیابی تصویر ترکیبی بدون نظارت² را تعریف می کند که هدف آن ساخت یک مدل CIR بدون استفاده از سه تایی های برچسب دار CIR در زمان آموزش است [8]. در روش های متداول، برای هر نوع وظیفه (مثلاً ترکیب اشیاء، ویرایش صفات، یا تبدیل حوزه) یک مدل جداگانه با داده سه تایی مخصوص همان وظیفه آموزش داده می شود؛ در حالی که Pic2Word هدف دارد یک مدل واحد بسازد که بتواند زیر-وظایف متنوع CIR را تنها با تکیه بر داده های ارزان تر انجام دهد [8].

برای این منظور، Pic2Word پیشنهاد می کند به جای سه تایی های هزینه بر CIR، از داده های ضعیف برچسب دار³ شامل:

- جفت های تصویر-کپشن⁴

- تصاویر بدون برچسب⁵

استفاده شود [8]. این داده ها به طور گسترده و با هزینه بسیار کمتر قابل جمع آوری اند.

ایده کلیدی Pic2Word این است که به جای انجام ترکیب در فضای تصویری، نداشت تصویر به فضای کلمات/متن انجام شود و عملیات CIR در فضای معنایی زبان⁶ صورت گیرد؛ فضایی که توسط VLM های پیش آموزش دیده مانند CLIP به خوبی سازمان یافته است [8]. بنابراین، Pic2Word هر تصویر را به یک «شبه کلمه⁷» در فضای متنی CLIP تبدیل کرده و بازیابی ترکیبی را در این فضای زبانی انجام می دهد. Pic2Word بر پایه ی یک مدل زبان-بینایی از پیش آموزش دیده⁸، به ویژه CLIP ساخته شده است [8]. معماری کلی از سه جزء اصلی تشکیل می شود:

1. رمزگذار تصویر⁹ CLIP

¹ Target Image

² Zero-Shot Composed Image Retrieval - ZS-CIR

³ Weakly Labeled Data

⁴ Image-Caption Pairs

⁵ Unlabeled Images

⁶ Language Semantic Space

⁷ Pseudo-word

⁸ Pre-trained Vision-Language Model

⁹ Frozen Visual Encoder


2. رمزگذار متن¹ CLIP3. شبکه ی نگاشت² با نماد f_M قابل آموزش

الف) رمزگذارهای تصویری و متنی CLIP

CLIP شامل دو رمزگذار مستقل برای تصویر و متن است:

- رمزگذار تصویر³ که تصویر x را به بردار تع f_{di} تصویری $v(x)$ نگاشت می کند.
 - رمزگذار متن⁴ که یک عبارت متنی را به بردار تعبیه در فضای مشترک⁵ تصویر-متن می برد.
- در Pic2Word، هر دو رمزگذار CLIP در طول آموزش ثابت نگه داشته می شوند⁶ و وزن های آنها به روزرسانی نمی شود [8]. این انتخاب باعث می شود روش Pic2Word بتواند مستقیماً از دانش معنایی گسترده ی CLIP، که بر داده های عظیم تصویر-متن آموزش دیده، بهره مند شود.
- ب) شبکه ی نگاشت f_M : تبدیل تصویر به شبه کلمه در فضای متن
- مؤلفه اصلی Pic2Word، شبکه ی نگاشت f_M است که وظیفه تبدیل بردار تصویری CLIP به یک بازنمایی متنی (شبه کلمه) را دارد [8].
- در این سازوکار:

- ورودی شبکه، تعبیه تصویر $v(x)$ است که توسط رمزگذار تصویری CLIP به دست آمده است.
- خروجی آن، یک تعبیه متنی است که به عنوان شبه کلمه⁷ را در فضای متن CLIP عمل می کند.
- این سازوکار باعث می شود برای هر تصویر، یک بازنمایی متنی معنادار و سازگار با تصویر تولید شود.



¹ Frozen Text Encoder

² Mapping Network

³ Image Encoder

⁴ Text Encoder

⁵ Joint Embedding Space

⁶ Frozen Encoders

⁷ Pseudo-word

شکل (1-1) سمت چپ: مروری بر آموزش شبکه نقشه برداری Pic2Word ما. با توجه به text-encoder و frozen visual، شبکه نقشه برداری، fM، بهینه سازی شده است تا افت کنتراست بین جاسازی تصویر و جاسازی زبان ایجاد شده توسط رمز کلمه s را به حداقل برساند.

راست: مروری بر استنتاج. رمز تخمینی برای پر کردن جمله اعلان داده شده استفاده می شود.

شبکه نگاشت f_M برای کمینه سازی زیان کانتراستیو بین تعبیه تصویری و تعبیه زبانی تولید شده توسط شبه کلمه آموزش داده می شود [8].

این سازوکار باعث می شود برای هر تصویر، یک بازنمایی متنی معنادار و سازگار با تصویر تولید شود. بر خلاف روش های نظارت شده CIR که مستقیماً از سه تایی های (تصویر مرجع، متن اصلاحی، تصویر هدف) استفاده می کنند، Pic2Word تنها بر روی دو نوع داده ارزان تر آموزش می بیند:

1. جفت های تصویر-کپشن¹

مقاله فرض می کند که یک دیتاست بزرگ از جفت های تصویر-کپشن در اختیار داریم:

که در آن x_n یک تصویر و t_n کپشن متنی متناظر با آن است [8].

2. تصاویر بدون برچسب²

علاوه بر جفت های تصویر-کپشن، می توان از مجموعه ای بزرگ از تصاویر بدون هیچ کپشن یا برچسبی نیز استفاده کرد؛ این تصاویر نیز در زیان کانتراستیو برای هم ترازای تعبیه مایش ها به کار گرفته می شوند [8].

الف) انگیزه استفاده از داده های ارزان تر

بدون نیاز به تلاش پرهزینه جمع آوری داده های سه تایی برچسب دار، در عوض، مدل بازیابی را با استفاده از جفت های تصویر-کپشن در مقیاس بزرگ و تصاویر بدون برچسب آموزش می دهیم که جمع آوری آن ها به مراتب ارزان تر است [8] که هدف آن ها اجتناب از هزینه سنگین جمع آوری سه تایی های برچسب دار CIR است

در نتیجه، Pic2Word می تواند به صورت Zero-shot روی وظایف CIR به کار گرفته شود، بدون این که مستقیماً روی سه تایی های آن وظایف آموزش دیده باشد [8].

ب) تابع زیان کانتراستیو³

¹ Image-Caption Pairs

² Unlabeled Images

³ Contrastive Loss

برای آموزش f_M ، مقاله از یک تابع زیان کانتراستیو استفاده می کند. ایده کلی این است که:

- برای هر تصویر x ، تعبیه تصویری $v(x)$ توسط رمزگذار تصویر تولید می شود؛
- شبکه نگاشت f_M بر روی $v(x)$ اعمال شده و یک تعبیه نمایش متنی شبه کلمه (در فضای متن CLIP) تولید می کند؛

• زیان کانتراستیو طوری تعریف می شود که تعبیه نمایش متنی شبه کلمه با تعبیه نمایش تصویری متناظر بیشترین شباهت را داشته و از تعبیه نمایش سایر نمونه ها متمایز باشد [8].

در کنار این، با استفاده از جفت های تصویر-کپشن، می توان همزمان روی سازگاری شبه کلمه با کپشن متناظر نیز نظارت کرد (یعنی شبه کلمه در همان فضای متنی قرار گیرد که کپشن واقعی t_n نیز حضور دارد). در متن استخراج شده، ساختار کامل فرم ریاضی زیان داده نشده، اما ایده ی اصلی، همترازسازی شبه کلمه با تصویر و با متن مرتبط در فضای مشترک CLIP است.

خروجی این فرایند آموزشی، شبکه ای است که می تواند برای هر تصویر، یک تعبیه نمایش متنی معنادار تولید کند؛ بدون آن که نیازی به مشاهده سه تایی های CIR در زمان آموزش داشته باشد [8].

۲.۵.۱.۴. فرایند استنتاج (Inference) برای ZS-CIR

پس از آموزش f_M ، Pic2Word می تواند برای بازیابی تصویر ترکیبی در حالت Zero-shot به کار رود. مطابق شکل ۲:

«... در این بخش رویکرد خود را برای ZS-CIR معرفی می کنیم. مرور کلی فرایند آموزش و استنتاج در شکل ۲ نشان داده شده است. ما از یک مدل تصویر-متن پیش آموزش دیده CLIP استفاده می کنیم...» [8].

برای یک کوئری CIR شامل تصویر مرجع و متن اصلاحی، مراحل استنتاج به صورت مفهومی به شرح زیر است:

1. تبدیل تصویر مرجع به شبه کلمه در فضای متن

- تصویر مرجع x_{ref} ابتدا توسط رمزگذار تصویری CLIP به تع u_{ref} نمایش نگاشت می شود؛
- سپس این تعبیه به شبکه ی نگاشت f_M داده می شود تا یک تع u نمایش متنی شبه کلمه تولید شود.

2. کدگذاری متن اصلاحی توسط رمزگذار متن CLIP

- متن اصلاحی به کمک رمزگذار متنی CLIP به یک بردار در فضای متنی CLIP نگاشت می شود.

3. ترکیب در فضای زبان

- تعبیه نمایش شبه کلمه‌ی حاصل از تصویر و تعبیه نمایش متن اصلاحی در فضای تعبیه نمایش متنی¹ ترکیب می‌شوند؛
- مقاله در متن به این موضوع اشاره می‌کند که جزئیات دقیق ترکیب در شکل ۲ و بخش روش آمده است [8], p.3, line 37. از متن استخراج شده، به‌طور صریح نوع عملگر ترکیب (مثل جمع برداری ساده یا تابع ترکیب آموخته شده) مشخص نشده است و برای نوشتن فرمول دقیق باید به خود شکل و فرمول‌ها مراجعه کرد.

4. بازیابی تصویر در پایگاه داده

- بردار نهایی ترکیبی در فضای متن، به‌عنوان کوئری متنی ترکیبی² عمل می‌کند؛
 - تصاویر موجود در پایگاه داده قبلاً توسط رمزگذار تصویری CLIP به تعبیه نمایش تصویری نگاشت شده‌اند؛
 - با استفاده از معیار شباهت³ در فضای مشترک (مثلاً ضرب داخلی نرمال شده)، نزدیک‌ترین تصاویر به کوئری ترکیبی بازیابی می‌شوند (Nearest Images).
- بدین ترتیب، بدون استفاده از هیچ‌گونه سه‌تایی مخصوص CIR در آموزش، مدل می‌تواند تنها بر پایه‌ی نگاشت تصویر به شبه کلمه در فضای متن و ترکیب آن با متن اصلاحی، وظایف مختلف CIR را در حالت Zero-shot انجام ده [8].

۲.۵.۱.۵. ارزیابی تجربی و نتایج Pic2Word

الف) دیتاست‌های استفاده شده

Pic2Word بر روی چندین دیتاست برای Zero-shot Composed Image Retrieval ارزیابی شده است. دو دیتاست کلیدی عبارت‌اند از:

- **CIRR** – یک بنچمارک استاندارد CIR برای ترکیب اشیاء و تغییرات معنایی در صحنه‌ها؛
- **Fashion-IQ** – یک دیتاست محبوب CIR برای دستکاری صفات مد و لباس⁴ [8].

نویسندگان صراحتاً از این دو دیتاست به‌عنوان بنچمارک‌های استاندارد CIR یاد می‌کنند:

¹ Text Embedding Space

² Composed Text Query

³ Similarity Measure

⁴ Fashion Attribute Manipulation

«روش ما بر روی چندین دیتاست، از جمله بنچمارک های استاندارد CIR، CIRR و Fashion-IQ ارزیابی می شود.» [8] 4.p, 100 line.

علاوه بر این، مقاله از چهار دیتاست برای ارزیابی ZS-CIR استفاده می کند تا عملکرد مدل را در سناریوهای متنوع بررسی کند [8] 4.p, 100-97 lines.

ب) مقایسه با روش های نظارت شده موجود

برای ارزیابی کیفیت Pic2Word، آن را با روش های نظارت شده مبتنی بر Combiner (که بر روی سه تایی های CIR آموزش می بینند) مقایسه می کنند. برای این روش های پایه (Baselines):

- مدل Combiner روی حدود ۲۸'۰۰۰ سه تایی آموزشی CIRR و

- حدود ۱۸'۰۰۰ سه تایی آموزشی Fashion-IQ

آموزش داده [8] 6.p, 80-79 lines.

در مقابل، Pic2Word هرگز روی این سه تایی ها آموزش نمی بیند و تنها با تکیه بر جفت های تصویر-کپشن و تصاویر بدون برچسب آموزش دیده است [8] 1.p, 18 line, 2.p, 12-8 lines.

طبق نتایج گزارش شده در جدول ها و تحلیل ها:

- در آزمایش تبدیل حوزه (Domain Conversion) - مثلاً استفاده از ImageNet و اعمال انتقال از

یک فضای معنایی به دیگری - Pic2Word تمام روش های مبنا را با اختلاف قابل توجهی شکست [8] 5.p, 9 line, 1 Table).

- در وظیفه ترکیب اشیاء (Object Composition) روی COCO نیز Pic2Word نتایج رقابتی و در

مواردی برتر نسبت به Combiner ارائه [8] 5.p, 26 line, 2 Table).

- در بنچمارک های اصلی CIRR و Fashion-IQ، عملکرد Pic2Word قابل مقایسه و در برخی

معیارها برتر از روش های نظارت شده است، با وجود این که هیچ سه تایی CIR در آموزش آن استفاده

نشده است [8] 5.p, 6-5 Table, 1 Fig, 6.

این نتایج نشان می دهد که نگاشت تصویر به فضای کلمات و استفاده از داده های ضعیف برچسب دار، بدون

نیاز به داده های سه تایی، می تواند به سطح عملکردی برسد که حتی با روش های نظارت شده رقابت کند یا

آن ها را پشت سر بگذارد.

ج) تحلیل کیفی¹

- مقاله علاوه بر نتایج عددی، چند مثال کیفی نیز ارائه می کند. به عنوان نمونه:
- در شکل ۶، مثال هایی از بازیابی در دیتاست Fashion-IQ نمایش داده شده است. در این مثال ها، دستکاری صفات مد (مانند تغییر رنگ، طرح، یا سبک لباس) به صورت موفقیت آمیز توسط Pic2Word انجام شده است و تفاوت آن با روش های پایه مانند «متن + تصویر» (Text + Image) (Baseline) نشان داده می شود؛ در حالی که روش پایه در برخی موارد صرفاً تصویر مرجع را [8] 62-58 lines.
 - این مثال ها نشان دهنده توانایی Pic2Word در درک ترکیبی¹ متن اصلاحی و تصویر مرجع در فضای زبانی CLIP است.

۳ مدل CoLLM: استفاده از LLM برای CIR

۱-۳-۵-۲ انگیزه و مشکلات روش های پیشین

مقاله «CIR: CoLLM: A Large Language Model for Composed Image Retrieval» را یک وظیفه پیچیده می داند که در آن پرس و جو چندوجهی (Multimodal Query) است و داده های آموزشی معمولاً سه تایی های تصویر مرجع، متن تغییر و تصویر هدف را شامل می شود [CoLLM, p.1, lines 11-12]. نویسندگان اشاره می کنند که کمبود دیتاست های CIR موجب شده روش های صفر-نمونه مبتنی بر سه تایی های مصنوعی (Synthetic Triplets) یا مدل های بینایی-زبان وب مقیاس مطرح شوند، اما این روش ها محدودیت هایی دارند؛ سه تایی های مصنوعی اغلب مقیاس و تنوع کافی نداشته و متن تغییر نیز ممکن است غیرطبیعی باشد [p.1, lines 11-12].

۲-۳-۵-۲ CoLLM: LLM برای تولید سه تایی و نمایش مشترک

CoLLM دو ایده اصلی را ترکیب می کند:

۱. تولید سه تایی روی-هوا (On-The-Fly Triplet Generation)

CoLLM از جفت های تصویر-کپشن (Image-Caption Pairs) برای تولید سه تایی های CIR استفاده می کند؛ به این صورت که از روی یک تصویر و کپشن، تصاویر دیگر و متن های تغییر مرتبط ساخته می شود. بدین ترتیب، بدون برچسب گذاری انسانی می توان داده ی نظارت شده برای آموزش CIR تولید کرد [CoLLM, p.1, lines ~18-22].

۲. استفاده از مدل زبانی بزرگ برای نمایش مشترک (Joint Embedding)

CoLLM از LLM برای تولید نمایش مشترک (Joint Embedding) تصویر مرجع و متن تغییر استفاده می کند و بدین وسیله یک «فیوژن چندوجهی عمیق تر» (Deeper Multimodal Fusion) را محقق می سازد [CoLLM, p.1, lines ~18-22]. به عبارت دیگر، به جای صرفاً الحاق یا جمع برداری ویژگی های تصویر و متن، مدل از قدرت استدلال و ترکیب LLM استفاده می کند تا رابطه پیچیده بین تصویر مرجع و متن تغییر را بهتر مدل کند.

۳-۳-۵-۲ دیتاست MTCIR و بهبود ارزیابی

نویسندگان یک دیتاست جدید به نام MTCIR (Multi-Text CIR) با حدود ۳/۴ میلیون نمونه معرفی می کنند که امکان آموزش در مقیاس بزرگ را فراهم می آورد [CoLLM, p.1, lines ~18-22]. علاوه بر این، آن ها نسخه ای اصلاح شده ای از دیتاست های CIR و Fashion-IQ ارائه می دهند تا قابلیت اعتماد (Reliability) ارزیابی مدل ها افزایش یابد [همان منبع].

نتایج تجربی نشان می دهد که CoLLM در چندین معیار و دیتاست مختلف به عملکرد روزآمد (State-of-the-Art – SOTA) دست می یابد و MTCIR بهبودهایی تا حدود ۱۵٪ نسبت به روش های پیشین ایجاد می کند [CoLLM, p.1, lines 21-25].

5-9-2-ایده SEARLE

ایده SEARLE مبتنی بر «معکوس سازی متنی» (Textual Inversion) در فضای توکن های CLIP است. روش کار به این صورت است:

1. یک CLIP پیش آموزش دیده و منجمد¹ در نظر گرفته می شود.
2. تصویر مرجع به یک توکن شبه-کلمه² در فضای جاسازی توکن های CLIP نگاشت می شود [p.1, line 13؛ p.2, line 9].
3. این شبه-کلمه به همراه کپشن نسبی³ به عنوان یک توالی متنی ترکیبی به رمزگذار متن CLIP داده می شود.
4. بدین ترتیب، مسئله CIR به یک مسئله استاندارد متن-به-تصویر (Text-to-Image Retrieval)

¹ Frozen Pre-trained CLIP

² Pseudo-Word Token

³ Relative Caption

تبدیل می شود؛ یعنی به جای استفاده هم زمان از رمزگذار تصویر و متن، یک توالی متنی غنی شده (شامل شبه-کلمه ی تصویری) تولید می شود که می تواند با تصاویر پایگاه در فضای CLIP مقایسه شود.

این ایده، استفاده از فضای توکن های CLIP برای جذب اطلاعات تصویر در قالب یک توکن متنی آموزش پذیر است که ساختار زبان را حفظ می کند و امکان بهره گیری از ظرفیت CLIP را در حالت منجمد فراهم می سازد [10].

10-2- فیلوژن چندوجهی در بازیابی تصویر مبتنی بر محتوا

در

ب فیلوژن در سطح مدل

امکان ترکیب ویژگی های مدل های مختلف وجود دارد. چنین تلفیقی بیشتر بر مکمل بودن مدل متمرکز است، با روش هایی که به درون مدل و بین مدل طبقه بندی می شوند.

همجوشی درون مدلی چندین مدل عمیق را پیشنهاد می کند که ساختارهای مشابه یا بسیار سازگار دارند، در حالی که همجوشی بین مدل ها شامل مدلی با ساختارهای متفاوت است. به عنوان مثال، سیمونیان و همکاران. [49] یک استراتژی ادغام درون مدل ConvNet را برای بهبود ظرفیت یادگیری ویژگی VGG معرفی می کند که در آن 16-VGG و 19-VGG با هم ترکیب می شوند. وانگ و همکاران برای رسیدگی به بخش های مختلف یک شیء تصویری. [105] با انتخاب تمام لایه های کانولوشن 16-VGG برای استخراج نمایش های تصویر، که قوی تر از استفاده از ویژگی های تک لایه است، به ترکیب چند ویژگی پی ببرید.

همجوشی بین مدل راهی برای پل زدن ویژگی های مختلف با توجه به این واقعیت است که شبکه های عمیق مختلف میدان های دریافت متفاوتی دارند [52]، [68]، [79]، [97]. به عنوان مثال، یک شبکه توجه دو جریانی [79] برای پیاده سازی بازیابی تصویر معرفی شده است که در آن شبکه اصلی برای پیش بینی معنایی 16-VGG است در حالی که یک شبکه کمکی برای پیش بینی نقشه های توجه استفاده می شود. به طور مشابه، با توجه به اهمیت و ضرورت همجوشی بین مدلی برای پر کردن شکاف بین ویژگی های سطح متوسط و سطح بالا، لیو و همکارانش. [52] و ژنگ و همکاران. [97] ترکیب 19-VGG و AlexNet و ویژگی های ترکیبی را یاد می گیرند، در حالی که Ozaki و همکاران. [68]

توصیفگرها را از شش مدل مختلف به هم متصل کنید. ترکیب بین مدل و درون مدل به انتخاب مدل مربوط می شود. چند استراتژی برای تعیین نحوه ترکیب ویژگی های دو مدل وجود دارد. ترکیب کردن همه ویژگی ها از مدل های کاندید و سپس یادگیری یک متریک بر اساس ویژگی های به هم پیوسته [52]، [79]، که نوعی استراتژی «همجوشی اولیه» است، ساده است. همچنین می توان معیارهای بهینه را به طور جداگانه برای ویژگی های هر مدل یاد گرفت و سپس این معیارها را برای رتبه بندی بازیابی نهایی ترکیب کرد [36]، [106]، که نوعی استراتژی «همجوشی دیر هنگام» است.

بحث. ادغام در سطح لایه و ادغام در سطح مدل مشروط به این واقعیت است که لایه ها یا شبکه های مرتبط ظرفیت های توصیف ویژگی متفاوتی دارند. برای این استراتژی های همجوشی، سوال کلیدی این است که چه ویژگی هایی بهتر است با هم ترکیب شوند؟ برخی کاوش ها بر اساس مدل های خارج از قفسه، مانند Xuan et al. [107]، که اثر ترکیب تعداد مختلف ویژگی ها و اندازه های مختلف در مجموعه را نشان می دهد. چن و همکاران [108] عملکرد ویژگی های تعبیه شده از طبقه بندی تصویر خارج از قفسه و مدل های تشخیص شی را با توجه به بازیابی تصویر تحلیل می کنند.

مقاله Deep Learning for Instance Retrieval: A Survey

1-10-2- انواع فیوژن چندوجهی

در مسئله بازیابی تصویر ترکیبی¹، کیفیت نمایش مشترک تصویر-متن و نحوه ادغام (فیوژن) اطلاعات چندوجهی نقش تعیین کننده ای در عملکرد سیستم دارد [24]، [25].

راهبردهای فیوژن را می توان از دو منظر اصلی دسته بندی کرد:

1. «چه زمانی» فیوژن انجام می شود؟ (When to Fuse)
2. «چگونه» فیوژن انجام می شود؟ (How to Fuse)

در بُعد «زمان فیوژن»، سه سطح اصلی تعریف می شوند: فیوژن زودهنگام¹، فیوژن میانی² و فیوژن دیرهنگام³.

در بُعد «چگونگی فیوژن» نیز، روش ها به طور کلی به دو دسته ی بدون توجه (Attention Agnostic) و مبتنی بر توجه (Attention Based) - که شامل توجه متقابل⁴ نیز می شود - تقسیم می شوند [25]. در ادامه، با تکیه بر این دو بُعد، انواع فیوژن را به شکل مناسب برای CIR توضیح می دهیم.

الف) فیوژن زودهنگام

در فیوژن زودهنگام، ادغام مدالیت ها در سطح داده ی خام صورت می گیرد [25]. به عبارت دیگر، در این رویکرد:

- داده های متنی و تصویری (یا در رباتیک: RGB و depth، LiDAR، صوت، متن و ...) پیش از استخراج ویژگی، مستقیماً با هم ترکیب می شوند (مثلاً با الحاق (concatenation) کانال ها یا نداشت به یک تنسور مشترک).

- ساختار کلی ساده است و امکان استفاده ی مستقیم از خصوصیات خام داده را فراهم می کند.
- طبق گزارش همان منبع، روش های فیوژن زودهنگام معمولاً attention agnostic هستند و بر الحاق مستقیم یا pooling ویژگی ها تکیه می کنند [25].

در زمینه ی CIR، گرچه به ندرت داده ی «خام» متن و تصویر در یک فضای پیکسلی مشترک ترکیب می شود، اما ایده ی Early Fusion می تواند به صورت ادغام اولیه ی توکن های متنی و وصله های تصویری در ورودی یک ترنسفورمر مشترک تحقق یابد (مثلاً چسباندن دنباله ی توکن های متن و patch های تصویر قبل از هرگونه پردازش جداگانه). این نوع طراحی، بیشترین امکان تعامل زودهنگام میان دو مدالیت را فراهم می کند، اما از نظر پیچیدگی محاسباتی و مدیریت چالش برانگیز است.

ب) فیوژن میانی (Mid / Intermediate Fusion)

فیوژن میانی (Intermediate / Mid Fusion) در [25] به عنوان رویکردی معرفی می شود که پس از استخراج ویژگی، ولی پیش از مرحله ی تصمیم گیری انجام می شود. در این شیوه:

- تصویر و متن هر کدام ابتدا توسط رمزگذارهای اختصاصی (modality specific encoders) به

¹ Early Fusion

² Intermediate/Mid Fusion

³ Late Fusion

⁴ Cross Attention

فضای ویژگی نگاشت می شوند.

- سپس، نمایش های سطح بالا (نه داده ی خام) با روش هایی مثل الحاق ویژگی¹، جمع یا میانگین گیری، شبکه های ادغام (fusion networks) یا بلوک های توجه متقابل (cross attention blocks) ترکیب می شوند [25].

این سطح از فیوژن، در عمل، رایج ترین انتخاب برای مدل های زبان-بینایی (Vision Language Models – VLMs) است، چون:

- امکان استفاده از رمزگذارهای ازپیش آموزش دیده ی تخصصی (مثل CLIP image encoder و text encoder) را می دهد؛
- و در عین حال، اجازه می دهد که یک ماژول فیوژن انعطاف پذیر (مثلاً براساس Cross Attention) بر بالای این نمایش ها طراحی شود تا وابسته به وظیفه ی هدف (مانند CIR) بهینه گردد.
- در CIR، رویکردهای mid fusion معمولاً شامل این است که:
- ابتدا یک بردار متنی برای کوئری ترکیبی (متن + تصویر مبنا) و یک بردار تصویری برای هر تصویر در پایگاه داده تولید می شود؛
- سپس یک یا چند لایه ی فیوژن (مانند ترنسفورمر چندوجهی یا شبکه ی تطبیق² نمایش ها را برای محاسبه ی نمرات شباهت ترکیب می کنند.

ج) فیوژن دیر هنگام³

در فیوژن دیر هنگام، هر مدالیتة مسیر پردازش مستقل خود را طی می کند و ادغام تنها در مرحله ی تصمیم یا نمره دهی رخ می دهد [25].

هرچند ادامه ی جمله در قطعه ی بازیابی شده حذف شده، اما با توجه به چارچوب شکل ۳ و توضیحات بخش «When to Fuse»، منظور این است که:

- هر مدالیتة (مثلاً تصویر و متن) به طور کامل تا سطح پیش بینی⁴ یا نمره ی شباهت پردازش می شود؛
- سپس، تصمیم های نهایی یا نمرات هر مدالیتة از طریق ترکیب ساده (مثل میانگین، وزن دهی خطی، رأی گیری، و ...) ادغام می شوند.

در CIR، نمونه ی ساده ی Late Fusion می تواند این باشد که:

¹ feature concatenation

² matching network

³ Late Fusion

⁴ prediction

- ابتدا یک نمره شباهت برای تصویر کوئری و هر تصویر پایگاه داده (مثلاً با یک شبکه ی بصری) محاسبه شود؛
 - جداگانه، یک نمره شباهت بین متن اصلاحی¹ و توضیحات متنی تصاویر (یا متن تولیدشده توسط یک captioner) محاسبه گردد؛
 - و در نهایت، این نمرات در سطح تصمیم ترکیب شوند.
- مزیت اصلی Late Fusion این است که انعطاف پذیری بالایی در ترکیب سیستم های از قبل ساخته شده فراهم می کند، اما معمولاً تعامل عمیق معنایی میان مدالیت ها را به خوبی Early/Mid Fusion مبتنی بر توجه پوشش نمی دهد.

(د) فیوژن میان وجهی² و نقش توجه متقابل³

فیوژن میان وجهی [25] همجوشی چندوجهی در چند موضع مورد بحث قرار گرفته است. همچنین، در وظایف سه بعدی:

“BridgeQA constructs multi-level cross-modal fusion channels between global 3D scene context and fine grained object features, achieving tighter visual linguistic alignment and [25].spatial reasoning capabilities”

از این عبارات می توان نتیجه گرفت که در فیوژن میان وجهی:

- هدف، ساخت فضای تعاملی نمایش مشترک (shared / modality invariant embedding space) است که در آن فاصله ی مدالیت های (modal gaps) کاهش یابد؛
- فیوژن می تواند در چند سطح (multi level fusion channels) میان زمینه ی کلی تصویر/صحنه و جزئیات موضعی (objects, regions) انجام شود تا هم تراز ی زبان-بینایی (visual linguistic alignment) و استدلال فضایی (spatial reasoning) بهبود یابد؛
- با این حال، افزایش عمق و پیچیدگی این کانال های فیوژن، منجر به افزایش هزینه ی محاسباتی می شود و مقاله تصریح می کند که طراحی ساختارهای سبک تر و کاهش سر بار محاسباتی فیوژن میان وجهی یکی از چالش های مهم در VLM ها است [25].

یکی از مهم ترین سازوکارهای عملی برای پیاده سازی Cross Modal Fusion، استفاده از مکانیزم توجه متقابل (Cross Attention Mechanism) است. در حوزه ی رباتیک سه بعدی، نمونه هایی مانند DeepFusion

¹ modifying text

² Cross Modal Fusion

³ Cross Attention

و TransFusion به کارگیری Cross Attention را به روشنی نشان می دهند:

“DeepFusion ensures precise alignment of LiDAR and image features using InverseAug and cross attention mechanisms. ... TransFusion introduces a soft association fusion framework using a Transformer decoder... The first layer generates initial 3D boxes with object queries, while the second layer refines them using cross attention [25]”.

در این طرح ها:

- یک مجموعه query (مثلاً جعبه های سه بعدی اولیه یا توکن های متنی) با استفاده از Cross Attention بر روی ویژگی های مدالیت های دیگر (مثلاً تصویر یا LiDAR) حاضر می شود؛
 - Cross Attention بدین شکل، نقش یک مازول فیوژن میان وجهی را بازی می کند که از طریق آن، تصمیم ها یا نمایش های یک مدالیت بر اساس اطلاعات مدالیت های دیگر اصلاح و بهبود می شوند.
- همین سازوکار در مرور VLM ها برای وظایف بینایی نیز دیده می شود. در فایل Vision Language Models for Vision Tasks.pdf، یک رمزگشای متنی چندوجهی (Multi Modal Text Decoder) با برجسب Cross Attention نشان داده شده است که متن هایی مانند «a dog playing with a ball» را بر اساس تصویر + متن ورودی تولید می کند:

“Multi-modal Text Decoder – Cross Attention – a dog playing with a ball – Input Image – Input Text [25]”

و در همان سند، Cross Attention (CA) به عنوان یکی از روش های تطبیق/انتقال (Transfer Learning) در VLM ها کنار روش هایی همچون prompt tuning و adapters قرار گرفته است:

“CA: cross attention”

- همان منبع، جدول ۴، ص. ۱۱، خط ۳ همان منبع، جدول ۴، ص. ۱۱، خط ۳
- در زمینه ی CIR، استفاده از Cross Attention در لایه های میانی فیوژن امکان می دهد که:
- توکن های متنی (به ویژه متن اصلاحی یا توصیفی) به طور مستقیم به وصله های تصویری (image patches) یا ویژگی های اشیاء توجه کنند؛
 - برعکس، توکن های تصویری بتوانند از متن برای رفع ابهام و تمرکز بر نواحی مرتبط استفاده کنند؛
 - در نتیجه، مدل بتواند ترکیب معنایی دقیق تری از «تصویر مبنا + متن اصلاحی» بسازد و تصویر هدف را در پایگاه داده با دقت بالاتری بازیابی کند.

۲۸۲۲. فیوژن در CoLLM – نمونه ی پیشرفته برای CIR

مدل CoLLM به عنوان یکی از رویکردهای جدید در بازیابی تصویر ترکیبی، از مدل های زبانی بزرگ¹ به عنوان هسته ی فیوژن چندوجهی بهره می گیرد [22]. طبق گزارش این کار، CoLLM با استفاده از یک LLM، نمایش مشترک تصویر-متن را به صورت صریحاً متکی بر استدلال زبانی ایجاد می کند [22] در این چارچوب:

- ویژگی های تصویری ابتدا توسط یک رمزگذار بینایی² به توکن ها یا بردارهای نهفته تبدیل می شوند؛
 - کوئری CIR (ترکیب «تصویر مبنا + متن اصلاحی») به گونه ای قالب بندی می شود که برای LLM قابل درک باشد (مثلاً به صورت یک prompt ساختارمند که شامل خلاصه ای متنی از تصویر و متن اصلاحی است)؛
 - مدل زبانی بزرگ، با تکیه بر مکانیزم توجه (attention) درون خود، به طور همزمان روی نمایش های متنی و بازنمایی های تصویری (که به حوزه ی زبانی نگاشت شده اند یا به صورت توکن های ویژه وارد شده اند) عمل می کند و یک بردار نهفته ی مشترک³ یا نمره ی تطبیق برای هر تصویر تولید می کند.
- از منظر فیوژن چندوجهی، CoLLM چند نکته ی مهم را نشان می دهد:

1. ارتقای سطح فیوژن از سطح ویژگی به سطح استدلال⁴؛

در حالی که بسیاری از روش های کلاسیک CIR، فیوژن را در سطح بردارهای ویژگی (mid fusion) انجام می دهند، CoLLM با بهره گیری از توان استدلالی LLM، فیوژن را در سطح مفاهیم و روابط زبانی انجام می دهد. این امر به مدل اجازه می دهد تا روابط پیچیده ی «متن اصلاحی + محتوای تصویر» را در قالب استنتاج زبانی درک کند.

2. استفاده از سازوکارهای توجه درون LLM به عنوان Cross Modal Fusion ضمنی:

اگرچه در متن CoLLM تعبیر دقیقاً مشابه «cross attention» در معماری های کلاسیک ترنسفورمر چندوجهی ممکن است به صراحت نیامده باشد، اما در عمل، وقتی توکن های نماینده ی تصویر و متن در یک دنباله ی ورودی مشترک به LLM داده می شوند، مکانیزم خود توجه (self attention) نقش یک ماژول فیوژن میان وجهی را ایفا می کند؛ زیرا توکن های متنی می توانند به توکن های تصویری توجه کنند و برعکس. این امر، از نظر رفتاری بسیار نزدیک به آن چیزی است که در فیوژن مبتنی بر Cross Attention در VLM ها مشاهده می شود [24].

¹ Large Language Models – LLMs

² vision encoder

³ joint embedding

⁴ reasoning level fusion

3. کاربرد در CIR و بهبود درک روابط معنایی:

در وظیفه ی CIR، CoLLM نمایش ترکیبی غنی تری از کوئری «تصویر + متن» می سازد که:

- o هم اطلاعات ظاهر و محتوای تصویر مبنا را دربرمی گیرد؛
- o و هم قیود/اصلاحات معنایی اعمال شده توسط متن را مدل می کند (مثلاً تغییر سبک، رنگ، ترکیب اشیاء).

نتیجه ی این فیوژن سطح بالا، بهبود قابل ملاحظه ای در درک روابط معنایی ترکیبی و در نتیجه، بهبود دقت بازیابی تصویر نسبت به روش هایی است که فقط از ترکیب خطی یا فیوژن ساده ی ویژگی ها استفاده می کنند [22].

به طور خلاصه، می توان گفت CoLLM نمونه ای از فیوژن چندوجهی نسل جدید است که:

- از منظر «زمان فیوژن»، در سطح میانی تا دیر هنگام، اما روی نمایش های معنایی سطح بالا عمل می کند؛
- و از منظر «چگونگی فیوژن»، اساساً مبتنی بر توجه¹ است و از ظرفیت های LLM برای انجام استدلال میان وجهی² بهره می برد.

11-2- دیتاست ها

ساختار داده در CIR

در مسئله بازیابی تصویر ترکیبی³، نمونه های آموزشی و ارزیابی معمولاً به صورت سه تایی $(I_r, (I_t, Tr, Ir))$ در دسترس قرار می دهند که در آن I_r تصویر مرجع، Tr یک توصیف نسبی متنی و I_t تصویر هدف است. ساخت این نوع داده به طور قابل ملاحظه ای پرهزینه است، زیرا برخلاف برچسب های طبقه بندی یا کپشن های مطلق، توصیف های نسبی⁴ به سادگی در منابع موجود یافت نمی شوند و تولید خودکار آن ها همچنان چالش برانگیز است [10]. به همین دلیل، بخش قابل توجهی از دیتاست های

¹ attention based

² cross modal reasoning

³ Composed Image Retrieval – CIR

⁴ Modification Texts

کلاسیک CIR روی دامنه های خاصی مانند فشن، پرندگان یا اشیای مصنوعی تمرکز دارند (همان، ص. ۲، خط ۲۷) و غالباً برای هر query تنها یک تصویر هدف به عنوان Ground Truth در نظر گرفته می شود. این مسئله علاوه بر محدود کردن دامنه^۱ تعمیم مدل ها، منجر به بروز موارد متعدد «مثبت های کاذب» و «منفی های کاذب» در هنگام ارزیابی می شود.

در این میان، دو دیتاست CIRCO و CIRRR به عنوان نسل جدید دیتاست های CIR در دامنه باز مطرح شده اند. CIRRR نخستین دیتاست CIR مبتنی بر تصاویر واقعی در دامنه باز محسوب می شود، در حالی که CIRCO به طور ویژه برای ارزیابی سناریوی بازیابی تصویر ترکیبی بدون نمونه^۱ طراحی شده و اولین دیتاستی است که برای هر query چندین Ground Truth ارائه می کند [10].

دیتاست CIRRR در کارهای متعددی به عنوان یکی از بنچمارک های استاندارد CIR مورد استفاده قرار گرفته است. برای مثال، روش Pic2Word که یک روش Zero-Shot برای CIR است، عملکرد خود را بر روی «بنچمارک های رایج CIR، شامل CIRRR و Fashion-IQ» گزارش می کند و از این دو دیتاست به عنوان بنچمارک های استاندارد CIR یاد می کند [8]. همچنین مدل CoLLM نیز CIRRR و Fashion-IQ را به عنوان دو بنچمارک متداول CIR شناسایی کرده و برای بهبود اطمینان ارزیابی، نسخه^۱ بازبینی شده ای از آن ها ارائه می کند [22].

از منظر محتوا، CIRRR بر پایه^۱ تصاویر واقعی و در دامنه ای باز بنا شده است. SEARLE تصریح می کند که به زعم نویسندگان، CIRRR تنها دیتاست CIR است که «تصاویر طبیعی در دامنه باز» را در نظر می گیرد [10] و در ادامه اشاره می کند که این دیتاست «تنها دیتاست مبتنی بر تصاویر واقعی در دامنه^۱ باز» است که در فرآیند ساخت آن، مجموعه هایی شامل ۶ تصویر از لحاظ بصری مشابه به صورت خودکار تولید می شوند [10]. در مرحله^۱ برچسب گذاری، برای هر مجموعه^۱ ۶ تایی، تصویر مرجع و هدف از میان همان مجموعه انتخاب می شوند و annotator یک توصیف نسبی متنی می نویسند که اختلافات ظریف میان این دو تصویر را بیان می کند (همان، ص. ۶، خطوط ۱۷-۱۹). به این ترتیب، CIRRR به طور خاص برای سنجش توانایی مدل ها در تمایز میان تصاویر از لحاظ بصری بسیار مشابه و اعمال تغییرات ظریف بر پایه^۱ توصیف های نسبی طراحی شده است.

از دیدگاه ارزیابی، CIRRR علاوه بر معیار کلاسیک Recall@K روی کل مجموعه^۱ اندیس، معیار دیگری به نام RecallSubset@K معرفی می کند. در رویکردهای متداول، به منظور کاهش اثر منفی نبودن بسیاری از پاسخ های بالقوه صحیح در برچسب ها (False Negatives)، ارزیابی بر روی مقادیر نسبتاً بزرگ K (مانند ۱۰

¹ Zero-Shot CIR

و ۵۰) انجام می شود [10]. اما این امر تحلیل دقیق عملکرد مدل ها را دشوار می سازد. CIRR برای رفع این مشکل، RecallSubset@K را تعریف می کند که تنها روی همان مجموعه^۱ کوچک شامل ۶ تصویر بصری مشابه محاسبه می شود (همان، ص. ۶، خط ۵۰). به این ترتیب، امکان تحلیل دقیق تری از عملکرد مدل در سطح تمایز ظریف بین تصاویر بسیار مشابه فراهم می شود. با این حال، پژوهش های بعدی مانند CoLLM نشان داده اند که حتی در CIRR نیز ابهام در متون تغییر (Modification Texts) می تواند همچنان ارزیابی را تحت تأثیر قرار دهد و لذا این دیتاست نیازمند بازبینی و پالایش متون است [22].

در ادامه^۲ این روند، دیتاست CIRCO^۱ به منظور پشتیبانی از پژوهش در حوزه^۲ «بازیابی تصویر ترکیبی بدون نمونه» معرفی شده است. CIRCO یک دیتاست بنچمارک در دامنه^۳ باز است که بر پایه^۴ تصاویر مجموعه^۵ بدون برچسب COCO 2017 ساخته شده و به عنوان «اولین دیتاست CIR با چندین Ground Truth برای هر query» شناخته می شود [10]. برخلاف CIRR که از مجموعه های ۶ تایی تصاویر مشابه شروع می کند، CIRCO فرآیند ساخت داده را از یک زوج تک از تصاویر بصری مشابه آغاز کرده و برای این زوج، یک کپشن نسبی تولید می شود. افزون بر این، برای هر زوج یک حاشیه نویسی کمکی شامل ویژگی های مشترک تصویر مرجع و هدف نیز فراهم می شود تا ابهامات احتمالی در تفسیر توصیف نسبی کاهش یابد (همان، ص. ۶، خطوط ۲۹-۳۱).

یکی از نقاط تمایز اصلی CIRCO نسبت به دیتاست های پیشین، فراهم کردن Ground Truth های متعدد برای هر query است. نویسندگان با استفاده از راهبردی مبتنی بر SEARLE، فرآیند برچسب گذاری چندین تصویر هدف برای هر query را تسهیل کرده اند و گزارش می کنند که برای هر query به طور متوسط ۴/۵۳ Ground Truth وجود دارد [10]. علاوه بر این، در CIRCO کل مجموعه^۶ ۱۲۰ هزار تصویر COCO به عنوان مجموعه^۷ اندیس استفاده می شود که تعداد Distractor ها را به طور چشم گیری نسبت به مجموعه^۸ تست CIRR (با حدود ۲ هزار تصویر) افزایش می دهد (همان، ص. ۶، خط ۴۴). این دو عامل یعنی وجود Ground Truth های متعدد و اندازه^۹ بزرگ مجموعه^{۱۰} اندیس، CIRCO را از منظر ارزیابی، به یک بنچمارک واقع بینانه تر و چالش برانگیزتر برای مدل های ZS-CIR تبدیل می کنند.

از نظر معیارهای ارزیابی نیز بین دو دیتاست تفاوت وجود دارد. در حالی که CIRR (و Fashion-IQ) عمدتاً بر اساس Recall@K روی مجموعه^{۱۱} کامل اندیس ارزیابی می شوند، CIRCO به سبب داشتن چندین Ground Truth برای هر query بر اساس میانگین دقت متوسط^{۱۲} ارزیابی می شود [22]. mAP با در نظر

¹ Composed Image Retrieval on Common Objects in Context

² mean Average Precision – mAP

گرفتن موقعیت نسبی تمامی Ground Truth ها در لیست نتایج، ارزیابی جامع تری از کیفیت رتبه بندی ارائه می کند و برای سناریوهایی که در آن ها بیش از یک پاسخ صحیح وجود دارد، نسبت به Recall@K مناسب تر است.

با وجود این مزایا، CIRCO نیز بدون محدودیت نیست. CoLLM اشاره می کند که اگرچه CIRCO در جهت کاهش ابهام و مسئله Ground Truth یکتا گام برداشته است، اما تلاش های آن از نظر مقیاس همچنان محدود است و این ابهام در بنچمارک ها می تواند ارزیابی و مقایسه معنادار مدل ها را دشوار سازد (CoLLM، ص. ۲، خط ۲۷). از این رو، در سال های اخیر، پژوهش هایی مانند CoLLM علاوه بر استفاده از بنچمارک هایی همچون CIRCO و CIRR برای ارزیابی نهایی، دیتاست های آموزشی عظیمی نظیر Multi-Text CIR (MTCIR) با چند میلیون زوج تصویر و متن های نسبی نیز معرفی کرده اند تا کمبود داده آموزشی برطرف شود و مدل ها در مواجهه با طیف متنوع تری از ترکیبات تصویری و زبانی آموزش ببینند [22].

در مجموع، می توان CIRR را به عنوان اولین دیتاست CIR در دامنه باز با تصاویر واقعی و معیار ارزیابی ویژه RecallSubset@K و CIRCO را به عنوان اولین دیتاست CIR با Ground Truth های متعدد و اندیس گسترده مبتنی بر COCO در نظر گرفت. این دو دیتاست، در کنار بنچمارک های دامنه محوری مانند Fashion-IQ و همچنین دیتاست های آموزشی بزرگی نظیر MTCIR، مجموعه ای از ابزارهای ارزیابی را شکل می دهند که امکان تحلیل عملکرد مدل های زبان-بینایی و روش های بازیابی تصویر ترکیبی را در سناریوهای متنوع و نزدیک به کاربردهای دنیای واقعی فراهم می آورند.


12-2- روش های مبتنی بر مدل های چندوجهی و زبان محور در قطعه بندی

تصویر¹

تشخیص اشیاء (Object detection)

تشخیص اشیاء (Object detection) فعالیتی متفاوت اما بسیار مرتبط با فعالیت دسته بندی تصاویر است. برای دسته بندی تصاویر، کل تصویر بعنوان ورودی استفاده میشود و برچسب دسته اشیاء درون تصویر تخمین زده میشوند. برای تشخیص اشیاء (object detection) علاوه بر نمایش اطلاعات مربوط به حضور یک

کلاس داده شده , همانطور که در شکل ۱۹ نشان داده شده است ما نیازمند این هستیم که مکان نمونه (یا نمونه های) مورد نظر در تصویر را نیز تخمین بزنیم. یک پنجره تشخیص (detection window) در صورتی صحیح در نظر گرفته میشود که محفظه خروجی دور نمونه (outputted bounding box) یافت شده اشتراک زیادی با شی هدف ما داشته باشد (معمولاً بیشتر از ۵۰٪ باشد)



• شناسایی اشیا توسط RCNN

دیتاست های چالش برانگیز PASCAL VOC, فراگیرترین دیتاست برای ارزیابی تشخیص اشیا (object detection) است. این دیتابیس شامل ۲۰ دسته یا کلاس است. در حین فاز آزمایش یک الگوریتم باید بتواند بدرستی محفظه های شناسایی اشیا (bounding boxes) مربوط به هر کلاس را پیش بینی کند.(یعنی با کشیدن یک مربع یا مستطیل بدور هر شکل موجود در تصویر بگوید هر تصویر به کدام دسته یا کلاس تعلق دارد). در این بخش ما پیشرفت های اخیر در روش های deep learning برای تشخیص اشیا را بر اساس دستاوردهای آنها در VOC 2007 و VOC 2012 شرح میدهم. پیشرفت های مرتبط در جدول ۵ نمایش داده شده اند.

Voc2012			Voc2007		داده آموزشی	روش
mAP(VGG-Net)	mAP(AlexNet)		mAp(A/C-Net)	mAP(VGG-Net)		
-	-	-	-	۲۹,۰۹%	۰۷	DPM
-	-	-	-	۳۰,۱۴%	۱۲	DerecorNet
-	-	-	-	۲۹,۲۲%	۱۲	DeepMultiBox
-	-	-	۶۲,۲%	۵۴,۲%	۰۷	RCNN
	-	-	۶۶,۰%	۵۸,۵%	۰۷	RCNN+BB
	۵۹,۲%	۴۹,۶%	-	-	۱۲	RCNN
	۶۲,۴%	۵۳,۳%	-	-	۱۲	RCNN+BB
			۶۰,۴%	۵۵,۲%	۰۷	SPP-NET
			۶۴,۶%		۰۷+۱۲	SPP-NET
			۶۳,۱%	۵۹,۲%	۰۷	SPP-NET + BB
	۶۵,۷%	-	۶۶,۹%	-	۰۷	FCRN
	۶۸,۴%	-	۷۰,۰%	-	۱۲++۰۷	FCRN
			۶۹,۹%	۵۹,۹%	۰۷	RPN
	۶۷%				۱۲	RPN
			۷۳,۲%	-	۰۷+۱۲	RPN
	۷۰,۴%			-	۱۲++۰۷	RPN
	۶۹,۱%	-	۷۴,۹%	-	۰۷	MR_CNN
	۷۰,۷%	-	-	-	۱۲	MR_CNN
	-		۶۶,۵%		۰۷	FGS
	۶۶,۴%		۶۸,۵%		۰۷	FGS +BB
	۶۷,۶%		۷۱,۸%	۶۲,۹%	۰۷+۱۲	NoC
	۶۸,۸%		۷۳,۳%		۰۷+۱۲	NoC+BB

”: VOC07\۲p۰۷”: VOC2 trainval; “\۱۲”: VOC07 trainval; “۰۷Note: Training data: “

”: VOC07 trainval and test union with\۲p۰۷trainval union with VOC12 trainval; “

VOC12 trainval; BB: bounding box regression; A/C-Net: approaches based on

AlexNet or Clarifai (54); VGG-Net: approaches based on VGG-Net(50) سابقاً، قبل از فرا رسیدن موج یادگیری عمیق، Deformable Part Model (DPM)(136) موثرترین روش برای تشخیص اشیاء بود. این روش از مدل های deformable part بهره میبرد و اشیاء را در تمامی مقیاس ها و مکان های تصویر به شیوه ای جامع تشخیص میداد. بعد از ادغام یکسری روش post-processing مثل bounding box prediction و context rescoring، این مدل توانست به میانگین دقت ۲۹،۰۹٪ در مجموعه آزمایش VOC 2007 دست پیدا کند. از آنجایی که روش های یادگیری عمیق (خصوصاً روش های مبتنی بر شبکه عصبی کانولوشن) توانسته بودند به کارایی های سطح بالایی در فعالیتهای دسته بندی تصاویر دست پیدا کنند، محققان شروع به استفاده از آنها در حوزه تشخیص اشیاء کردند.

یک روش یادگیری عمیق ابتدایی برای تشخیص اشیاء توسط Szegedy et al.(137) ارائه شد. در این مقاله الگوریتمی بنام DetectorNet معرفی شد که آخرین لایه AlexNet(21) را با یک لایه رگرسیون (regression layer) جایگزین میکرد. این الگوریتم توانست مکان اشیاء را بخوبی بدست آورده و به نتایج قابل رقابت با پیشرفته ترین الگوریتم های آن زمان در VOC 2007 دست پیدا کند. به منظور پشتیبانی از چندین نمونه از یک شی در تصویر، DeepMultiBox(138) نیز یک مدل شبکه عصبی (-saliency inspired neural network) را به نمایش گذاشت.

یک طرح کلی برای سیستم های تشخیص اشیاء موفق فعلی ایجاد منبع بزرگی (large pool) از محفظه های کاندید (candidate boxes) و دسته بندی آنها با استفاده از ویژگی های CNN است. بهترین نمونه این روش، طرح RCNN است که توسط Girshick et al. (31) ارائه شد. این طرح از جستجوی انتخابی (139) Selective search برای ایجاد پیشنهاد اشیاء استفاده میکرد و ویژگی ها شبکه عصبی کانولوشن را برای هر پیشنهاد استخراج میکرد. این ویژگی ها سپس به یک دسته بندی کننده (کلاسیفایر) SVM تغذیه شده تا مشخص شود پنجره های کاندید مربوطه شامل شی مورد نظر هستند یا خیر. RCNN ها Benchmark را تا حد بسیار زیادی بهبود دادند و به مدل پایه برای بسیاری از الگوریتم های نویدبخش در این زمینه تبدیل شدند. (۲۱، ۵۵، ۵۶، ۵۸، ۶۰).

الگوریتم های مشتق شده از RCNN ها بطور کلی به دو دسته تقسیم میشوند. دسته اول بدنبال تسریع فرآیند آموزش و آزمایش است. هرچند RCNN دقت بسیار عالی در تشخیص اشیاء دارد اما بواسطه اینکه بطور جداگانه هر پیشنهاد شی ای را انتخاب و بعد پردازش میکند از لحاظ پردازشی بسیار سنگین است. در نتیجه بعضی از الگوریتم های معروف که بدنبال بهینگی این مدل بودند پدیدار شدند. الگوریتمهای SPP-net(46), FRCN(55), RPN(56), YOLO(140), و ... از این دسته اند. دسته دوم عمدتاً بدنبال بهبود دقت RCNN ها هستند. کارایی طرح "recognition using regions" یا تشخیص از طریق ناحیه ها بشدت به کیفیت فرضیه شی وابسته است. در حال حاضر، الگوریتم های پیشنهاد شی زیادی وجود دارد که BING, category-independent (142) object proposals, selective search(139), objectness(141), et al (143) و edge boxes(144) نمونه هایی از این دست هستند.

این طرح ها و روشها بصورت جامع در (۱۴۵) مورد ارزیابی قرار گرفتند. اگرچه این روش ها در پیدا کردن مکانهای تقریبی اشیاء خوب هستند اما معمولاً قادر به مکان یابی دقیق تمام شی از طریق یک محفظه تنگ (tight bounding box) نیستند. که همین مسئله باعث ایجاد بزرگترین منبع خطای تشخیص در آنها شده است. (۱۴۶, ۱۴۷) بنابر این برای حل این مشکل روشهای زیادی بوجود آمدند تا به تصحیح این مکان یابی ضعیف پردازند.

یک جهت مهم در این روش ها ترکیب آنها با روش های قطعه بندی معنایی (semantic segmentation) است. (۵۸, ۶۰, ۱۴۸) بعنوان مثال روش SDS پیشنهاد شده توسط Hariharan et al.(60) از قطعه بندی (segmentation) برای حذف (mask-out) پس زمینه در یک عملیات تشخیص استفاده میکند که این کار باعث بهبود کارایی در تشخیص اشیا (از ۴۹,۶٪ به ۵۰,۷٪ بدون رگرسیون محفظه تشخیص (bounding box regression)) شد. از طرف دیگر روش UDS(148) تشخیص اشیاء و فرایند قطعه بندی معنایی را در یک چارچوب با اجبار ثبات آنها و ادغام اطلاعات متنی، باهم ترکیب کرد. این مدل کارایی خوبی در هر دو فعالیت از خود نشان داد. کارهای مشابه مثل segDeepM که توسط Zhu et al.(58) ارائه شد و MR_CNN در(۵۷) هم که از قطعه بندی به همراه مدارک اضافی برای افزایش دقت در تشخیص اشیاء استفاده کردند نیز وجود دارند. روشهای دیگری هم وجود دارند که سعی میکنند بصورت های دیگری به مکان یابی دقیقی دست پیدا کنند. بعنوان مثال FGS(59) از طریق ۲ روش به حل این مشکل پرداخته است. ابتدا یک الگوریتم سرچ بهینه (fine-grained) برای بهینه سازی تکراری مکان توسعه داد و سپس یک دسته بندی کننده (کلاسیفایر) شبکه عصبی کانولوشن را به همراه یک هدف SVM ساخت یافته

(structured SVM objective) برای بالانس کردن بین دسته بندی و مکان یابی آموزش داد. ترکیب این روشها کارایی امیدوارکننده ای در دیتاست های چالش برانگیز از خود نشان داده است.

گذشته از تلاشهای صورت گرفته در مکان یابی اشیاء، چارچوب NoC در (۱۴۹) تلاش میکند تا تلاشها را بسمت دسته بندی اشیاء تکامل دهد. بجای شبکه پرسپترون چند لایه این مقاله ساختارهای NoC مختلفی را جهت پیاده سازی دسته بندی کننده اشیاء امتحان کرده است.

جمع آوری مقدار زیادی از برچسب های سطح تصویر نسبت به جمع آوری داده تشخیص و بعد برچسب گذاری آن با استفاده از محفظه های شناسایی (bounding box) دقیق بسیار ارزانتر و ساده تر است. بنابر این یک چالش اصلی در مقیاس پذیری (scaling) تشخیص اشیاء، دشواری بدست آوردن تصاویر برچسب گذاری شده برای تعداد زیادی دسته است. (۱۵۰، ۱۵۱). Hoffman et al. (151) الگوریتم Deep Detection Adaption (DDA) را برای یادگیری تفاوت بین دسته بندی تصاویر و تشخیص اشیاء، با تبدیل دسته بندی کننده های (کلاسیفایرها) دسته ها به detector ها بدون داده های حاشیه نویسی شده با محفظه شناسایی (bounding box annotated data) ارائه داد. این روش پتانسیل تشخیص هزاران دسته که فاقد تفسیر های (حاشیه نویسی) محفظه شناسایی هستند را دارد.

دو روش نوید بخش و مقیاس پذیر (۱۵۲) ConceptLearner و (153) BabyLearning هستند. هردو اینها قادر به یادگیری دقیق مفهوم یابها (concept detectors) بدون حاشیه نویسی فراوان مفاهیم بصری هستند. از آنجایی که جمع آوری تصاویر برچسب گذاری شده ضعیف ارزان است، ConceptLearner یک الگوریتم max-margin hard instance learning را جهت کشف مفاهیم بصری از مجموعه تصاویر برچسب گذاری شده نوید دار توسعه داد. در نتیجه، این روش پتانسیل یادگیری مفاهیم از وب را بصورت مستقیم دارد. از طرف دیگر روش Baby- Learning (153) تعامل یک نوزاد با دنیای فیزیکی را شبیه سازی کرده و میتواند نتایج قابل مقایسه ای را با روش های مبتنی بر آموزش کامل به همراه تعداد کمی نمونه برای هر دسته از اشیاء و تعداد زیادی ویدئو بدون برچسب آنلاین بدست آورد. در جدول شماره ۴ علاوه بر خود الگوریتم، چندین فاکتور که میتوانند باعث بهبود کارایی شوند نشان داده شده است (۱) مجموعه آموزشی بزرگ (۲) مدل پایه عمیقتر (۳) رگرسیون محفظه شناسایی)

از مقاله پیشینه و مروری بر روشهای مختلف یادگیری عمیق (با محوریت Computer Vision)

بخش بندی تصویر (Image Segmentation)

2.1.1 بخش بندی کلاسیک (Classic Segmentation)

بخش بندی تصویر یک وظیفه ی بنیادی در بینایی کامپیوتر (computer vision) است که یک تصویر دیجیتال را با اختصاص هر پیکسل به یک کلاس یا شیء، به چندین بخش تقسیم می کند. به طور سنتی، بخش بندی شامل سه وظیفه ی اصلی است: معنایی (semantic)، نمونه ای (instance) و همه نگار (panoptic).

بخش بندی معنایی (Semantic Segmentation) [69], [70], [71], [72] هر پیکسل را به یک برچسب کلاس معنایی از پیش تعریف شده اختصاص می دهد.

بخش بندی نمونه ای (Instance Segmentation) [73], [74], [75] نمونه های مختلف یک کلاس واحد را از هم جدا می کند.

بخش بندی همه نگار (Panoptic Segmentation) که توسط [76] پیشنهاد شد، بخش بندی معنایی و نمونه ای را ترکیب کرده تا درک جامع تری از صحنه ارائه دهد.

پژوهشگران این وظایف را در مطالعات گذشته به طور کامل بررسی کرده اند. با توجه به یکسان بودن عملیات این وظایف در سطح پیکسل، بسیاری از مطالعات تلاش کرده اند از یک چارچوب یکپارچه برای ارائه ی راهکارهایی برای هر سه نوع بخش بندی به صورت همزمان استفاده کنند؛ مانند K-Net [77]، MaskFormer [78] و Mask2Former [79].

2.1.2 بخش بندی تعاملی (Interactive Segmentation)

بخش بندی تعاملی (Interactive Segmentation) [80] یک وظیفه ی خاص بخش بندی است که از اطلاعات ناشی از تعامل کاربر بهره می گیرد. با وجود اینکه این موضوع یک چالش دیرینه است، پیشرفت قابل توجهی در آن حاصل شده است. معمولاً کاربر ورودی اولیه ای مانند نقاط (points)، خطوط (strokes) یا جعبه های مرزی (bounding boxes) فراهم می کند تا مکان و شکل تقریبی شیء را مشخص کند. سپس الگوریتم با استفاده از بازخورد کاربر، بخش بندی را به صورت تکراری اصلاح می کند؛ برای نمونه با تصحیح نواحی اشتباه برچسب خورده یا افزودن بخش های جاافتاده.

بخش بندی تعاملی در بسیاری از کاربردهایی که نیازمند استخراج دقیق شیء هستند مفید است؛ مانند تحلیل تصاویر پزشکی (medical image analysis) [81], [82], [83]، ویرایش عکس (photo editing)

[84] و نشانه گذاری داده (data annotation) [85], [86].

مقاله A Comprehensive Survey on Segment Anything Model for Vision and Beyond

1-12-2- محدودیت های روش های کلاسیک قطعه بندی تصویر

قطعه بندی تصویر یکی از مسائل بنیادی در حوزه بینایی ماشین¹ محسوب می شود که هدف آن تقسیم یک تصویر به نواحی معنادار² یا اشیاء موجود در صحنه است. در حالت خاص، قطعه بندی معنایی³ به فرآیندی گفته می شود که در آن به هر پیکسل تصویر یک برچسب معنایی⁴ اختصاص داده می شود. در سال های اخیر، با ظهور شبکه های عصبی عمیق⁵ و به ویژه شبکه های کانولوشنی⁶، روش های مبتنی بر یادگیری عمیق به رویکرد غالب برای حل مسئله قطعه بندی تبدیل شده اند.

با وجود پیشرفت های قابل توجه در این حوزه، اغلب روش های کلاسیک قطعه بندی معنایی دارای محدودیت های ساختاری مهمی هستند. یکی از مهم ترین این محدودیت ها این است که مدل ها معمولاً برای مجموعه ای ثابت و از پیش تعریف شده از کلاس ها (Fixed Set of Classes) آموزش داده می شوند. به بیان دیگر، مدل در مرحله آموزش با مجموعه ای مشخص از برچسب ها (مانند dog, car, person و غیره) آموزش می بیند و در زمان آزمون (Inference) تنها قادر است همان کلاس ها را شناسایی و قطعه بندی کند [26]. بر اساس این دیدگاه، اگر در یک کاربرد عملی نیاز باشد که مدل قادر به شناسایی کلاس های جدید باشد یا پرسش های پیچیده تری درباره تصویر مطرح شود، لازم است مدل مجدداً با مجموعه داده جدید آموزش داده شود. این فرایند که به بازآموزی⁷ مدل معروف است، معمولاً نیازمند جمع آوری داده های برچسب گذاری شده⁷ جدید و صرف منابع محاسباتی قابل توجه است [27].

¹ Computer Vision

² Meaningful Regions

³ Semantic Segmentation

⁴ Semantic Label

⁵ Deep Neural Networks

⁶ Convolutional Neural Networks

⁷ Retraining

از منظر کاربردی، این مسئله چالش های متعددی ایجاد می کند. نخست آن که فرایند برچسب گذاری پیکسلی¹ بسیار زمان بر و پرهزینه است، زیرا برای هر تصویر باید ماسک دقیق نواحی مختلف توسط انسان تولید شود. دوم آن که در بسیاری از کاربردهای واقعی، مجموعه مفاهیمی که کاربر ممکن است به آن ها علاقه داشته باشد از پیش قابل پیش بینی نیست. برای مثال، کاربر ممکن است بخواهد ناحیه ای از تصویر را بر اساس یک ویژگی خاص (مانند «اشیاء قرمز رنگ»، «سطوح قابل نشستن» یا «درهای باز») قطعه بندی کند؛ مفاهیمی که لزوماً در دیتاست آموزشی اولیه وجود نداشته اند.

بنابراین، وابستگی شدید مدل های کلاسیک به مجموعه کلاس های ثابت، مقیاس پذیری² و انعطاف پذیری³ این سیستم ها را در سناریوهای واقعی محدود می کند. این محدودیت ها باعث شده است پژوهشگران به سمت رویکردهای جدیدی حرکت کنند که بتوانند بدون نیاز به بازآموزی کامل مدل، مفاهیم جدید را در زمان اجرا تعریف کنند.

یکی از مهم ترین جهت گیری های پژوهشی در این زمینه، توسعه مفهوم قطعه بندی مبتنی بر پرامپت⁴ یا قطعه بندی پرامپت پذیر⁵ است. در این چارچوب، کاربر می تواند در زمان آزمون، با استفاده از یک پرامپت⁶—مانند یک توصیف متنی، یک نقطه، یک جعبه مکانی⁷ یا حتی یک تصویر مرجع—مشخص کند که کدام ناحیه از تصویر باید قطعه بندی شود. این رویکرد امکان تعریف پویا و انعطاف پذیر مفاهیم جدید را فراهم می کند و وابستگی مدل به مجموعه کلاس های ثابت را کاهش می دهد.

در سال های اخیر، چندین رویکرد مهم در این حوزه معرفی شده اند که از جمله آن ها می توان به [28]⁸ برای قطعه بندی پرامپت پذیر در مقیاس بزرگ، CLIPSeg برای قطعه بندی مبتنی بر پرامپت های متنی و تصویری، و GroupViT برای یادگیری قطعه بندی معنایی تنها با استفاده از نظارت متنی اشاره کرد. این روش ها نشان می دهند که ترکیب مدل های چندوجهی⁹، نظارت زبانی¹⁰ و یادگیری در مقیاس بزرگ¹¹ می تواند پارادایم

¹ Pixel-level Annotation

² Scalability

³ Flexibility

⁴ Prompt-based Segmentation

⁵ Promptable Segmentation

⁶ Prompt

⁷ Bounding Box

⁸ Segment Anything Model

⁹ Multimodal Models

¹⁰ Language Supervision

¹¹ Large-scale Learning

سنتی قطعه‌بندی تصویر را به سمت سیستم‌های انعطاف‌پذیرتر و تعمیم‌پذیرتر سوق دهد.

2-12-2- قطعه بندی پرامپت پذیر و مدل های پایه قطعه بندی : Segment Anything (SAM)

1-2-12-2- تعریف وظیفه قطعه بندی پرامپت پذیر¹

با گسترش مدل های پایه² در حوزه های مختلف هوش مصنوعی، پژوهشگران تلاش کرده‌اند مفاهیم مشابهی را در حوزه قطعه‌بندی تصویر نیز توسعه دهند. در این راستا، مقاله [28] چارچوب جدیدی تحت عنوان قطعه‌بندی پرامپت‌پذیر³ معرفی می‌کند که هدف آن ایجاد مدلی عمومی برای قطعه‌بندی است که بتواند تنها با دریافت یک پرامپت، ناحیه مورد نظر را از تصویر استخراج کند.

در این چارچوب، مسئله قطعه‌بندی به صورت زیر تعریف می‌شود: ورودی شامل یک تصویر و یک پرامپت قطعه‌بندی⁴ است و مدل باید یک ماسک قطعه‌بندی⁵ معتبر تولید کند [28].

بر اساس این تعریف، پرامپت می‌تواند شامل انواع مختلفی از اطلاعات باشد، از جمله:

- اطلاعات مکانی (Spatial Prompts) مانند نقطه (Point) یا جعبه محدودکننده (Bounding Box)
- اطلاعات ساختاری یا نشانه‌های بصری
- توصیف‌های متنی⁶

ویژگی مهم این چارچوب آن است که مدل باید حتی در شرایطی که پرامپت ابهام‌آمیز (Ambiguous) است نیز یک خروجی معتبر تولید کند. به عبارت دیگر، اگر پرامپت بتواند به چند شیء مختلف در تصویر اشاره کند، مدل باید حداقل یکی از آن‌ها را به طور معقول قطعه‌بندی کند.

این تعریف، قطعه‌بندی تصویر را از یک مسئله بسته با مجموعه کلاس‌های محدود به یک مسئله تعاملی (Interactive Task) تبدیل می‌کند که در آن کاربر می‌تواند در زمان اجرا مشخص کند چه ناحیه‌ای باید

¹ Promptable Segmentation

² Foundation Models

³ Promptable Segmentation

⁴ Segmentation Prompt

⁵ Segmentation Mask

⁶

استخراج شود.

2-12-2-2 SAM به عنوان مدل پایه برای قطعه بندی (Foundation Model)

در ادامه این چارچوب مفهومی، مقاله [28] مدلی به نام Segment Anything Model (SAM) معرفی می کند که هدف آن ایفای نقش یک مدل پایه برای قطعه بندی تصویر¹ است.

مدل های پایه معمولاً بر روی مجموعه داده های بسیار بزرگ آموزش داده می شوند و می توانند برای طیف وسیعی از وظایف پایین دستی² مورد استفاده قرار گیرند. در مورد SAM، هدف این است که یک مدل عمومی برای قطعه بندی ایجاد شود که بتواند با استفاده از مهندسی پرامپت³ به انواع مختلف وظایف قطعه بندی تعمیم پیدا کند.

طراحی پروژه Segment Anything بر سه مؤلفه اصلی استوار است:

۱. وظیفه⁴

تعریف وظیفه قطعه بندی پرامپت پذیر که امکان تعمیم صفر-نمونه⁵ به اشیاء و دامنه های جدید را فراهم می کند.

۲. مدل⁶

معماری Segment Anything Model (SAM) که برای دریافت انواع مختلف پرامپت و تولید ماسک های قطعه بندی طراحی شده است.

۳. داده⁷

یک موتور تولید داده⁸ که برای ایجاد یک مجموعه داده بسیار بزرگ از ماسک های قطعه بندی مورد استفاده قرار گرفته است.

این طراحی سه گانه باعث می شود SAM نه تنها یک مدل جدید، بلکه یک چارچوب جامع برای توسعه

¹ Segmentation Foundation Model

² Downstream Tasks

³ Prompt Engineering

⁴ Task

⁵ Zero-shot Generalization

⁶ Model

⁷ Data

⁸ Data Engine

مدل های قطعه بندی در مقیاس بزرگ محسوب شود.

3-2-12-2-3- دیتاست SA-1B و اهمیت مقیاس داده

یکی از مهم ترین عوامل موفقیت SAM، استفاده از یک مجموعه داده بسیار بزرگ به نام SA-1B¹ است. در مقاله اصلی اشاره شده است که این دیتاست بزرگ ترین مجموعه داده قطعه بندی ایجاد شده تا زمان انتشار مقاله محسوب می شود [28].

مشخصات اصلی این مجموعه داده عبارتند از:

- بیش از ۱ میلیارد ماسک قطعه بندی (B+ segmentation masks 1)
 - حدود ۱۱ میلیون تصویر (M images 1)
 - تصاویر دارای مجوز و سازگار با الزامات حفظ حریم خصوصی²
- برای ساخت این دیتاست، پژوهشگران از یک موتور داده تعاملی (Data Engine) استفاده کردند که در آن مدل و انسان به صورت تکرارشونده با یکدیگر تعامل دارند. در این فرایند، مدل به تدریج بهبود می یابد و در عین حال تولید ماسک های جدید برای آموزش نیز تسریع می شود.
- استفاده از چنین مجموعه داده بزرگی باعث شده است SAM بتواند ویژگی های عمومی و قابل تعمیمی از ساختار تصاویر یاد بگیرد. در نتیجه، این مدل قادر است بدون آموزش اضافی، در دامنه های جدید و روی تصاویر خارج از توزیع آموزشی نیز عملکرد قابل قبولی داشته باشد.

4-2-12-2-4- قطعه بندی مبتنی بر متن و تصویر با CLIPSeg

۳.۱. قطعه بندی مبتنی بر پرامپت متنی و تصویری

یکی از رویکردهای مهم برای غلبه بر محدودیت های قطعه بندی کلاسیک، استفاده از مدل های چندوجهی است که بتوانند اطلاعات زبان طبیعی³ را در فرایند قطعه بندی وارد کنند. مقاله CLIPSeg [27] یکی از

¹ Segment Anything 1 Billion

² Privacy Respecting

³ Natural Language

نخستین تلاش ها در این راستا محسوب می شود.

در این مقاله، پژوهشگران سیستمی معرفی می کنند که قادر است بر اساس پرامپت های دلخواه در زمان آزمون، ناحیه مورد نظر در تصویر را قطعه بندی کند [27].

در این چارچوب، پرامپت می تواند به دو شکل ارائه شود:

- **پرامپت متنی**¹: یک توصیف زبانی آزاد مانند «سگ قهوه ای»، «چرخ های ماشین» یا «سطح چوبی میز».

- **پرامپت تصویری**²: یک تصویر نمونه که مفهوم مورد نظر را نشان می دهد.

این طراحی به مدل اجازه می دهد که بدون نیاز به بازآموزی، انواع مختلفی از مفاهیم را در زمان اجرا درک کرده و نواحی مرتبط با آن ها را در تصویر قطعه بندی کند.

۳.۲. مدل یکپارچه برای چند وظیفه قطعه بندی

یکی از ویژگی های مهم CLIPSeg آن است که یک مدل یکپارچه³ برای چندین وظیفه قطعه بندی ارائه می دهد [27].

این سه وظیفه عبارتند از:

۱. Referring Expression Segmentation

در این وظیفه، یک عبارت توصیفی مشخص می کند که کدام ناحیه از تصویر باید قطعه بندی شود. برای مثال، عبارتی مانند «مردی با پیراهن قرمز در سمت چپ تصویر» می تواند ناحیه خاصی را مشخص کند.

۲. Zero-shot Segmentation

در این حالت، مدل قادر است اشیائی را قطعه بندی کند که در داده آموزشی دارای برچسب پیکسلی نبوده اند، اما از طریق توصیف متنی قابل تعریف هستند.

۳. One-shot Segmentation

در این سناریو، یک نمونه تصویری از شیء مورد نظر به همراه ماسک آن به مدل ارائه می شود و مدل باید همان مفهوم را در تصاویر دیگر شناسایی و قطعه بندی کند.

وجود یک مدل مشترک برای این وظایف مختلف نشان می دهد که پرامپت محور بودن می تواند به عنوان یک

¹ Text Prompt

² Prompt-driven Modeling

³ Unified Model

چارچوب عمومی برای حل مسائل مختلف قطعه‌بندی مورد استفاده قرار گیرد.

۳.۳. معماری CLIPSeg

CLIPSeg بر پایه مدل CLIP¹ ساخته شده است و از فضای تعبیه شده مشترک تصویر و متن برای شرطی‌سازی فرایند قطعه‌بندی استفاده می‌کند [27].

معماری CLIPSeg به‌طور کلی از دو بخش اصلی تشکیل شده است:

۱. بک‌بون CLIP²

این بخش مسئول استخراج ویژگی‌های چندوجهی از تصویر و پرامپت است. CLIP یک فضای تعبیه شده مشترک³ برای تصویر و متن ایجاد می‌کند که در آن مفاهیم مشابه در نزدیکی یکدیگر قرار می‌گیرند.

۲. دیکودر مبتنی بر ترنسفورمر⁴

برای تبدیل نمایش‌های سطح بالا به پیش‌بینی‌های پیکسلی، یک دیکودر ترنسفورمری به مدل اضافه می‌شود که می‌تواند خروجی‌های CLIP را به پیش‌بینی چگال (Dense Prediction) در سطح پیکسل تبدیل کند [27].

به این ترتیب، مدل می‌تواند از فضای تعبیه شده مشترک CLIP برای پردازش هم‌زمان پرامپت‌های متنی و تصویری استفاده کند.

۳.۴. فرموله‌سازی دودویی قطعه‌بندی

در CLIPSeg مسئله قطعه‌بندی ابتدا به‌صورت یک مسئله قطعه‌بندی دودویی⁵ تعریف می‌شود [27]. در این چارچوب، مدل باید تشخیص دهد که کدام پیکسل‌ها به پیش‌زمینه منطبق با پرامپت⁶ تعلق دارند و کدام پیکسل‌ها به پس‌زمینه⁷ مربوط هستند.

با این حال، این ساختار می‌تواند به قطعه‌بندی چندبرچسبی⁸ نیز تعمیم یابد، به‌ویژه در سناریوهایی مانند

¹ Contrastive Language-Image Pretraining

² CLIP Backbone

³ Joint Embedding Space

⁴ Transformer-based Decoder

⁵ Binary Segmentation

⁶ Prompt-matching Foreground

⁷ Background

⁸ Multi-label Segmentation

Pascal Zero-shot Segmentation که چندین کلاس ممکن است همزمان در تصویر حضور داشته باشند.

۴. قطعه‌بندی معنایی مبتنی بر نظارت متنی: GroupViT

مقاله [26] رویکردی متفاوت برای یادگیری قطعه‌بندی ارائه می‌دهد. در این روش، هدف آن است که بدون استفاده از برچسب‌های پیکسلی، تنها با استفاده از نظارت متنی^۱ و یادگیری کانتراستیو^۲، ساختارهای معنایی تصویر استخراج شوند.

برای این منظور، مدل Grouping Vision Transformer (GroupViT) معرفی شده است که در آن توکن‌های بصری به صورت سلسله‌مراتبی گروه‌بندی می‌شوند. مکانیزم خودتوجهی سراسری^۳ در ترنسفورمرها این امکان را فراهم می‌کند که توکن‌های مختلف تصویر با یکدیگر تعامل داشته باشند و به تدریج در قالب سگمنت‌های بزرگ‌تر سازمان‌دهی شوند.

در این معماری، یک ماژول گروه‌بندی^۴ در هر مرحله توکن‌های کوچک‌تر را به سگمنت‌های بزرگ‌تر ادغام می‌کند. این سگمنت‌ها دارای شکل‌های نامنظم هستند و به‌طور پویا برای هر تصویر تشکیل می‌شوند. در نهایت، خروجی سگمنت‌ها با استفاده از یک تابع زیان کانتراستیو تصویر-متن^۵ با نمایش‌های متنی مقایسه می‌شود.

نتایج تجربی نشان می‌دهد که این رویکرد حتی بدون استفاده از برچسب‌های پیکسلی نیز قادر است عملکرد رقابتی در معیار میانگین تقاطع بر اجتماع (Mean Intersection over Union – mIoU) ارائه دهد:

“GroupViT achieves 48.1% mIoU on the PASCAL VOC 2012 and 22.4% mIoU on PASCAL Context datasets.”

[26] این نتایج نشان می‌دهد که نظارت زبانی در مقیاس بزرگ می‌تواند به‌عنوان جایگزین یا مکملی برای برچسب‌گذاری پیکسلی مورد استفاده قرار گیرد.

جدول (2-1) به صورت نمونه ارائه شده است.

¹ Text Supervision

² Contrastive Learning

³ Global Self-Attention


⁴ Grouping Module

⁵ Image-Text Contrastive Loss

جدول (2-1) نتیجه بررسی پرسش نامه ها در ارتباط با عوامل موثر

ردیف	عوامل موثر	درصد
1	احساس تعلق به سازمان	95/1
2	نقش مدیریت سازمان	87/7
3	عوامل درون سازمانی	82/9
4	برگزاری دوره های آموزشی	82/9

نمودار (2-1) به صورت نمونه ارائه شده است.



نمونه شکل

متن

$$\frac{dX}{dt} = \mu X - DX \quad (1-2)$$

که در آن X (kg/m³) غلظت توده سلولی، μ (h⁻¹) شدت رشد ویژه و D (h⁻¹) شدت رقیق سازی می باشد.

2-13- مروری بر ادبیات موضوع

ارائه ی تمام نتایج به دست آمده توسط دیگر محققان در چند سال اخیر در دنیا، همراه با ذکر مراجع است (حدود 20 صفحه).

14-2- نتیجه گیری

در نتیجه گیری آخر فصل، با توجه به بررسی انجام شده بر روی مراجع تحقیق، افق های تازه ای که پیش روست یا خلأ های تحقیقاتی بیان می شود.

فصل دوم این پایان نامه مروری جامع بر مفاهیم، مدل ها و رویکردهای نوین در حوزه **بینایی-زبانی (Vision-Language)** ارائه کرد؛ حوزه ای که به دلیل رشد سریع مدل های پایه (Foundation Models)، امروزه به یکی از محوری ترین مباحث پژوهشی در بینایی ماشین تبدیل شده است. در این فصل نشان دادیم که چگونه همگرایی دانش بینایی و زبان، چارچوب های جدیدی را برای حل مسائلی همچون **قطعه بندی تصویر، بازیابی تصویر ترکیبی (CIR)** و **درک چندرسانه ای (Multimodal Understanding)** ایجاد کرده است.

در بخش نخست فصل، مدل های پایه ای مانند **CLIP** معرفی شدند که توانستند با استفاده از نظارت زبان طبیعی و یادگیری کانتراستیو، فضای تع **嵌** مشترکی برای تصویر و متن ایجاد کنند (Radford et al., *Learning Transferable Visual Models from Natural Language Supervision*). این مفهوم به عنوان زیربنای بسیاری از مدل های پیشرفته تر—از جمله **BLIP**، **CLIPSeg**، **CoLLM** و **Qwen-VL**—مورد استفاده قرار گرفته است. بررسی مدل **BLIP** نشان داد که چگونه ترکیب معماری **MED** و اهداف آموزشی چندگانه (**ICML**، **ITM**، **ITC**) منجر به مدل های چندرسانه ای مؤثرتر برای تولید و بازیابی تصویر-متن می شود (Li et al., *BLIP: Bootstrapping Language-Image Pretraining*).

در ادامه، رویکردهای ویژه حوزه **بازیابی تصویر ترکیبی (Composed Image Retrieval)** بررسی شد. چالش اصلی **CIR—that is**، ترکیب پرسش تصویری و متنی برای یافتن تصویر هدف—به دلیل هزینه زیاد داده های سه تایی (**Image-Text-TargetImage**)، نیازمند راه حل های مبتنی بر مهارت تعمیم صفر-نمونه و مدل های ترکیبی پیش آموزش دیده است. روش هایی مانند **Pic2Word** و **CoLLM** نشان می دهند که چگونه می توان از توان مدل های چندوجهی برای انجام **CIR** بدون تکیه بر داده های پرهزینه استفاده کرد (*CoLLM: A Large Language Model*؛ *Pic2Word: Mapping Pictures to Words for Zero-shot CIR*) (for Composed Image Retrieval).

در بخش های بعدی، مدل های قدرتمند خانواده **Qwen-VL** بررسی شدند. مدل **Qwen2.5-VL** به عنوان یک مدل پایه با توانایی پردازش تصویر، متن، سند و ویدئو، قابلیت هایی مانند موضع یابی دقیق شیء، تحلیل

اسناد و استدلال چندمرحله ای را فراهم می کند. در مقابل، مدل های **Qwen3-VL Embedding/Reranker** رویکردی تخصصی برای بازیابی و رتبه بندی چندرسانه ای ارائه می دهند و با بهره گیری از یادگیری کانتراستیو و معماری Cross-Encoder برای رتبه بندی دقیق، پایه ای مناسب برای سیستم های بازیابی در مقیاس بزرگ ایجاد می کنند (*Qwen2.5-VL Technical Report*; *Qwen3-VL Embedding and Reranker: A Unified Vision-Language Framework*).

در بخش پایانی فصل، تمرکز بر مسئله **قطعه بندی تصویر** قرار گرفت. ابتدا محدودیت های روش های کلاسیک بیان شد—به ویژه وابستگی آن ها به مجموعه کلاس های ثابت—که این مسئله نیاز به مدل های پرامپت پذیر و تعمیم پذیر را برجسته می کند (*CLIPSeg, p.1*). سپس مدل های پیشرفته زیر بررسی شدند:

- **SAM (Segment Anything Model)** به عنوان اولین مدل پایه **قطعه بندی** که با تعریف وظیفه **Promptable Segmentation** و اتکا بر دیتاست عظیم **SA-1B** شامل بیش از یک میلیارد ماسک، امکان **قطعه بندی عمومی** و تعمیم پذیر را فراهم کرد (*Kirillov et al., Segment Anything*, p.1–2).

- **CLIPSeg** که با استفاده از فضای تعبیه CLIP و دیکودر ترنسفورمری، **قطعه بندی مبتنی بر پرامپت های متنی** و تصویری را به صورت یکپارچه در قالب وظایفی همچون Referring Segmentation و Zero-shot Segmentation ارائه می کند (*CLIPSeg, Abstract*).
- **GroupViT** که نشان داد حتی بدون برچسب گذاری پیکسلی و تنها با نظارت متنی (Text Supervision)، امکان یادگیری سگمنت های معنایی و دستیابی به نتایج رقابتی در معیار mIoU وجود دارد (*GroupViT, Abstract*).

آنچه از مقایسه این مدل ها در فصل به دست آمد آن است که گذار از **قطعه بندی مبتنی بر کلاس های ثابت** به سمت **قطعه بندی پرامپت پذیر و متن محور** یک تحول بنیادی در این حوزه ایجاد کرده است. مدل های جدید قادرند مفاهیم جدید را در زمان اجرا براساس متن، نقطه یا تصویر مرجع تعریف کنند و این انعطاف پذیری، مسیر را برای کاربردهای تعاملی و تطبیقی در محیط های واقعی هموار کرده است. در مجموع، این فصل نشان داد که ترکیب مقیاس داده، معماری های چندرسانه ای و نظارت زبان طبیعی، بنیان مدل هایی را شکل داده است که قابلیت درک سطح بالای تصویر، بازیابی ترکیبی و **قطعه بندی تعمیم پذیر** را فراهم می کنند. این بررسی مبانی نظری و فنی لازم برای چارچوب پیشنهادی در فصول بعد، و همچنین طراحی سیستم ها و آزمایش های این پژوهش را فراهم می سازد.

نتیجه گیری فصل دوم

با توجه به بررسی انجام شده بر روی منابع و تحقیقات پیشین در حوزه مدل های بینایی-زبانی (Vision-Language Models) و بازیابی تصویر ترکیبی، می توان افق های تازه و خلأ های پژوهشی قابل توجهی را شناسایی کرد که مسیر تحقیقات آینده را روشن می سازد.

در دهه اخیر، پیشرفت های چشمگیری در توسعه مدل های پایه چندوجهی مانند **BLIP**، **CLIP**، **GroupViT**، **SAM** و **Qwen2.5-VL** مشاهده شده است. این مدل ها زمینه را برای درک مشترک تصویر و زبان و ارتقای قابلیت های یادگیری تعمیم پذیر (Generalization) فراهم کرده اند. با این حال، مرور منابع نشان داد که هنوز چالش های اساسی و فرصت های تحقیقاتی مهمی در این حوزه وجود دارد که می توان آن ها را در دو دسته اصلی زیر خلاصه کرد:

۱. افق های پژوهشی جدید

۱. تعمیم پذیری و یادگیری در سناریوهای صفر-نمونه (Zero-shot) و کم-نمونه (Few-shot):

با وجود پیشرفت های مدل هایی مانند **CLIPSeg** و **Qwen-VL**، توانایی درک و استدلال مدل ها در وظایف پیچیده تر همچنان قابل بهبود است. توسعه روش های آموزشی برای یادگیری دانش انتزاعی (Abstract Knowledge) و انتقال پذیر به دامنه های جدید (Transferable Learning) یکی از مسیرهای کلیدی آینده است.

(ارجاع: Radford et al., "Learning Transferable Visual Models from Natural Language Supervision", p.3-5)

۲. مدل های چندوجهی ترکیبی (Hybrid Multimodal Foundation Models):

جهت گیری پژوهش ها به سمت مدل های چندمدالیت همگرا (مانند **Qwen2.5-VL**) نشان می دهد که آینده یادگیری عمیق، در ادغام مدالیت های متنوع تر (صدا، ویدئو، اسناد) نهفته است. پژوهش های آینده می توانند ساختارهای سبک تر و آموزش های کارآمدتر برای این مدل ها ارائه دهند تا یادگیری همزمان متن، تصویر و سایر داده ها عملی تر شود.

(ارجاع: Qwen2.5-VL Technical Report, p.4-6)

۳. عوامل بصری تعاملی و هوشمند (Interactive Visual Agents):

مدل های بینایی-زبانی در حال حرکت به سمت عوامل تعاملی چندمرحله ای (Multi-step Agents) هستند که می توانند برنامه ریزی، استدلال و تصمیم گیری کنند. این حوزه افق گسترده ای برای ترکیب بینایی ماشین، پردازش زبان طبیعی و رباتیک فراهم می کند.

(ارجاع: *GroupViT: Semantic Segmentation Emerges from Text Supervision*, p.7-9)

4. بازیابی و سازمان دهی پیشرفته^۱ اطلاعات چندرسانه ای:

مطالعات اخیر مانند CoLLM و Pic2Word زمینه را برای بازیابی ترکیبی تصویر-متن (Composed Image Retrieval) فراهم کرده اند، اما همچنان چالش هایی در درک ترکیبات انتزاعی و روابط علی میان اجزا وجود دارد. ایجاد مدل هایی با قدرت استدلال مفهومی و درک علیت (Causality) می تواند جهت گیری جدیدی برای تحقیقات آینده باشد.

(ارجاع: *CoLLM: A Large Language Model for Composed Image Retrieval*”, p.2-3)

۲. خلأهای پژوهشی موجود

1. نبود بنچ مارک های جامع برای ارزیابی تعمیم پذیری مدل ها:

اغلب معیارهای فعلی محدود به دامنه ها و وظایف خاص اند. این مسئله مانع ارزیابی واقع بینانه^۲ توان مدل ها در محیط های دنیای واقعی می شود. طراحی بنچ مارک های چندوجهی و متنوع، خلأ مهمی در پژوهش های فعلی است.

(ارجاع: *A Decade Survey of Content-Based Image Retrieval*”, p.9-11)

2. فقدان درک علی (Causal Understanding) از روابط تصویری و متنی:

بیشتر مدل های موجود بر همبستگی ها (Correlations) تکیه دارند و توانایی در مدل سازی علی (Cause-Effect Reasoning) را ندارند. توسعه^۳ مدل هایی که بتوانند دلیل وقوع یک اتفاق و پیامد آن را درک کنند، یک حوزه^۴ باز و مهم محسوب می شود.

(ارجاع: *Diffusion Models in Vision: A Survey*”, p.12)

3. تفسیرپذیری (Interpretability) و اطمینان پذیری (Reliability):

افزایش پیچیدگی مدل های چندوجهی موجب کاهش شفافیت در تصمیم گیری آن ها شده است. ایجاد مکانیزم های شفاف سازی و شناسایی سوگیری ها (Biases) میان داده ها از خلأهای مهم پژوهشی در حوزه^۵ کاربردهای حساس است.

(ارجاع: *Universal Cross-lingual Cross-modal Vision-and-Language Pre-training*”, p.10)

4. محدودیت منابع و نیاز به مدل های سبک:

با توجه به محدودیت های محاسباتی در دستگاه های لبه (Edge Devices)، پژوهش ها باید بر فشرده سازی

مدل ها (Model Compression) و استنتاج سریع (Fast Inference) متمرکز شوند تا استفاده از مدل های چندرسانه ای در بسترهای واقعی ممکن شود.
(ارجاع: "Efficient Diffusion Policies", p.5-7)

فصل 3:

روش تحقیق

1-3- مقدمه

هدف اصلی این پژوهش، بررسی، تحلیل و ارزیابی روش های نوین بازیابی تصویر مبتنی بر محتوا¹ به کمک مدل های تصویر-زبان² است. به واسطه تحولاتی که طی سال های اخیر در حوزه مدل های یادگیری عمیق³ و مدل های چندوجهی⁴ رخ داده، سیستم های CBIR از مرحله استفاده از ویژگی های ساده و سطح پایین تصویری مانند لبه ها، بافت ها و رنگ ها عبور کرده و اکنون به سمت استفاده از نمایش های معنایی⁵ حرکت کرده اند. این نمایش ها قادرند مفاهیم عمیق و معنایی موجود در تصویر را استخراج کنند.

در استخراج ویژگی های معنایی از تصاویر و متون و استفاده از آن ها در فرآیند بازیابی تصویر است. به طور کلی، سیستم های بازیابی تصویر مبتنی بر محتوا با استخراج ویژگی های بصری⁶ از تصاویر و مقایسه آن ها با ویژگی های تصویر یا متن جستجو، تصاویر مشابه را بازیابی می کنند. در سال های اخیر مدل های تصویر-زبان مانند CLIP توانسته اند نمایش های مشترک⁷ برای تصویر و متن ایجاد کنند که دقت بازیابی را به شکل قابل توجهی افزایش می دهد [1].

در این تحقیق از روش تحقیق نرم افزارنویسی همراه با مدل سازی و ارزیابی آزمایشگاهی استفاده شده است. بدین منظور ابتدا مجموعه داده مناسب انتخاب شده، سپس مدل های تصویر-زبان برای استخراج ویژگی ها به کار گرفته شده و در نهایت عملکرد روش پیشنهادی با معیارهای استاندارد ارزیابی می شود.

این فصل به تشریح کامل روش تحقیق برای بازیابی تصویر مبتنی بر محتوا (Content-Based Image Retrieval - CBIR) با استفاده از مدل های پایه تصویر-زبان (Vision-Language Models - VLMs) می پردازد. در سناریوهای نوین بازیابی، کاربران غالباً نیاز دارند تا علاوه بر ارائه یک تصویر مرجع، تغییرات مدنظر خود را نیز به صورت متنی بیان کنند که این مسئله تحت عنوان بازیابی تصویر ترکیبی (Composed

¹ CBIR :Content-Based Image Retrieval

² VLMs :Vision-Language Models

³ Deep Learning

⁴ Multimodal Deep Learning Models

⁵ Semantic Representations

⁶ Visual Features

⁷ Joint Embedding Space

(Image Retrieval - CIR) شناخته می شود (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۳). در این پژوهش، از یک معماری مبتنی بر شبکه های عصبی عمیق شامل رمزگذارهای از پیش آموزش دیده (Pre-trained Encoders) و یک شبکه ترکیب کننده (Combiner Network) برای نگاشت مشترک ویژگی های بصری و متنی استفاده شده است.

در این فصل، روش پیشنهادی برای مسئله بازیابی تصویر مبتنی بر ترکیب تصویر مرجع و توصیف متنی ارائه می شود. مسئله مورد بررسی از نوع **Composed Image Retrieval** است که در آن کاربر علاوه بر ارائه یک تصویر مرجع، تغییر موردنظر خود را به صورت یک عبارت متنی بیان می کند. هدف سامانه، تولید یک نمایش مناسب از این ورودی ترکیبی و بازیابی تصاویر مرتبط از میان مجموعه تصاویر گالری است. در این پژوهش، یک چارچوب ارزیابی یکپارچه برای مجموعه داده CIRR توسعه داده شده است. این چارچوب امکان ارزیابی مدل های CLIP، CLIP-beta، OpenCLIP، SEARLE، و SigLIP را در یک محیط یکسان فراهم می کند. همچنین به منظور افزایش قابلیت مقایسه مدل ها، فرآیند استخراج ویژگی، ساخت پرس و جوی ترکیبی، محاسبه شباهت، رتبه بندی تصاویر و محاسبه معیارهای ارزیابی به صورت ساختاریافته پیاده سازی شده است.

در طراحی سامانه، علاوه بر ارزیابی روی کل گالری، پروتکل **CIRR subset** نیز پشتیبانی شده است. در این پروتکل، برای هر پرس و جو مجموعه ای از تصاویر عضو `img_set.members` عنوان مجموعه محدود جست و جو در نظر گرفته می شود. کد سامانه امکان اعمال این محدودیت را هنگام رتبه بندی فراهم می کند.

2-3- تعریف مسئله

در بازیابی تصویر ترکیبی، هر نمونه شامل سه مؤلفه اصلی است:

$$Q = (I_r, T, I_t)$$

که در آن:

- I_r تصویر مرجع است؛
- T توصیف متنی تغییر موردنظر است؛
- I_t تصویر هدف است.


هدف سامانه، یافتن تصویری از مجموعه گالری G است که بیشترین سازگاری را با تصویر مرجع و تغییر متنی داشته باشد:

$$I^* = \arg \max_{I_g \in G} S(I_g, Q)$$

در این پژوهش، به جای استفاده مستقیم از تصویر مرجع و متن به صورت مستقل، تلاش شده است یک نمایش مشترک از اطلاعات موجود در این دو مؤلفه ایجاد شود. این مسئله به طور ویژه در روش SEARLE مورد توجه قرار گرفته است.

3-3- چارچوب کلی سامانه پیشنهادی

معماری کلی سامانه پیاده سازی شده به صورت زیر است:



در کنار SEARLE، سه گروه دیگر از مدل ها نیز در سامانه پیاده سازی شده اند: مدل CLIP و نسخه ترکیبی آن، OpenCLIP و SigLIP. انتخاب مدل از طریق پارامتر `--models` انجام می شود و مدل های `clip`، `searle`، `open_clip`، `siglip` و `clip_beta` توسط چارچوب پشتیبانی می شوند.

1-3-3- آماده سازی و پردازش مجموعه داده CIRR

2-3-3- ساختار Annotation

در این پژوهش از ساختار annotation مجموعه داده CIRR استفاده شده است. نمونه های `train` و `validation` شامل فیلدهای `reference`، `caption`، `target_hard`، `target_soft` و `img_set` هستند. در پیاده سازی، شناسه تصویر مرجع از فیلد `reference` استخراج شده و عبارت متنی از `caption` دریافت می شود. همچنین `target_hard` به عنوان تصویر هدف اصلی و تصاویر موجود در `target_soft` به عنوان تصاویر مرتبط در نظر گرفته می شوند. مجموعه `img_set.members` نیز برای اجرای پروتکل `subset` مورد استفاده قرار می گیرد.

برای نمونه، ساختار داده به صورت مفهومی شامل موارد زیر است:

در این پژوهش از ساختار annotation مجموعه داده CIRR استفاده شده است. نمونه های `train` و `validation` شامل فیلدهای `reference`، `caption`، `target_hard`، `target_soft` و `img_set` هستند. در پیاده سازی، شناسه تصویر مرجع از فیلد `reference` استخراج شده و عبارت متنی از `caption` دریافت می شود. همچنین `target_hard` به عنوان تصویر هدف اصلی و تصاویر موجود در `target_soft` به عنوان تصاویر مرتبط در نظر گرفته می شوند. مجموعه `img_set.members` نیز برای اجرای پروتکل `subset` مورد استفاده قرار می گیرد. برای نمونه، ساختار داده به صورت مفهومی شامل موارد زیر است:

تابع `parse_cirr_sample` وظیفه تبدیل این ساختار به یک ساختار داخلی استاندارد را بر عهده دارد.

- `pairid`
- `reference`
- `caption`
- `target_hard`
- `target_soft`

- `img_set.members`
- `reference_rank`
- `target_rank`

تابع `parse_cirr_sample` وظیفه تبدیل این ساختار به یک ساختار داخلی استاندارد را بر عهده دارد.

3-3-3- نرمالسازی شناسه تصویر

وظیفه به منظور جلوگیری از ناسازگاری میان نام فایل تصویر و شناسه موجود در فایل JSON، شناسه تصاویر پیش از استفاده نرمال سازی می شوند. در این مرحله فضای خالی حذف شده و در صورت وجود پسوند فایل، پسوند از شناسه حذف می شود.

این مرحله اهمیت زیادی دارد؛ زیرا عملیات استخراج `embedding`، بازیابی تصویر و تطبیق `Ground Truth` همگی بر اساس شناسه تصویر انجام می شوند.

3-4- مدیریت فایل ها و تصاویر

برای دسترسی سریع به تصاویر، ابتدا یک `index` از مسیرهای فیزیکی تصاویر ایجاد می شود. این `index` به صورت بازگشتی در تمام زیرپوشه های `image_folder` جست و جو کرده و شناسه تصویر را به مسیر فایل مربوطه نگاشت می کند.

بنابراین فرآیند دسترسی به تصویر به صورت زیر انجام می شود:

ImageID → FilePath → Image

همچنین برای افزایش تحمل سامانه در برابر تصاویر JPEG ناقص، قابلیت بارگذاری تصاویر ناقص در Pillow فعال شده است.

تابع `load_image` پس از یافتن مسیر تصویر، فایل را باز کرده، `decode` می کند و تصویر را به فضای رنگی RGB تبدیل می نماید.

3-5- مدل CLIP

3-5-1-1 استخراج ویژگی تصویر

در مدل CLIP، تصویر ابتدا توسط preprocessing مربوط به مدل آماده شده و سپس به image encoder داده می شود. خروجی encoder به عنوان embedding تصویر در نظر گرفته شده و با استفاده از نرمال سازی L2 به یک بردار با طول واحد تبدیل می شود.

فرآیند استخراج ویژگی به صورت زیر است:

$$I \rightarrow \text{Preprocess}(I) \rightarrow \text{Encoder}_{\text{image}}(I) \rightarrow \frac{f_I}{\|f_I\|_2}$$

در پیاده سازی فعلی، مدل پیش فرض CLIP از نوع ViT-B/32 است.

3-5-1-2 استخراج ویژگی متنی

برای استخراج embedding متن، caption توسط tokenizer مدل CLIP به توالی توکن تبدیل شده و سپس توسط text encoder پردازش می شود embedding. نهایی نیز با نرمال سازی به یک بردار واحد تبدیل می شود.

به این ترتیب، امکان محاسبه شباهت کسینوسی بین embedding متن و embedding تصاویر گالری فراهم می شود.

3-6- روش ترکیب تصویر و متن در CLIP

به عنوان یک baseline، در مدل CLIP دو نوع شباهت در نظر گرفته شده است:

$$S_T(I_g) = \text{sim}(T, I_g)$$

$$S_R(I_g) = \text{sim}(I_r, I_g)$$

سپس امتیاز نهایی با استفاده از ضریب به صورت زیر محاسبه می شود:

$$S(I_g) = \alpha S_T(I_g) + (1 - \alpha) S_R(I_g)$$

این روش در تابع `evaluate_cross_modal` پیاده سازی شده است.

مقادیر مختلف از طریق پارامتر برنامه قابل آزمایش هستند:

$$\alpha \in \{0, 0.25, 0.5, 0.75, 1\}$$

که در کد به عنوان مقدار پیش فرض تعریف شده اند.

3-7- SEARLE روش

3-7-1- ایجاد نمایش پرس و جوی ترکیبی

روش اصلی مورد توجه در این پژوهش SEARLE است. در این روش، هدف تولید embedding است که به صورت همزمان محتوای تصویر مرجع و اطلاعات موجود در caption را نمایش دهد.

ابتدا embedding خام تصویر مرجع توسط CLIP استخراج شده و به شبکه SEARLE داده می شود:

سپس SEARLE از این نمایش تصویری pseudo-token تولید می کند:

این pseudo-token ها به همراه caption به encoder متنی CLIP داده می شوند. در پیاده سازی، نماد \$ به عنوان محل قرارگیری pseudo-token در prompt تعریف شده است.

prompt اصلی مورد استفاده در روش عبارت است از:

a photo of \$ {caption}

در صورت فعال کردن prompt ensemble، دو prompt دیگر نیز استفاده می شوند:

```
an image of $ {caption}
$ {caption}
```

و embedding حاصل از آن ها در فضای embedding میانگین گیری و مجدداً نرمال می شود.

3-7-2- تولید رتبه بندی توسط SEARLE

پس از تولید embedding پرس و جوی ترکیبی، شباهت آن با embedding تصاویر گالری محاسبه می شود:

$$S(I_g) = q_{SEARLE}^T v_g$$

از آنجا که embedding ها نرمال شده اند، این مقدار معادل شباهت کسینوسی است.

سپس تصاویر بر اساس این امتیاز به صورت نزولی مرتب می شوند. در فرآیند رتبه بندی، تصویر مرجع از نتایج حذف می شود.

3-8- روش SigLIP

مدل دیگری که برای مقایسه استفاده شده SigLIP است. در این روش، مدل و processor از طریق کتابخانه Transformers بارگذاری می شوند.

برای تصویر، تابع `get_image_features` و برای متن، تابع `get_text_features` مورد استفاده قرار می گیرند. خروجی هر دو encoder نرمال شده و در فضای embedding مقایسه می شوند.

به منظور افزایش سرعت پردازش تصاویر گالری، استخراج embedding تصاویر SigLIP به صورت batch انجام شده است. در پیاده سازی، batch پیش فرض برابر 32 تصویر است.

3-9- روش Clip-beta

روش CLIP-beta با هدف بررسی اثر استفاده همزمان از caption واقعی و caption تولیدشده پیاده سازی شده است.

در این روش دو نمایش ایجاد می شود:

$$q_1 = \beta T_{rel} + (1 - \beta) T_{gen}$$

و:

$$q_2 = \beta I_r + (1 - \beta) T_{gen}$$

سپس امتیاز نهایی به صورت زیر محاسبه می شود:

$$S(I_g) = \alpha sim(I_g, q_1) + (1 - \alpha) sim(I_g, q_2)$$

این ساختار مستقیماً در تابع `evaluate_clip_beta` پیاده سازی شده است .
پارامترهای و از طریق ورودی برنامه قابل تنظیم هستند و مقادیر پیش فرض آن ها شامل 0، 0.25، 0.5، 0.75 و 1 است.

10-3- پروتکل CIRRR Subset

یکی از ویژگی های مهم مجموعه داده CIRRR وجود پروتکل subset است. در این پروتکل، برای هر پرس و جو مجموعه ای از تصاویر عضو در فیلد `img_set.members` وجود دارد.

در صورت فعال بودن گزینه:

`cirr_subset--`

سامانه ranking را فقط روی تصاویر موجود در این مجموعه انجام می دهد. در غیر این صورت، تمام تصاویر موجود در گالری در نظر گرفته می شوند .
از دید ریاضی، در حالت subset داریم:

$$G_q = \{I_1, I_2, \dots, I_m\}$$

و:

$$I^* = \arg \max_{I_i \in G_q} S(I_i, Q)$$

در این فرآیند، تصویر مرجع از ranking حذف می شود تا خود تصویر مرجع به عنوان پاسخ بازیابی شده در نظر گرفته نشود.

3-11- GroundTruth و تعیین تصاویر مرتبط

برای ارزیابی مدل ها، تصاویر مرتبط از سه منبع استخراج می شوند:

1. target_hard

2. target_soft

3. positives

تابع `get_relevant_ids` ابتدا target_hard را به مجموعه تصاویر مرتبط اضافه می کند و سپس تصاویر دارای

امتیاز مثبت در target_soft و سایر positive ها را نیز در نظر می گیرد .

در نتیجه برای هر پرس و جو مجموعه زیر تعریف می شود:

$$R_q = \{I_1, I_2, \dots, I_r\}$$

که شامل تصاویر مرتبط با پرس و جوی مورد نظر است.

این طراحی اجازه می دهد معیارهای چندمشتی مانند Recall و mAP نیز به صورت مناسب محاسبه شوند.

3-12- معیار های ارزیابی

به منظور ارزیابی جامع عملکرد مدل ها، دوازده معیار مورد استفاده قرار گرفته است:

MRR

mAP@5, mAP@10, mAP@50

P@1, P@5, P@10, P@50

R@1, R@5, R@10, R@50

Precision@K -3-12-1

Precision@K نسبت تصاویر مرتبط موجود در نتیجه اول به تعداد کل نتایج بازیابی شده است:

$$P@K = \frac{|Retrieved_K \cap R_q|}{K}$$

در کد، تعداد تصاویر مرتبط موجود در top-K بر K تقسیم می شود.

Recall@K -3-12-2

Recall@K نسبت تصاویر مرتبط بازیابی شده در نتیجه اول به کل تصاویر مرتبط است:

$$R@K = \frac{|Retrieved_K \cap R_q|}{|R_q|}$$

این معیار در کد با تقسیم تعداد hit ها بر تعداد کل positive ها محاسبه می شود.

Average Precision و mAP -3-12-3

برای هر پرس و جو، Average Precision در K های 5، 10 و 50 محاسبه می شود. سپس میانگین AP تمام

پرس و جوها به عنوان mAP گزارش می شود.

تابع average_precision_at_k را در موقعیت هایی که یک تصویر مرتبط دیده شده است جمع کرده و بر تعداد تصاویر مرتبط محدود به K تقسیم می کند.

Mean Precision Rank -3-12-4

روش های برای هر پرس و جو، رتبه اولین تصویر مرتبط محاسبه می شود:

$$RR_q = \frac{1}{rank_q}$$

و سپس:

$$MRR = \frac{1}{N} \sum_{q=1}^N RR_q$$

تابع reciprocal_rank اولین تصویر مرتبط موجود در ranking را پیدا کرده و معکوس رتبه آن را برمی گرداند.

3-13- راهبرد مدیریت embedding ها

به منظور جلوگیری از محاسبه مجدد embedding تصاویر در اجرای متوالی آزمایش ها، embedding های CLIP تصاویر گالری در فایل cache ذخیره می شوند.

اطلاعاتی مانند:

- version
- model_name
- gallery_ids
- normalized
- raw

در ساختار cache قرار می گیرند و هنگام بارگذاری، سازگاری مدل و شناسه های گالری بررسی می شود . این روش به ویژه برای آزمایش های متعدد روی یک گالری ثابت اهمیت دارد، زیرا عملیات inference تصاویر گالری تنها یک مرتبه انجام شده و در اجرای بعدی embedding ها مستقیماً از حافظه ذخیره شده خوانده می شوند.

3-14- کنترل اعتبار داده ها

پیش از اجرای مدل، داده های CIRRR از نظر وجود Ground Truth بررسی می شوند. برای هر query مشخص می شود که آیا target_hard یا positive های معتبر وجود دارند یا خیر. همچنین وجود img_set.members نیز بررسی می شود .

در صورت استفاده از گزینه --require_cirr_gt، اگر داده فاقد Ground Truth مورد نیاز باشد، اجرای ارزیابی متوقف می شود. این سازوکار از تولید metric های نامعتبر جلوگیری می کند .


3-15- مدیریت خطا و query های نامعتبر


در فرآیند ارزیابی، ممکن است تصویر reference وجود نداشته باشد، embedding آن ایجاد نشده باشد یا caption خالی باشد. در این شرایط query با ذکر علت در بخش skip_reasons ثبت می شود. برای نمونه، در SEARLE در صورت نبود embedding تصویر reference یا خالی بودن caption، query ارزیابی خارج می شود .

این طراحی امکان تحلیل خطا و بررسی کیفیت داده را در فصل های بعدی فراهم می کند.

16-3- طراحی فرآیند آزمایش

فرآیند کامل ارزیابی مدل ها به صورت زیر طراحی شده است:





رای هر مدل، ranking تولید شده و سپس نتایج با Ground Truth متناظر مقایسه می شوند. در پایان، نتایج همه مدل ها در یک جدول مشترک ذخیره و نمایش داده می شوند. جدول نهایی شامل MRR، سه مقدار mAP، چهار مقدار Precision و چهار مقدار Recall است.

3-17- ذخیره نتایج آزمایش

برای بازتولیدپذیری آزمایش ها، نتایج علاوه بر نمایش در ترمینال، در یک فایل JSON نیز ذخیره می شوند. فایل نتیجه شامل نام مجموعه داده، split، وضعیت پروتکل CIRR subset، نتایج metric ها و ترتیب معیارهای گزارش شده است.

ترتیب معیارهای ثبت شده در فایل خروجی به صورت زیر است:

- MRR
- mAP@5
- mAP@10
- mAP@50
- P@1
- P@5
- P@10
- P@50
- R@1
- R@5

• R@10

• R@50

این ویژگی امکان تحلیل مجدد نتایج و ایجاد جداول و نمودارهای فصل چهارم را بدون اجرای مجدد مدل فراهم می کند.

18-3- پارامترهای قابل تنظیم آزمایش

پارامتر	نقش
--dataset	انتخاب مجموعه داده
--image_folder	مسیر تصاویر
--json_path	مسیر annotation
--models	انتخاب مدل ها
--alphas	وزن ترکیب تصویر و متن
--betas	وزن در CLIP-beta
--cirr_subset	فعال سازی subset protocol
--searle_hybrid_weights	وزن ترکیب CLIP و SEARLE
--clip_model	انتخاب backbone CLIP
--searle_path	مسیر نسخه محلی SEARLE
--force_rebuild_embeddings	بازسازی cache

پارامترهای مربوط به مدل ها و وزن های آزمایش در رابط خط فرمان برنامه تعریف شده اند.

19-3- روش مقایسه مدل ها

روش های برای اطمینان از عادلانه بودن مقایسه، مدل های مختلف در یک چارچوب یکسان ارزیابی می شوند. برای همه مدل ها:

1. annotation یکسان استفاده می شود؛

2. مجموعه تصاویر گالری یکسان است؛

3. Ground Truth یکسان است؛

4. پروتکل subset یکسان اعمال می شود؛

5. معیارهای ارزیابی یکسان هستند .

به این ترتیب، تفاوت مشاهده شده در عملکرد مدل ها عمدتاً ناشی از تفاوت روش استخراج و ترکیب نمایش های تصویری و متنی خواهد بود.

20-3- قابلیت بازتولید آزمایش ها

یکی از اصول طراحی پیاده سازی، قابلیت تکرار آزمایش ها است. به همین منظور، مسیر داده ها، مدل، تنظیمات وزن دهی، split و نتایج metric ها در فرآیند اجرای برنامه مشخص شده و embedding های استخراج شده نیز در cache نگهداری می شوند. از طرف دیگر، prediction های SEARLE نیز در فایل JSON جداگانه ذخیره می شوند که شامل شناسه query، تصویر reference، caption و ranking تصاویر است .

21-3- جمع بندی فصل

در این فصل، روش پیشنهادی و چارچوب پیاده سازی سیستم بازیابی تصویر ترکیبی تشریح شد. ابتدا ساختار داده های CIRR و فرآیند استخراج اطلاعات مربوط به تصویر مرجع، caption و Ground Truth بررسی شد. سپس فرآیند استخراج embedding با CLIP، ساخت پرس و جوی ترکیبی در SEARLE و روش های مقایسه ای OpenCLIP، SigLIP و CLIP-beta توضیح داده شدند. همچنین سازوکار ranking در دو حالت Full Gallery و CIRR Subset، روش تعیین تصاویر مرتبط، معیارهای MRR، mAP، Recall و Precision، مدیریت embedding cache و سازوکار کنترل خطا تشریح شد. در نهایت، چارچوبی یکپارچه برای مقایسه مدل های مختلف طراحی شد که امکان استخراج و ذخیره نتایج ۱۲ معیار ارزیابی را فراهم می کند. در فصل بعد، نتایج حاصل از اجرای این چارچوب روی مجموعه داده CIRR ارائه شده و عملکرد مدل های مختلف بر اساس معیارهای تعریف شده مورد مقایسه قرار خواهد گرفت.

1-21-3- علت انتخاب روش

روش های سنتی بازیابی تصویر مبتنی بر محتوا تنها بر اساس شباهت های بصری (Visual Similarity) عمل می کردند و توانایی درک مقاصد پیچیده کاربر که نیازمند ترکیب تصویر و متن است را نداشتند. دلیل انتخاب مدل های تصویر-زبان مانند CLIP (Contrastive Language-Image Pre-training) این است که این مدل ها می توانند تصاویر و متن ها را در یک فضای جاسازی (Embedding Space) مشترک نمایش دهند.

با استفاده از این روش، می توانیم ویژگی های بصری تصویر مرجع (Reference Image) و متن اصلاحی (Modification Text/Relative Caption) را استخراج کرده و آن ها را به صورت هدفمند ترکیب کنیم تا به ویژگی تصویر هدف نزدیک شود (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۱). همچنین استفاده از این معماری ها امکان ارزیابی در تنظیمات بدون نمونه (Zero-shot) را نیز فراهم می کند که برای داده های دنیای واقعی بسیار کارآمد است (مقاله *CoLLM*, صفحه ۱).

2-21-3- تشریح کامل روش تحقیق

با توجه به ماهیت مسئله، روش تحقیق این پژوهش از نوع **تحلیلی/مدل سازی و نرم افزار نویسی** است که مراحل آن در ادامه تشریح می شود:

۱. مبانی مدل و استخراج ویژگی ها (Feature Extraction):

در مرحله اول، پایگاه داده ای از تصاویر (گالری) تشکیل می شود. برای تمامی این تصاویر، ویژگی های بصری با استفاده از رمزگذار تصویر مدل CLIP (CLIP Image Encoder) پیش محاسبه (Pre-compute) شده و در حافظه سیستم ذخیره می گردند تا سرعت جست و جو افزایش یابد. در زمان پرس و جو (Query Time)، کاربر یک تصویر مرجع و یک متن ارائه می دهد. تصویر مرجع وارد رمزگذار تصویر CLIP شده و ویژگی بصری fimage تولید می شود. همچنین متن اصلاحی وارد رمزگذار متن (CLIP Text Encoder) شده و بردار ویژگی متنی f_text استخراج [29].

۲. مدل سازی شبکه ترکیب کننده^۱:

هسته اصلی این روش، یک شبکه پرسپترون چندلایه (MLP) به نام شبکه ترکیب کننده است. این شبکه بردارهای f_text و f_image را دریافت کرده و یک ویژگی ترکیبی (Combined Feature) تولید می کند. ساختار معماری این شبکه شامل لایه های زیر است:

- لایه خطی اول (Linear)
- تابع فعال سازی (ReLU)
- لایه حذف تصادفی (Dropout) جهت جلوگیری از بیش برآش (Overfitting)
- لایه خطی دوم (Linear)
- تابع فعال سازی سیگموید (σ - Sigmoid) در خروجی.

این شبکه از طریق یادگیری تقابلی^۲ آموزش می بیند تا بردار ترکیبی تولید شده، بیشترین شباهت را با بردار تصویر هدف (Target Image) در پایگاه داده داشته باشد [29].

۳. پیاده سازی نرم افزاری و بازیابی^۳:

از نظر نرم افزاری، به منظور کاهش مصرف حافظه و افزایش سرعت، شبکه ترکیب کننده و مدل CLIP هر دو در دقت نیمه (Half Precision - fp16) اجرا می شوند (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۵). پس از تولید ویژگی ترکیبی، فرآیند بازیابی دقیقاً مشابه یک سیستم CBIR استاندارد عمل می کند؛ بدین صورت که فاصله کسینوسی^۴ بین ویژگی ترکیبی و تمام ویژگی های تصاویر گالری محاسبه شده و تصاویر بر اساس بیشترین شباهت رتبه بندی^۵ می شوند.

۴. روش اعتبارسنجی^۶:

برای اعتبارسنجی مدل پیشنهادی، از مجموعه داده های استاندارد در این حوزه نظیر FashionIQ (برای حوزه مد) و CIRR (برای تصاویر عمومی دنیای واقعی) استفاده می شود. معیار اصلی ارزیابی، نرخ یادآوری در رتبه K یا $K@KRecall@KRecall@Recall$ است. به طور خاص، عملکرد مدل با معیارهای $10@Recall@10Recall10@Recall$ و $50@Recall@50Recall50@Recall$ سنجیده می شود. برای مجموعه داده CIRR، نتایج هم بر روی کل گالری و هم بر روی زیرمجموعه های معنایی (Subset Results)

¹ Combiner Network

² Contrastive Learning

³ Retrieval Process

⁴ Cosine Similarity

⁵ Ranking

⁶ Validation Method

گزارش می گردد تا دقت روش تحقیق به طور کامل اثبات شود (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۵ و مقاله *CoLLM*, صفحه ۸).

۵. معرفی دقیق مجموعه داده ها (Datasets):

در این پژوهش، از دو مجموعه داده استاندارد با دامنه های متفاوت برای آموزش و اعتبارسنجی شبکه ترکیب کننده استفاده شده است. این تنوع در پایگاه داده ها، نشان دهنده قابلیت تعمیم پذیری (Generalizability) روش پیشنهادی است.

الف) مجموعه داده FashionIQ:

این مجموعه داده به طور خاص برای بازیابی در حوزه مد و پوشاک (Fashion Domain) طراحی شده است (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۲).

- **دسته بندی ها:** بر اساس پروتکل استاندارد ارزیابی FashionIQ، این مجموعه داده به سه دسته اصلی پوشاک تقسیم بندی می شود:

1. پیراهن ها (Dress)

2. تاپ و تی شرت (Toptee)

3. پیراهن مردانه/بلوز (Shirt)

- **نحوه ارزیابی:** نتایج ارزیابی مدل برای این مجموعه داده روی مجموعه اعتبارسنجی (Validation Set) گزارش می شود. معیارهای کلیدی برای این مجموعه داده $10@Recall$ ، $10@Recall@10$ و $50@Recall@50$ هستند که نشان دهنده درصد موفقیت مدل در یافتن تصویر هدف در میان ۱۰ یا ۵۰ تصویر برتر بازیابی شده است (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحات ۵ و ۷).

ب) مجموعه داده CIRR:

این مجموعه داده شامل تصاویر عمومی و دنیای واقعی (Generic real-world images) است و برای سنجش عملکرد مدل در شرایط پیچیده تر و عمومی تر استفاده می شود (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۳).

- **ساختار و حجم داده ها:** این مجموعه داده شامل ۳۶,۵۵۴ سه تایی (Triplet) است. هر سه تایی شامل یک تصویر مرجع، یک متن اصلاحی (Relative Caption) و یک تصویر هدف می باشد.
- **گروه بندی معنایی:** تصاویر در این پایگاه داده در زیرمجموعه های ۶ تایی (Subsets of six images) که از نظر بصری و معنایی بسیار به یکدیگر شبیه هستند، گروه بندی شده اند. کپشن های

نسبی دقیقاً بر اساس تفاوت های ظریف بین این ۶ تصویر نوشته شده اند تا مدل را در درک جزئیات دقیق به چالش بکشند.

- **تقسیم بندی داده ها (Data Split):** داده های CIRR به صورت تصادفی به سه بخش تقسیم شده اند:

- **۸۰ درصد** برای آموزش شبکه (Training Set)

- **۱۰ درصد** برای اعتبارسنجی (Validation Set)

- **۱۰ درصد** برای آزمون نهایی (Test Set)

- **نحوه ارزیابی:** به دلیل عدم انتشار برچسب های حقیقت زمینه ای (Ground-truth labels) برای مجموعه آزمون (Test set) در زمان ارائه روش، تمام ارزیابی ها و گزارش های عملکردی (مانند $K@KRecall@KRecall@Recall$) بر روی مجموعه اعتبارسنجی (Validation Set) محاسبه شده است. برای CIRR علاوه بر نتایج کلی، نتایج زیرمجموعه ای (Subset Results) نیز برای بررسی دقت مدل در میان تصاویر بسیار مشابه گزارش می شود (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحات ۵ و ۶).

نکته درباره محیط دمو (Demo):

در محیط دمویی که برای تست این روش طراحی شده است، کاربر می تواند بین استفاده از کپشن های موجود در مجموعه اعتبارسنجی و یا وارد کردن کپشن دلخواه خود یکی را انتخاب کند. در صورتی که کپشنی از مجموعه اعتبارسنجی انتخاب شود، جست و جو فقط در تصاویر همان مجموعه انجام می پذیرد تا امکان مقایسه دقیق با تصاویر هدف (Ground truth) فراهم باشد (مقاله *Effective Conditioned and Composed Image Retrieval*, صفحه ۵).

□ روش تحقیق آزمایشگاهی

توصیف کامل برنامه ی آزمایشگاهی شامل مواد مصرفی و نحوه ی ساخت نمونه ها، شرح آزمایش ها شامل نحوه تنظیم و آماده سازی آزمایش ها و دستگاه های مورد استفاده و دقت و نحوه ی کالیبره کردن، شرح دستگاه ساخته شده (در صورت ساخت) و ارائه ی روش اعتبارسنجی.

□ روش تحقیق آماری

توصیف ابزارهای گردآوری اطلاعات کمی و کیفی، اندازه‌ی نمونه‌ها، روش نمونه‌برداری، تشریح مبانی روش آمار و ارائه‌ی روش اعتبارسنجی.

□ روش تحقیق نرم‌افزارنویسی

توصیف کامل برنامه‌نویسی، مبانی برنامه و ارائه‌ی روش اعتبارسنجی.

□ روش تحقیق مطالعه‌ی موردی

توصیف کامل محل و موضوع مطالعه، علت انتخاب مورد و پارامترهایی که تحت ارزیابی قرار داده می‌شوند، و ارائه‌ی روش اعتبارسنجی.

□ روش تحقیق تحلیلی یا مدلسازی

توصیف کامل مبانی یا اصول تحلیل یا مدل و ارائه‌ی روش اعتبارسنجی.

□ روش تحقیق میدانی

چگونگی دستیابی به داده‌ها در میدان عمل و نحوه برداشت از پاسخ‌های دریافتی

جدول (3-1) بالانویس جدول

جدول

متن

شکل

زیرنویس شکل

متن

فرمول

(1-3)

متن

فصل 4:

نتایج و تفسیر آنها

4-1- مقدمه

ارائه‌ی در این فصل نتایج حاصل از پیاده‌سازی و ارزیابی روش‌های مورد بررسی در مسئله بازیابی تصویر ترکیبی ارائه و تحلیل می‌شود. هدف از انجام آزمایش‌ها، بررسی توانایی روش‌های مختلف در بازیابی تصویر هدف با استفاده همزمان از تصویر مرجع و توصیف متنی تغییر موردنظر است.

در این راستا، مدل‌های CLIP، SEARLE، OpenCLIP، SigLIP و روش CLIP-beta در چارچوب آزمایشی یکسان مورد ارزیابی قرار گرفته‌اند. برای هر روش، تصاویر گالری پس از استخراج ویژگی در فضای embedding قرار گرفته و بر اساس میزان شباهت با پرس‌وجوی ترکیبی رتبه‌بندی شده‌اند. سپس رتبه‌بندی حاصل با تصاویر مرتبط موجود در Ground Truth مقایسه شده است.

برای سنجش عملکرد مدل‌ها از دوازده معیار شامل MRR، mAP@5، mAP@10، mAP@50، Precision@1، Precision@5، Precision@10، Recall@1، Recall@5، Recall@10 و Recall@50 استفاده شده است. ساختار کد نیز همین دوازده معیار را برای ذخیره و گزارش نتایج در نظر گرفته است.

در این فصل ابتدا صحت داده‌ها و شرایط اجرای آزمایش بررسی می‌شود، سپس نتایج هر مدل به صورت مستقل ارائه و تحلیل شده و در ادامه مقایسه جامع مدل‌ها، تحلیل خطا، تحلیل هزینه محاسباتی و مقایسه با نتایج پژوهش‌های پیشین انجام می‌شود. در تمامی موارد، تفسیر نتایج صرفاً بر اساس مقادیر به‌دست‌آمده از آزمایش‌ها و شواهد موجود انجام خواهد شد.

4-2- محیط اجرای آزمایش‌ها و تنظیمات نهایی

4-2-1- مشخصات سخت افزاری

مشخصات	مولفه
	CPU
16 GB	RAM
	GPU

	VRAM
	Storage
	Operating System

2-2-4- مشخصات نرم افزاری

نسخه	نرم افزار / کتابخانه
3.10.5	Python
	PyTorch
	CUDA
1.0	OpenAI CLIP
	OpenCLIP
5.8.1	Transformers
12.2.0	Pillow
2.2.6	NumPy

3-4- آماده سازی و صحت سنجی

همان گونه که جدول ... نشان می دهد، تمامی query های مجموعه validation دارای Ground Truth معتبر بوده اند. بنابراین امکان محاسبه محلی معیارهای ارزیابی برای مجموعه validation فراهم بوده است. همچنین پیش از آغاز فرآیند inference، پوشش تصاویر reference و تصاویر مورد نیاز در گالری بررسی شده است تا حذف ناخواسته query ها بر نتایج نهایی اثر نگذارد.

مورد	تعداد
کل Query ها	4181
Query دارای target_hard	4181
Query دارای positive	4181

0	Query بدون Ground Truth
	Reference های یکتا
4181	Reference های موجود
0	Reference های مفقود

4-4- معیار های ارزیابی

داده ها و نتایج به صورت تابعی از پارامترهای

معیارها	دسته
MRR	رتبه
mAP@5, mAP@10, mAP@50	mAP
P@1, P@5, P@10, P@50	Precision
R@1, R@5, R@10, R@50	Recall

4-5- نتایج CLIP

R@50	R@10	R@5	R@1	P@50	P@10	P@5	P@1	mAP@50	mAP@10	mAP@5	MR R	a
1.0000	1.0000	1.0000	0.2122	0.0200	0.1000	0.2000	0.2122	0.4690	0.4690	0.4690	0.4690	0
1.0000	1.0000	1.0000	0.2495	0.0200	0.1000	0.2000	0.2495	0.5028	0.5028	0.5028	0.5028	0.25
1.0000	1.0000	1.0000	0.3401	0.0200	0.1000	0.2000	0.3401	0.5736	0.5736	0.5736	0.5736	0.50
1.0000	1.0000	1.0000	0.5042	0.0200	0.1000	0.2000	0.5042	0.6899	0.6899	0.6899	0.6899	0.75
1.0000	1.0000	1.0000	0.6238	0.0200	0.1000	0.2000	0.6238	0.7711	0.7711	0.7711	0.7711	1.00

[illegible]

SERALE 4-6- نتایج

R@5 0	R@1 0	R@5	R@1	P@5 0	P@1 0	P@5	P@1	mAP@ 50	mAP@ 10	mAP @5	MR R	مدل
1.00 00	1.00 00	1.00 00	0.55 70	0.02 00	0.10 00	0.20 00	0.55 70	0.7295	0.7295	0.7295	0.72 95	Search

7-4- نتایج Siglip

مقایسه نتایج نشان می‌دهد که مدل ... در معیار MRR مقدار بالاتری نسبت به مدل ... به دست آورده است. این تفاوت تنها در صورتی از نظر پژوهشی قابل تفسیر است که تفاوت در شرایط اجرای دو مدل وجود

نداشته باشد؛ از این رو هر دو مدل در این پژوهش با گالری، Ground Truth و پروتکل یکسان ارزیابی شدند.

4-8- نتایج Blip

R@50	R@10	R@5	R@1	P@50	P@10	P@5	P@1	mAP@50	mAP@10	mAP@5	MR R	a
0.9189	0.7029	0.5492	0.2263	0.0184	0.0703	0.1098	0.2263	0.3737	0.3622	0.3416	0.3745	Blip

مقایسه نتایج نشان می دهد که مدل ... در معیار MRR مقدار بالاتری نسبت به مدل ... به دست آورده است. این تفاوت تنها در صورتی از نظر پژوهشی قابل تفسیر است که تفاوت در شرایط اجرای دو مدل وجود نداشته باشد؛ از این رو هر دو مدل در این پژوهش با گالری، Ground Truth و پروتکل یکسان ارزیابی شدند.

4-9- مقایسه جامع مدل ها

مدل	MR R	mAP@5	mAP@10	mAP@50	P@1	P@5	P@10	P@50	R@1	R@5	R@10	R@50
CLIP												
SEARLE												
OpenCLIP												
SigLip												
CLIP-beta												

4-10- تحلیل جامع نتایج

بر اساس MRR

بالاترین MRR مربوط به مدل ... با مقدار ... بوده است، در حالی که پایین ترین مقدار متعلق به مدل ... با مقدار ... است.

بر اساس Recall@50

مدل ... با Recall@50 برابر ... بیشترین پوشش تصاویر مرتبط را در 50 نتیجه اول ایجاد کرده است.

بر اساس Precision@1

در معیار Precision@1، مدل ... عملکرد بهتری داشته و این موضوع نشان می دهد که تصویر مرتبط در اولین نتیجه با احتمال بیشتری بازیابی شده است.

4-11- تحلیل CIRR Subset و Full Gallery

مدل	P r o t o c o l	M R R	mAP @5	mAP @10	mAP @50	P @ 1	P @ 5	P@ 10	P@ 50	R @1	R @5	R@ 10	R@ 50
CLIP													
SEAR LE													
OpenC LIP													
SigLip													
CLIP- beta													

در مقایسه نتایج دو پروتکل نشان می دهد که محدود کردن فضای جست و جو به اعضای `img_set` باعث ... در معیار ... شده است. این تفاوت بر اساس تغییر فضای جست و جو تفسیر می شود و باید با مقدار واقعی معیارها پشتیبانی شود.

4-12- تحلیل خطا

4-12-1- خطای تصویر مرجع

4-13- تحلیل جامع نتایج

4-14- تحلیل جامع نتایج

4-15- محتوا

تولید داده ها

ارائه ی داده ها و نتایج به صورت تابعی از پارامترهای مستقل است.

جدول (4-1) بالانویس جدول

جدول

متن

شکل

زیرنویس شکل

متن

فرمول

(1-4)

متن

فصل 5:

جمع‌بندی و پیشنهادها

1-5- مقدمه

ارائه‌ی خلاصه‌ای از یافته‌های تحقیق جاری است. این فصل می‌تواند حاوی یک مقدمه شامل مروری اجمالی بر مراحل انجام تحقیق باشد (حدود یک صفحه). مطالب پاراگراف‌بندی شود و هر پاراگراف به یک موضوع مستقل اختصاص یابد. فقط به ارائه‌ی یافته‌ها و دست‌آوردها بسنده شود و از تعمیم بی‌مورد نتایج خودداری شود. از ارائه‌ی جداول و نمودارها اجتناب شود. از ارائه‌ی عناوین کلی در حوزه‌ی تحقیق و پیشنهاد تحقیقات آتی خودداری شود و کاملاً در چارچوب و زمینه‌ی مربوط به تحقیق جاری باشد. این فصل حدود 5 صفحه است.

2-5- محتوا

به ترتیب شامل موارد زیر است:

جمع‌بندی

خلاصه‌ای از تمام یافته‌ها و دست‌آوردهای تحقیق جاری است.

نوآوری

نوآوری تحقیق را بر اساس یافته‌های آن تشریح می‌کند.

پیشنهادها

عناوین و موضوعات پیشنهادی را برای تحقیقات آتی بیشتر در زمینه‌ی مورد بحث در آینده ارائه می‌کند.

جدول (5-1) بالانویس جدول

جدول

متن

شکل

زیرنویس شکل

متن

فرمول

(1-5)

متن

مراجع

مراجع

- [1] Radford, A., Kim, J. W., Hallacy, C., et al. (2021). Learning Transferable Visual Models From Natural Language Supervision. ICML.
- [2] Liu, Y., et al. (2023). SEARLE: A Structure-aware Retrieval Learning for Composed Image Retrieval. arXiv preprint arXiv:2306.00924.
- [3] Qwen2.5-VL Technical Report. Alibaba Cloud, 2024.
- [4] Li, J., & Yu, C. (2022). BLIP: Bootstrapped Language-Image Pre-training for Unified Vision-Language Understanding and Generation. ICML.
- [5] سید حسین سیدین، "مدل سازی انتقال حرارت و انجماد در فرایند ریخته گری مداوم تک غلتکه رول سرب — کلسیم"، گزارش قرارداد تحقیقاتی، شهریور 1380

[6]

پیوست‌ها

پیوست الف

Abstract:

Abstract ...

Keywords:



IU ST

**Iran University of Science and Technology
..... Department (or School of -----)**

Thesis Title

**A Thesis Submitted in Partial Fulfillment of the Requirement for the
Degree of Master of Science (Doctor of Philosophy) in -----**

**By:
Student Name**

**Supervisor:
Dr. -----**

**Advisor:
Dr. -----
Dr. -----**

December 2008

Gan, Z., et al., <i>Vision-language pre-training: Basics, recent advances, and future trends</i> . Foundations and Trends® in Computer Graphics and Vision, 2022 .p. 163–352	.2
Li, J., et al. <i>Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation</i> . PMLR	.3
Li, J., et al., <i>Align before fuse: Vision and language representation learning with momentum distillation</i> . Advances in neural information processing systems, 2021. 34 : .p. 9694–9705	.4
.Singh, A., et al. <i>Flava: A foundational language and vision alignment model</i>	.5
Dosovitskiy, A., et al., <i>An image is worth 16x16 words: Transformers for image recognition at scale</i> . arXiv preprint arXiv:2010.11929, 2020	.6
Liu, Z., et al. <i>Image retrieval on real-life images with pre-trained vision-and-language models</i>	.7
Saito, K., et al. <i>Pic2word: Mapping pictures to words for zero-shot composed image retrieval</i>	.8
Huang, K., et al., <i>T2i-compbench++: An enhanced and comprehensive benchmark for compositional text-to-image generation</i> . IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025	.9
.Baldrati, A., et al. <i>Zero-shot composed image retrieval with textual inversion</i>	.10
.Bai, S., et al., <i>Qwen2. 5-vl technical report</i> . arXiv preprint arXiv:2502.13923, 2025	.11
Faysse, M., et al., <i>Colpali: Efficient document retrieval with vision language models</i> . arXiv preprint arXiv:2407.01449, 2024	.12
<i>Image retrieval: Ideas, influences, and trends of the new age</i> . ACM Computing Surveys (Csur), 2008. 40 (2): p. 1–60	.13
Manzoor, M.A., et al., <i>Multimodality representation learning: A survey on evolution, pretraining and its applications</i> . ACM Transactions on Multimedia Computing, Communications and Applications, 2023. 20 (3): p. 1–34	.14
.Vo, N., et al. <i>Composing text and image for image retrieval-an empirical odyssey</i>	.15
Zhang, D. and G. Lu, <i>Review of shape representation and description techniques</i> . Pattern recognition, 2004. 37 (1): p. 1–19	.16
Faghri, F., et al., <i>Vse++: Improving visual-semantic embeddings with hard negatives</i> . arXiv preprint arXiv:1707.05612, 2017	.17
Smeulders, A.W.M., et al., <i>Content-based image retrieval at the end of the early years</i> . IEEE Transactions on pattern analysis and machine intelligence, 2002. 22 (12): .p. 1349–1380	.18
Krizhevsky, A., I. Sutskever, and G.E. Hinton, <i>Imagenet classification with deep convolutional neural networks</i> . Advances in neural information processing systems, 2012. 25	.19
Li, J., et al., <i>Align before Fuse: Vision and Language Representation Learning with Momentum Distillation</i> . arXiv preprint, 2021. arXiv:2107.07651	.20
Dubey, S.R., <i>A decade survey of content based image retrieval using deep learning</i> . IEEE Transactions on Circuits and Systems for Video Technology, 2021. 32 (5): p. .2687–2704	.21
.Huynh, C., et al. <i>Collm: A large language model for composed image retrieval</i>	.22

Schütze, H., C.D. Manning, and P. Raghavan, <i>Introduction to information retrieval</i> . .Vol. 39. 2008: Cambridge University Press Cambridge	.23
.Zhang, J., et al., <i>Vision-Language Models for Vision Tasks: A Survey</i> . 2024	.24
Han, X., et al., <i>Multimodal Fusion and Vision-Language Models: A Survey for Robot</i> .Vision. arXiv preprint, 2025	.25
Xu, J., et al., <i>GroupViT: Semantic Segmentation Emerges from Text Supervision</i> . .arXiv preprint, 2022. arXiv:2202.11094	.26
Lüddecke, T. and A. Ecker, <i>Image Segmentation Using Text and Image Prompts</i> . .arXiv preprint, 2022. arXiv:2112.10003	.27
.Kirillov, A., et al., <i>Segment Anything</i> . arXiv preprint, 2023. arXiv:2304.02643	.28
Baldrati, A., et al., <i>Effective Conditioned and Composed Image Retrieval Combining</i> .CLIP-based Features. Unknown Journal, 2023. TBD	.29